

从概率路径到可训练流

Flow Matching 推导

—作者: Yang kunpeng

算法核心：训练时借助容易获得的条件速度作为监督，
最终让网络学到生成时真正需要的边缘速度场

前言

本书把 Flow Matching 的构造与训练放在正文主线中，概率论、微积分和向量微积分等基础内容集中到附录。正文从噪声分布到数据分布的运输问题出发，依次引入概率路径、条件路径与条件向量场，再由条件构造得到边缘路径和边缘向量场；随后讨论 Flow Matching loss、Conditional Flow Matching loss 及其等价性，最后给出 straight-line 训练和 ODE 采样。

推导中第一次用到某项基础数学时，正文会给出简短的交叉引用，读者可按需查阅附录。例如：

数学基础提示：这里使用 Bayes 定理与 posterior，详见附录 A.1。

已经熟悉相关数学的读者可以直接沿正文阅读；需要补充细节时，再转到相应附录。正文与附录的关系以推导所需为准。

全书主线。

$$\begin{aligned} X_0 \sim p_{\text{init}} &\longrightarrow \{p_t\}_{t \in [0,1]} \longrightarrow (p_t(\mathbf{x} \mid \mathbf{z}), \mathbf{u}_t(\mathbf{x} \mid \mathbf{z})) \\ &\longrightarrow (p_t(\mathbf{x}), \mathbf{u}_t(\mathbf{x})) \longrightarrow \mathcal{L}_{\text{CFM}} \longrightarrow \mathbf{u}_t^\theta \longrightarrow X_1 \sim p_{\text{data}}. \end{aligned}$$

符号约定

符号	含义
$\boldsymbol{z} \sim p_{\text{data}}$	从真实数据分布抽到的数据样本，也是条件构造中已知的目标数据点
$\boldsymbol{\epsilon} \sim \mathcal{N}(0, \boldsymbol{I}_d)$	标准 Gaussian 噪声
$t \in [0, 1]$	连续时间
X_t	时刻 t 的随机状态；大写表示随机变量
$\boldsymbol{x}$ 或 $\boldsymbol{x}_t$	某个具体状态或一次具体采样得到的中间样本
$p_t(\boldsymbol{x} \mid \boldsymbol{z})$	给定数据点 $\boldsymbol{z}$ 时的 conditional probability path
$p_t(\boldsymbol{x})$	对所有 $\boldsymbol{z}$ 边缘化后的 marginal probability path
$\boldsymbol{u}_t(\boldsymbol{x} \mid \boldsymbol{z})$	conditional vector field
$\boldsymbol{u}_t(\boldsymbol{x})$	marginal vector field，生成阶段真正需要的速度场
$\boldsymbol{u}_t^\theta(\boldsymbol{x})$	神经网络对 marginal vector field 的近似

目录

前言	ii
符号约定	iii
第一章 流匹配	1
1.1 从生成问题到概率路径	1
1.2 条件流匹配：构造一个容易处理的 Flow	3
1.3 从条件流到边缘流	6
第二章 训练流匹配	9
2.1 从 Marginal Flow Matching Loss 到 Conditional Flow Matching Loss	9
2.2 为什么 Conditional Flow Matching 能学到 Marginal Flow	10
2.3 Straight-Line Flow Matching：从理论到训练与生成	13
附录 A 流匹配推导所需的数学基础	17
A.1 概率论基础	17
A.2 微积分基础	20
A.3 向量微积分与连续性方程	22
A.4 Gaussian 基础	24

流匹配

1.1 从生成问题到概率路径

这里考虑的生成问题是：从一个容易采样的初始分布出发，通过连续动力学把样本运输到真实数据分布。记

$$X_0 \sim p_{\text{init}}, \quad X_1 \sim p_{\text{data}}.$$

常见选择是

$$p_{\text{init}} = \mathcal{N}(0, \mathbf{I}_d).$$

Flow Model 用时间相关向量场定义常微分方程 (ODE)：

$$\frac{dX_t}{dt} = \mathbf{u}_t(X_t). \quad (1.1)$$

若粒子在时刻 t 位于 $\mathbf{x}$ ， $\mathbf{u}_t(\mathbf{x})$ 给出该位置的瞬时速度；其方向和模长分别对应运动方向与速度大小。

数学基础提示：随机变量、概率密度与向量的基本记号，详见附录 A.1。

粒子轨迹与分布演化。 固定初值 $X_0 = \mathbf{x}_0$ 后，ODE 的解对应一条确定轨迹。生成时，初始状态本身来自随机采样：

$$X_0 \sim p_{\text{init}},$$

每个初始样本都按同一向量场运动，因此时刻 t 的随机状态具有一个随时间变化的分布，记作

$$X_t \sim p_t.$$

下列三个对象分别描述速度规则、随机状态和总体分布：

- $\mathbf{u}_t(\mathbf{x})$ 描述某个位置上的瞬时速度规则；

- X_t 描述一个随机粒子的状态；
- $p_t(\mathbf{x})$ 描述所有粒子在时刻 t 的总体概率密度。

从端点分布到概率路径。 仅给出

$$p_0 = p_{\text{init}}, \quad p_1 = p_{\text{data}},$$

还不能确定中间时刻的运输方式，也就无法给网络定义逐时刻的速度目标。Flow Matching 因而先指定一族中间分布：

$$\{p_t\}_{t \in [0,1]}, \quad p_0 = p_{\text{init}}, \quad p_1 = p_{\text{data}}.$$

这族分布称为概率路径（probability path）。

概率路径描述的是各个时刻的分布快照。它不指定某个初始粒子必须沿哪一条曲线运动到终点；具体粒子轨迹由所选向量场及初值共同决定。

指定目标概率路径 p_t 后，还需要确定与它相容的向量场。采样阶段实际运行的是 ODE (1.1)，因此要求该 ODE 诱导出的分布演化正好等于给定的 p_t 。二者的相容关系由连续性方程刻画。

一维连续性方程。 在一维空间取固定小区间 $[x, x + \Delta x]$ ，其中的概率质量近似为

$$p_t(x)\Delta x.$$

若粒子的速度为 $u_t(x)$ ，定义 probability flux

$$J_t(x) = p_t(x)u_t(x).$$

从量纲上看，

$$\frac{\text{概率}}{\text{长度}} \times \frac{\text{长度}}{\text{时间}} = \frac{\text{概率}}{\text{时间}},$$

因此 $J_t(x)$ 表示单位时间通过位置 x 的概率量。

区间内的概率变化等于左边流入减去右边流出：

$$\frac{d}{dt} [p_t(x)\Delta x] = J_t(x) - J_t(x + \Delta x).$$

因为区间位置固定，左边可写成

$$\frac{\partial p_t(x)}{\partial t} \Delta x.$$

两边除以 Δx 并令 $\Delta x \rightarrow 0$:

$$\frac{\partial p_t(x)}{\partial t} = -\frac{\partial J_t(x)}{\partial x}.$$

代入 $J_t = p_t u_t$:

$$\frac{\partial p_t(x)}{\partial t} = -\frac{\partial}{\partial x} [p_t(x) u_t(x)].$$

在高维空间中，一维空间导数相应推广为散度 (divergence):

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla \cdot [p_t(\mathbf{x}) \mathbf{u}_t(\mathbf{x})].$$

等价地，

$$\partial_t p_t + \nabla \cdot (p_t \mathbf{u}_t) = 0.$$

数学基础提示：偏导、积分号下求导、divergence 与连续性方程的严格积分推导，详见附录 A.3。

连续性方程与 Flow Matching. 连续性方程在这里作为速度场与概率路径之间的相容条件使用，并不额外构成训练 loss。给定候选 $\mathbf{u}_t$ 和目标 p_t ，若

$$\partial_t p_t = -\nabla \cdot (p_t \mathbf{u}_t)$$

成立，则由 $\mathbf{u}_t$ 产生的概率流与 p_t 的时间变化一致。因此后续构造可以写成：

先选择 p_t ，再寻找能够生成它的 $\mathbf{u}_t$ 。

1.2 条件流匹配：构造一个容易处理的 Flow

直接为真实数据分布写出可处理的边缘概率路径和边缘向量场通常并不方便。一个可行的做法是先固定训练数据点 $\mathbf{z}$ ，研究从噪声到该数据点的条件运输：

$$\mathbf{z} \sim p_{\text{data}}.$$

条件概率路径。 固定 $\mathbf{z}$ 后，定义条件概率路径

$$p_t(\mathbf{x} \mid \mathbf{z}).$$

一种常用且可以解析处理的选择是 Gaussian path:

$$p_t(\cdot \mid \mathbf{z}) = \mathcal{N}(\alpha_t \mathbf{z}, \beta_t^2 \mathbf{I}_d). \quad (1.2)$$

其中 $\alpha_t \mathbf{z}$ 给出 Gaussian 的均值， β_t 是各向同性标准差。

若希望条件路径从标准 Gaussian 出发，并在终点收缩到 $\mathbf{z}$ ，取端点条件

$$\alpha_0 = 0, \quad \beta_0 = 1,$$

以及

$$\alpha_1 = 1, \quad \beta_1 = 0.$$

此时

$$p_0(\cdot \mid \mathbf{z}) = \mathcal{N}(0, \mathbf{I}_d),$$

并且当 $t \rightarrow 1$ 时概率质量集中到 $\mathbf{z}$ 。

数学基础提示：条件概率、多元 Gaussian 与端点退化的含义，详见附录 A.4。

Gaussian 重参数化。 若

$$\epsilon \sim \mathcal{N}(0, \mathbf{I}_d),$$

则 Gaussian 的仿射变换给出

$$\mu + \sigma \epsilon \sim \mathcal{N}(\mu, \sigma^2 \mathbf{I}_d).$$

因此式 (1.2) 可通过下式采样：

$$X_t = \alpha_t \mathbf{z} + \beta_t \epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I}_d) \quad (1.3)$$

式 (1.3) 来自所选 Gaussian 条件路径的重参数化，并非由连续性方程反解得到。固定 ϵ 后，它给出一条具体粒子轨迹；令 ϵ 按标准 Gaussian 随机采样时， X_t 的分布就是 $p_t(\cdot \mid \mathbf{z})$ 。

数学基础提示：Gaussian 仿射变换与 reparameterization，详见附录 A.4。

条件速度与条件向量场。 对式 (1.3) 关于时间求导：

$$\frac{dX_t}{dt} = \dot{\alpha}_t \mathbf{z} + \dot{\beta}_t \boldsymbol{\epsilon}. \quad (1.4)$$

它给出了固定 $(\mathbf{z}, \boldsymbol{\epsilon})$ 时该轨迹的瞬时速度。

为了把速度写成当前位置 $\mathbf{x}$ 的函数，在 $\beta_t > 0$ 的时刻，由

$$\mathbf{x} = \alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}$$

解得

$$\boldsymbol{\epsilon} = \frac{\mathbf{x} - \alpha_t \mathbf{z}}{\beta_t}.$$

代回式 (1.4)：

$$\mathbf{u}_t(\mathbf{x} | \mathbf{z}) = \dot{\alpha}_t \mathbf{z} + \frac{\dot{\beta}_t}{\beta_t} (\mathbf{x} - \alpha_t \mathbf{z}) \quad (1.5)$$

$$\text{notag} = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) \mathbf{z} + \frac{\dot{\beta}_t}{\beta_t} \mathbf{x}. \quad (1.6)$$

所得式 (1.6) 即为该 Gaussian 条件概率路径对应的条件向量场。

数学基础提示：普通导数、偏导数、链式法则与乘积法则，详见附录 A.2。

与连续性方程的相容性。 这里的 $p_t(\mathbf{x} | \mathbf{z})$ 和 $\mathbf{u}_t(\mathbf{x} | \mathbf{z})$ 都由同一个显式粒子运动定义：

$$X_t = \alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}.$$

$p_t(\mathbf{x} | \mathbf{z})$ 描述该随机运动在时刻 t 的分布， $\mathbf{u}_t(\mathbf{x} | \mathbf{z})$ 描述同一运动的瞬时速度。在适当的正则条件下，概率质量守恒给出

$$\frac{\partial p_t(\mathbf{x} | \mathbf{z})}{\partial t} = -\nabla \cdot [p_t(\mathbf{x} | \mathbf{z}) \mathbf{u}_t(\mathbf{x} | \mathbf{z})]. \quad (1.7)$$

附录 A.4 将 Gaussian 密度与式 (1.6) 直接代入连续性方程，对两边作逐项验证。

数学基础提示：Gaussian 密度、log-density 求导与直接验证，详见附录 A.4。

上述构造可概括为

$$p_t(\mathbf{x} | \mathbf{z}) \longrightarrow X_t = \alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon} \longrightarrow \mathbf{u}_t(\mathbf{x} | \mathbf{z}).$$

固定目标数据点 z 后，条件路径既可直接采样，也能写出对应速度场，并与连续性方程相容。

1.3 从条件流到边缘流

条件构造依赖已知的数据点 z 。生成时从随机噪声出发，终点数据并未预先给定，因此采样 ODE 不能显式依赖 z 。需要把所有条件流合成为只依赖当前状态 $(\mathbf{x}, t)$ 的边缘流。

边缘概率路径。 数据点本身满足

$$z \sim p_{\text{data}}.$$

固定 z 时中间状态的条件密度是 $p_t(\mathbf{x} | z)$ ，因此联合密度为

$$p_t(\mathbf{x}, z) = p_t(\mathbf{x} | z)p_{\text{data}}(z).$$

只保留当前位置 $\mathbf{x}$ 时，对 z 做边缘化：

$$p_t(\mathbf{x}) = \int p_t(\mathbf{x} | z)p_{\text{data}}(z) \, dz. \quad (1.8)$$

所得 $p_t(\mathbf{x})$ 称为边缘概率路径。

数学基础提示：联合分布、条件分布与 marginalization，详见附录 A.1。

端点条件由条件路径直接继承。由于 $t = 0$ 时 $p_0(\mathbf{x} | z)$ 与 z 无关，

$$p_0(\mathbf{x}) = p_{\text{init}}(\mathbf{x}).$$

当 $t = 1$ 时，每个条件分布收缩到相应的数据点 z ；对 $z \sim p_{\text{data}}$ 做混合后得到

$$p_1(\mathbf{x}) = p_{\text{data}}(\mathbf{x}).$$

给定当前状态后的终点分布。 固定 $(\mathbf{x}, t)$ 后，同一状态可能对应不同的数据点 z 。不同 z 下的条件向量场给出的速度一般不同：

$$\mathbf{u}_t(\mathbf{x} | z).$$

因此需要根据给定当前状态后各个 z 的条件概率来加权。

由 Bayes 定理：

$$p(\mathbf{z} \mid \mathbf{x}, t) = \frac{p_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z})}{p_t(\mathbf{x})}. \quad (1.9)$$

其中 $p_{\text{data}}(\mathbf{z})$ 是先验分布 (prior), $p(\mathbf{z} \mid \mathbf{x}, t)$ 是给定当前状态后的后验分布 (posterior)。

数学基础提示：Bayes、prior、posterior 与条件期望，详见附录 A.1。

边缘向量场。 定义

$$\mathbf{u}_t(\mathbf{x}) = \int \mathbf{u}_t(\mathbf{x} \mid \mathbf{z})p(\mathbf{z} \mid \mathbf{x}, t) d\mathbf{z}. \quad (1.10)$$

也就是

$$\mathbf{u}_t(\mathbf{x}) = \mathbb{E}[\mathbf{u}_t(\mathbf{x} \mid Z) \mid X_t = \mathbf{x}, t].$$

利用式 (1.9)，可写成

$$\mathbf{u}_t(\mathbf{x}) = \frac{1}{p_t(\mathbf{x})} \int \mathbf{u}_t(\mathbf{x} \mid \mathbf{z})p_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}) d\mathbf{z}. \quad (1.11)$$

等价地，

$$p_t(\mathbf{x})\mathbf{u}_t(\mathbf{x}) = \int p_t(\mathbf{x} \mid \mathbf{z})\mathbf{u}_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}) d\mathbf{z}. \quad (1.12)$$

条件向量场以 $\mathbf{z}$ 为已知条件；边缘向量场只依赖当前的 $\mathbf{x}, t$ ，因而采用后验分布对各个条件速度进行加权平均。

边缘路径的连续性方程。 从式 (1.8) 出发：

$$\begin{aligned} \partial_t p_t(\mathbf{x}) &= \partial_t \int p_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}) d\mathbf{z} \\ &= \int \partial_t p_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}) d\mathbf{z}. \end{aligned}$$

代入 conditional continuity equation (1.7)：

$$\begin{aligned} \partial_t p_t(\mathbf{x}) &= - \int \nabla \cdot [p_t(\mathbf{x} \mid \mathbf{z})\mathbf{u}_t(\mathbf{x} \mid \mathbf{z})]p_{\text{data}}(\mathbf{z}) d\mathbf{z} \\ &= - \nabla \cdot \left[\int p_t(\mathbf{x} \mid \mathbf{z})\mathbf{u}_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}) d\mathbf{z} \right]. \end{aligned}$$

利用式 (1.12):

$$\partial_t p_t(\mathbf{x}) = -\nabla \cdot [p_t(\mathbf{x}) \mathbf{u}_t(\mathbf{x})].$$

因此, 对条件运输进行边缘化后, 得到的边缘概率路径与边缘向量场仍满足同一概率守恒方程。

数学基础提示: 积分号下求导、线性算子与积分交换, 详见附录 A.2。

训练时可获得的监督信号。 生成阶段需要的是边缘向量场

$$\mathbf{u}_t(\mathbf{x}),$$

因为采样时网络只接收当前 $(\mathbf{x}, t)$ 。但式 (1.11) 包含后验分布以及对所有 $\mathbf{z}$ 的积分, 通常无法逐样本直接计算。

训练阶段可以从数据集中得到 $\mathbf{z}$, 并采样噪声 ϵ 与时间 t , 因此条件速度

$$\mathbf{u}_t(\mathbf{x} \mid \mathbf{z})$$

可以直接构造。由此得到训练中的基本设置: 目标是边缘向量场, 而可直接提供的监督量是条件向量场。第二章将说明以条件速度为标签的平方误差为何与边缘 Flow Matching 的目标具有相同的最优解。

训练流匹配

2.1 从 Marginal Flow Matching Loss 到 Conditional Flow Matching Loss

第一章得到的生成目标是边缘向量场 $\mathbf{u}_t(\mathbf{x})$ 。若它可以直接计算，一个自然的训练目标是

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{\substack{t \sim \text{Unif}[0,1] \\ \mathbf{x} \sim p_t}} \left[\|\mathbf{u}_t^\theta(\mathbf{x}) - \mathbf{u}_t(\mathbf{x})\|^2 \right]. \quad (2.1)$$

式 (2.1) 记为 Marginal Flow Matching loss。

Marginal loss 的含义。 在模型容量和优化条件允许的情况下，若

$$\mathbf{u}_t^\theta(\mathbf{x}) \approx \mathbf{u}_t(\mathbf{x}),$$

则采样时运行

$$\frac{dX_t}{dt} = \mathbf{u}_t^\theta(X_t)$$

就近似使用生成目标概率路径所对应的边缘向量场。结合连续性方程，速度场的逼近误差会体现在相应的分布演化上。

直接监督边缘向量场的困难。 由

$$\mathbf{u}_t(\mathbf{x}) = \int \mathbf{u}_t(\mathbf{x} | \mathbf{z}) p(\mathbf{z} | \mathbf{x}, t) d\mathbf{z}$$

可知，计算边缘速度需要后验分布 $p(\mathbf{z} | \mathbf{x}, t)$ 以及对 $\mathbf{z}$ 的积分；真实数据分布本身也通常只通过有限数据集给出。因此 $\mathbf{u}_t(\mathbf{x})$ 很难直接作为逐样本监督标签。

条件目标可以由一次随机采样直接得到：

$$\mathbf{z} \sim p_{\text{data}}, \quad t \sim \text{Unif}[0, 1], \quad \epsilon \sim \mathcal{N}(0, \mathbf{I}_d),$$

然后构造

$$\mathbf{x}_t = \alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}$$

以及

$$\mathbf{v}_t = \dot{\alpha}_t \mathbf{z} + \dot{\beta}_t \boldsymbol{\epsilon}.$$

这里 $\mathbf{v}_t$ 是当前条件构造对应的目标速度。

据此定义 Conditional Flow Matching loss:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, \mathbf{z}, \mathbf{x}} \left[\|\mathbf{u}_t^\theta(\mathbf{x}) - \mathbf{u}_t(\mathbf{x} | \mathbf{z})\|^2 \right], \quad (2.2)$$

其中

$$t \sim \text{Unif}[0, 1], \quad \mathbf{z} \sim p_{\text{data}}, \quad \mathbf{x} \sim p_t(\cdot | \mathbf{z}).$$

对 Gaussian path, 式 (2.2) 可进一步写成直接采样的形式:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, \mathbf{z}, \boldsymbol{\epsilon}} \left[\left\| \mathbf{u}_t^\theta(\alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}) - (\dot{\alpha}_t \mathbf{z} + \dot{\beta}_t \boldsymbol{\epsilon}) \right\|^2 \right].$$

数学基础提示: 期望、多变量联合密度、Unif[0, 1] 与 Monte Carlo, 详见附录 A.1。

接下来需要证明, 虽然 CFM 的逐样本目标是 $\mathbf{u}_t(\mathbf{x} | \mathbf{z})$, 优化式 (2.2) 与优化边缘目标 (2.1) 对模型参数产生相同的作用。

2.2 为什么 Conditional Flow Matching 能学到 Marginal Flow

下面先直接展开两个 loss, 比较它们对模型参数的依赖; 随后用条件均值给出回归视角的解释。

Loss 的直接展开。 对向量 $\mathbf{a}, \mathbf{b}$, 平方范数满足

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 - 2\mathbf{a}^\top \mathbf{b} + \|\mathbf{b}\|^2.$$

因此

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t, \mathbf{z}, \mathbf{x}} \left[\|\mathbf{u}_t^\theta(\mathbf{x})\|^2 - 2\mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x} | \mathbf{z}) + \|\mathbf{u}_t(\mathbf{x} | \mathbf{z})\|^2 \right].$$

数学基础提示：向量内积、转置与平方范数展开，详见附录 A.3。

第一项：对 z 做边缘化。 固定 t ，有

$$\begin{aligned} & \mathbb{E}_{z,x} \|\mathbf{u}_t^\theta(\mathbf{x})\|^2 \\ &= \int \int \|\mathbf{u}_t^\theta(\mathbf{x})\|^2 p_t(\mathbf{x} | z) p_{\text{data}}(z) \, d\mathbf{x} \, dz. \end{aligned}$$

由于 $\mathbf{u}_t^\theta(\mathbf{x})$ 不依赖 z ，交换积分顺序后，可将其移到关于 z 的积分之外：

$$\begin{aligned} &= \int \|\mathbf{u}_t^\theta(\mathbf{x})\|^2 \left[\int p_t(\mathbf{x} | z) p_{\text{data}}(z) \, dz \right] d\mathbf{x} \\ &= \int \|\mathbf{u}_t^\theta(\mathbf{x})\|^2 p_t(\mathbf{x}) \, d\mathbf{x}. \end{aligned}$$

所以

$$\mathbb{E}_{t,z,x} \|\mathbf{u}_t^\theta(\mathbf{x})\|^2 = \mathbb{E}_{t,x \sim p_t} \|\mathbf{u}_t^\theta(\mathbf{x})\|^2. \quad (2.3)$$

数学基础提示：多重积分、Fubini 定理与 marginalization，详见附录 A.2。

第二项：由条件速度得到边缘速度。 固定 t ，考虑

$$B_t = \int \int \mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x} | z) p_t(\mathbf{x} | z) p_{\text{data}}(z) \, dz \, d\mathbf{x}.$$

由于 $\mathbf{u}_t^\theta(\mathbf{x})$ 不依赖 z ：

$$B_t = \int \mathbf{u}_t^\theta(\mathbf{x})^\top \left[\int \mathbf{u}_t(\mathbf{x} | z) p_t(\mathbf{x} | z) p_{\text{data}}(z) \, dz \right] d\mathbf{x}.$$

由式 (1.12)，

$$\int \mathbf{u}_t(\mathbf{x} | z) p_t(\mathbf{x} | z) p_{\text{data}}(z) \, dz = p_t(\mathbf{x}) \mathbf{u}_t(\mathbf{x}).$$

因此

$$B_t = \int \mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x}) \, d\mathbf{x},$$

即

$$\mathbb{E}_{t,z,x} [\mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x} | z)] = \mathbb{E}_{t,x} [\mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x})]. \quad (2.4)$$

第三项：与模型参数无关的项。 定义

$$C_{\text{cond}} = \mathbb{E}_{t,z,x} \|\mathbf{u}_t(\mathbf{x} \mid \mathbf{z})\|^2.$$

该项不含参数 θ 。结合式 (2.3) 和 (2.4)，CFM loss 可写为

$$\mathcal{L}_{\text{CFM}}(\theta) = A_\theta - 2B_\theta + C_{\text{cond}},$$

其中

$$\begin{aligned} A_\theta &= \mathbb{E}_{t,x} \|\mathbf{u}_t^\theta(\mathbf{x})\|^2, \\ B_\theta &= \mathbb{E}_{t,x} [\mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x})]. \end{aligned}$$

Marginal loss 展开后为

$$\begin{aligned} \mathcal{L}_{\text{FM}}(\theta) &= \mathbb{E}_{t,x} \left[\|\mathbf{u}_t^\theta(\mathbf{x})\|^2 - 2\mathbf{u}_t^\theta(\mathbf{x})^\top \mathbf{u}_t(\mathbf{x}) + \|\mathbf{u}_t(\mathbf{x})\|^2 \right] \\ &= A_\theta - 2B_\theta + C_{\text{marg}}, \end{aligned}$$

其中

$$C_{\text{marg}} = \mathbb{E}_{t,x} \|\mathbf{u}_t(\mathbf{x})\|^2$$

同样与 θ 无关。于是

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathcal{L}_{\text{FM}}(\theta) + C,$$

其中

$$C = C_{\text{cond}} - C_{\text{marg}}$$

与模型参数无关。

所以

$$\arg \min_{\theta} \mathcal{L}_{\text{CFM}}(\theta) = \arg \min_{\theta} \mathcal{L}_{\text{FM}}(\theta),$$

并且

$$\nabla_{\theta} \mathcal{L}_{\text{CFM}} = \nabla_{\theta} \mathcal{L}_{\text{FM}}.$$

因此，两种 loss 关于 θ 的梯度相同，并具有相同的最优参数集合。

条件均值视角。 固定网络输入 $(\mathbf{x}, t)$ 后, 网络输出一个确定向量 $\mathbf{a}$, 而目标

$$\mathbf{u}_t(\mathbf{x} \mid Z)$$

仍随未观测的终点 Z 变化。考虑条件 MSE:

$$\mathbb{E} [\|\mathbf{a} - \mathbf{u}_t(\mathbf{x} \mid Z)\|^2 \mid X_t = \mathbf{x}, t].$$

平方误差在该条件下的最优解为条件均值:

$$\mathbf{a}^* = \mathbb{E}[\mathbf{u}_t(\mathbf{x} \mid Z) \mid X_t = \mathbf{x}, t].$$

根据式 (1.10),

$$\mathbf{u}_t(\mathbf{x}) = \mathbb{E}[\mathbf{u}_t(\mathbf{x} \mid Z) \mid X_t = \mathbf{x}, t].$$

所以

$$\mathbf{a}^* = \mathbf{u}_t(\mathbf{x}).$$

数学基础提示: 条件期望与 MSE 最优预测器的完整证明, 详见附录 A.1。

前面的代数展开比较了两个总体目标对 θ 的依赖; 条件均值视角则说明, 在固定 $(\mathbf{x}, t)$ 时, 平方误差会把可能出现的条件速度按 $p(\mathbf{z} \mid \mathbf{x}, t)$ 做平均。两种表述对应同一训练结果。

2.3 Straight-Line Flow Matching: 从理论到训练与生成

前面的推导允许多种 α_t, β_t 。取最简单的线性 schedule:

$$\alpha_t = t, \quad \beta_t = 1 - t.$$

代入 conditional path:

$$\mathbf{x}_t = t\mathbf{z} + (1 - t)\boldsymbol{\epsilon}.$$

也可以写成

$$\mathbf{x}_t = \boldsymbol{\epsilon} + t(\mathbf{z} - \boldsymbol{\epsilon}),$$

对固定的 (z, ϵ) ，该式给出从噪声 ϵ 到数据点 z 的直线插值。

对时间求导：

$$v_t = \frac{dx_t}{dt} = z - \epsilon.$$

因此 straight-line CFM 的训练目标为

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, z, \epsilon} \left[\left\| u_t^\theta(tz + (1-t)\epsilon) - (z - \epsilon) \right\|^2 \right]. \quad (2.5)$$

在这一参数化下，网络输入是噪声与数据之间的中间点，监督目标为从噪声指向数据的差向量。

训练样本的构造。 式 (2.5) 在程序中对以下随机采样过程：

1. 从数据集中采样 $z \sim p_{\text{data}}$ ；
2. 采样 $\epsilon \sim \mathcal{N}(0, I_d)$ ；
3. 采样 $t \sim \text{Unif}[0, 1]$ ；
4. 构造 $x_t = tz + (1-t)\epsilon$ ；
5. 构造 target $v_t = z - \epsilon$ ；
6. 网络预测 $u_t^\theta(x_t)$ ；
7. 最小化 $\|u_t^\theta(x_t) - v_t\|^2$ 。

```

1  for \vect{z} in dataloader:
2      eps = randn_like(\vect{z})
3      t = rand_uniform(batch_size, 1)
4
5      \vect{x}_t = t * \vect{z} + (1 - t) * eps
6      target = \vect{z} - eps
7
8      pred = model(\vect{x}_t, t)
9      loss = mean_squared_error(pred, target)
10
11     optimizer.zero_grad()
12     loss.backward()
13     optimizer.step()

```

训练时用 mini-batch Monte Carlo 平均近似理论期望：

$$\mathcal{L}_{\text{batch}} = \frac{1}{B} \sum_{i=1}^B \|\mathbf{u}_{t_i}^{\theta}(\mathbf{x}_{t_i}) - \mathbf{v}_{t_i}\|^2.$$

数学基础提示：Unif[0, 1]、期望与 mini-batch Monte Carlo 近似，详见附录 A.1。

生成阶段。 采样时不再使用真实数据点 $\mathbf{z}$ 。先抽取初始噪声

$$X_0 \sim p_{\text{init}},$$

然后解神经网络 ODE

$$\frac{dX_t}{dt} = \mathbf{u}_t^{\theta}(X_t), \quad t : 0 \rightarrow 1.$$

最简单的 Euler 离散化为

$$X_{k+1} = X_k + h \mathbf{u}_{t_k}^{\theta}(X_k), \quad h = \frac{1}{N}.$$

若网络学到目标边缘向量场，即

$$\mathbf{u}_t^{\theta}(\mathbf{x}) = \mathbf{u}_t(\mathbf{x}),$$

并从相同初始分布 $p_0 = p_{\text{init}}$ 出发，则模型分布与目标概率路径满足相同的连续性方程和相同初值。在相应方程具有所需存在唯一性的条件下，两者的分布演化一致，因此

$$X_1 \sim p_{\text{data}}.$$

整体关系。

$$\begin{aligned} p_{\text{init}} &\longrightarrow p_t(\mathbf{x} \mid \mathbf{z}) \longrightarrow \mathbf{u}_t(\mathbf{x} \mid \mathbf{z}) \\ &\longrightarrow p_t(\mathbf{x}) \longrightarrow \mathbf{u}_t(\mathbf{x}) \\ &\longrightarrow \mathcal{L}_{\text{CFM}} \longrightarrow \mathbf{u}_t^\theta \longrightarrow p_{\text{data}}. \end{aligned}$$

第一章给出了条件流及其对应的边缘流，第二章说明条件监督与边缘 Flow Matching 目标之间的关系，并把一般构造化为 straight-line 训练与 ODE 采样。

流匹配推导所需的数学基础

本附录只整理正文推导所使用的数学工具，不试图覆盖完整的概率论、微积分或向量分析。熟悉这些内容的读者可以直接查阅所需条目。

A.1 概率论基础

正文用途：主要用于正文 1.2–1.3 的 conditional/marginal 构造，以及 2.1–2.2 的期望、Bayes、条件期望和 MSE 推导。

随机变量、取值与概率密度。 随机变量通常用大写字母表示，例如 X ；某一次具体取值用小写 x 表示。写

$$X \sim p$$

表示 X 服从分布 p 。若存在密度，写为 $p(x)$ 。

对于连续随机变量，单个点的概率通常为零，区间概率为

$$\Pr(a < X < b) = \int_a^b p(x) \, dx.$$

小区间 $[x, x + \Delta x]$ 上的概率近似为

$$p(x)\Delta x.$$

期望。 离散情形中

$$\mathbb{E}[f(X)] = \sum_x f(x) \Pr(X = x),$$

连续情形中

$$\mathbb{E}[f(X)] = \int f(x)p(x) \, dx.$$

两种形式都表示按概率进行加权平均。

若有多个随机变量，使用联合密度：

$$\mathbb{E}[f(X, Z)] = \int \int f(x, z) p(x, z) \, dx \, dz.$$

在 CFM 中，

$$\mathbb{E}_{t,z,x}[F(t, z, x)]$$

对应对 t, z, x 按其联合分布取期望，也可写成相应的多重积分。

联合分布与条件分布。 条件密度满足

$$p(x \mid z) = \frac{p(x, z)}{p(z)},$$

因此

$$p(x, z) = p(x \mid z)p(z).$$

Flow Matching 中

$$p_t(\mathbf{x}, \mathbf{z}) = p_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}).$$

记号 $p_t(\cdot \mid \mathbf{z})$ 中的 “ $\cdot$ ” 是占位符，表示固定 $\mathbf{z}$ 后关于第一个变量的整个分布。

Marginalization。 若只保留 X ，对 Z 积分得到：

$$p(x) = \int p(x, z) \, dz.$$

结合联合分解式：

$$p(x) = \int p(x \mid z)p(z) \, dz.$$

因此正文中的 marginal probability path 为

$$p_t(\mathbf{x}) = \int p_t(\mathbf{x} \mid \mathbf{z})p_{\text{data}}(\mathbf{z}) \, d\mathbf{z}.$$

Bayes、prior 与 posterior。 同一个联合分布也可以写成

$$p(x, z) = p(x \mid z)p(z) = p(z \mid x)p(x).$$

所以

$$p(z | x) = \frac{p(x | z)p(z)}{p(x)}.$$

Flow Matching 中:

$$p(\mathbf{z} | \mathbf{x}, t) = \frac{p_t(\mathbf{x} | \mathbf{z})p_{\text{data}}(\mathbf{z})}{p_t(\mathbf{x})}.$$

其中 $p(\mathbf{z})$ 是观察 $\mathbf{x}$ 之前的先验, $p(\mathbf{z} | \mathbf{x}, t)$ 是给定当前状态后的后验。

条件期望。 给定 $X = x$ 后, 随机变量 Y 的条件期望写成

$$\mathbb{E}[Y | X = x] = \int y p(y | x) dy.$$

在 Flow Matching 中

$$\mathbb{E}[\mathbf{u}_t(\mathbf{x} | Z) | X_t = \mathbf{x}, t] = \int \mathbf{u}_t(\mathbf{x} | \mathbf{z})p(\mathbf{z} | \mathbf{x}, t) d\mathbf{z},$$

因此边缘向量场可写成条件向量场关于后验分布的条件均值。

MSE 的最优预测器。 令

$$m(X) = \mathbb{E}[Y | X].$$

对任意预测器 $f(X)$,

$$\begin{aligned} \|f - Y\|^2 &= \|f - m + m - Y\|^2 \\ &= \|f - m\|^2 + \|m - Y\|^2 + 2(f - m)^\top(m - Y). \end{aligned}$$

对给定 X 取条件期望, 最后一项消失, 因为

$$\mathbb{E}[m - Y | X] = 0.$$

因此

$$\mathbb{E}[\|f - Y\|^2 | X] = \|f - m\|^2 + \mathbb{E}[\|m - Y\|^2 | X].$$

第二项与 f 无关, 所以最优解为

$$f^*(X) = \mathbb{E}[Y | X].$$

Unif[0, 1] 与 Monte Carlo。若

$$T \sim \text{Unif}[0, 1],$$

则 $0 \leq t \leq 1$ 上概率密度为 1, 所以

$$\mathbb{E}_T[f(T)] = \int_0^1 f(t) dt.$$

这里仅有

$$\int_0^1 p(t) dt = 1,$$

一般的 $\mathbb{E}[f(T)]$ 没有这一限制。

理论期望可由随机样本平均近似:

$$\mathbb{E}[\ell(Y)] \approx \frac{1}{B} \sum_{i=1}^B \ell(Y_i),$$

mini-batch loss 正是这种样本平均的实际形式。

A.2 微积分基础

正文用途: 主要用于正文的 conditional velocity 推导、连续性方程、积分号下求导以及 CFM loss 多重积分交换。

普通导数与偏导数。 若 $y = f(t)$ 只有一个自变量, 普通导数

$$\frac{dy}{dt}$$

表示 t 改变时的瞬时变化率。

概率密度通常是多变量函数 $p(t, x)$ 。固定 x 只观察时间变化, 写

$$\frac{\partial p}{\partial t};$$

固定 t 只观察空间变化, 写 $\partial p / \partial x$ 。

链式法则。 若 $y = f(x)$ 且 $x = g(t)$, 则

$$\frac{dy}{dt} = \frac{dy}{dx} \frac{dx}{dt}.$$

对于 $p(t, x(t))$:

$$\frac{d}{dt}p(t, x(t)) = \frac{\partial p}{\partial t} + \frac{\partial p}{\partial x} \frac{dx}{dt}.$$

高维时第二项写成

$$\nabla p(\mathbf{x})^\top \dot{\mathbf{x}}.$$

乘积法则与 log 求导。

$$\frac{d}{dx}[f(x)g(x)] = f'(x)g(x) + f(x)g'(x).$$

如果 $f(x) > 0$, 则

$$\frac{d}{dx} \log f(x) = \frac{f'(x)}{f(x)}.$$

所以

$$\partial_t p = p \partial_t \log p.$$

多重积分与 Fubini 定理。 多重积分可以看作多重求和的连续形式。在绝对可积等条件成立时, 积分顺序可以交换:

$$\int \left[\int f(x, z) dx \right] dz = \int \left[\int f(x, z) dz \right] dx.$$

CFM 等价性证明中利用这一规则, 把关于 z 的项放到同一个积分内, 从而识别出边缘化项或边缘向量场。

积分号下求导: Leibniz rule。 当积分区域固定, 并满足适当光滑和可积条件时,

$$\frac{d}{dt} \int_a^b p(t, x) dx = \int_a^b \frac{\partial p(t, x)}{\partial t} dx.$$

若积分上下限也依赖 t , 还会出现边界项。连续性方程使用固定控制区域时边界不随时间移动, 因此这里没有这些附加项。

分部积分。 一维中

$$\int_a^b f'(x)g(x) \, dx = [f(x)g(x)]_a^b - \int_a^b f(x)g'(x) \, dx.$$

在高维弱形式中，相应的操作通常借助散度定理完成，用于在积分中转移导数。

A.3 向量微积分与连续性方程

正文用途：主要用于正文的向量 MSE 展开、divergence、概率流以及连续性方程的高维表达。

向量、转置、内积与平方范数。 对 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^d$:

$$\mathbf{a}^\top \mathbf{b} = \sum_{i=1}^d a_i b_i, \quad \|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

因此

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 - 2\mathbf{a}^\top \mathbf{b} + \|\mathbf{b}\|^2.$$

CFM loss 的平方范数展开因此会出现内积 $\mathbf{a}^\top \mathbf{b}$ 。

Gradient 与 Jacobian。 对于标量函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$,

$$\nabla f = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_d \end{bmatrix}.$$

对于向量场 $\mathbf{u} = (u_1, \dots, u_d)$, Jacobian 为

$$\mathbf{J}_\mathbf{u}(\mathbf{x}) = \left[\frac{\partial u_i}{\partial x_j} \right]_{i,j=1}^d.$$

Divergence。 Divergence 是 Jacobian 的迹:

$$\nabla \cdot \mathbf{u} = \text{tr}(\mathbf{J}_\mathbf{u}) = \sum_{i=1}^d \frac{\partial u_i}{\partial x_i}.$$

二维时

$$\nabla \cdot \mathbf{u} = \frac{\partial u_1}{\partial x_1} + \frac{\partial u_2}{\partial x_2}.$$

正值对应局部体积的扩张趋势，负值对应收缩趋势；一维时散度退化为 $\partial u / \partial x$ 。

对于标量 p 与向量场 $\mathbf{u}$ ，有

$$\nabla \cdot (p\mathbf{u}) = \nabla p^\top \mathbf{u} + p \nabla \cdot \mathbf{u}.$$

连续性方程的严格积分形式。 设 $\Omega \subset \mathbb{R}^d$ 为固定区域，边界为 $\partial\Omega$ ，外法向量为 $\mathbf{n}$ 。定义概率流

$$\mathbf{J}_t(\mathbf{x}) = p_t(\mathbf{x})\mathbf{u}_t(\mathbf{x}).$$

区域内总概率为

$$M_\Omega(t) = \int_\Omega p_t(\mathbf{x}) \, d\mathbf{x}.$$

固定区域上的概率守恒写为

$$\frac{d}{dt} \int_\Omega p_t(\mathbf{x}) \, d\mathbf{x} = - \int_{\partial\Omega} \mathbf{J}_t(\mathbf{x}) \cdot \mathbf{n} \, dS.$$

散度定理给出

$$\int_{\partial\Omega} \mathbf{J} \cdot \mathbf{n} \, dS = \int_\Omega \nabla \cdot \mathbf{J} \, d\mathbf{x}.$$

固定区域上把时间导数移入积分，得到

$$\int_\Omega [\partial_t p_t + \nabla \cdot (p_t \mathbf{u}_t)] \, d\mathbf{x} = 0.$$

若该关系对任意合适的 Ω 都成立，则得到局部 PDE：

$$\partial_t p_t(\mathbf{x}) + \nabla \cdot [p_t(\mathbf{x})\mathbf{u}_t(\mathbf{x})] = 0.$$

沿粒子轨迹观察密度。 展开连续性方程：

$$\partial_t p + \nabla p^\top \mathbf{u} = -p \nabla \cdot \mathbf{u}.$$

如果粒子满足 $\dot{X}_t = \mathbf{u}_t(X_t)$ ，链式法则给出

$$\frac{d}{dt} p_t(X_t) = -p_t(X_t) \nabla \cdot \mathbf{u}_t(X_t).$$

除以 $p_t(X_t)$:

$$\frac{d}{dt} \log p_t(X_t) = -\nabla \cdot \mathbf{u}_t(X_t).$$

该式把沿轨迹的密度变化与向量场的局部散度联系起来：正散度对应密度下降，负散度对应密度上升。

A.4 Gaussian 基础

正文用途：主要用于正文 1.2 的 Gaussian conditional path、reparameterization、conditional vector field 与连续性方程验证。

多元 Gaussian。 标准多元 Gaussian 记为

$$\epsilon \sim \mathcal{N}(0, \mathbf{I}_d).$$

若

$$X \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_d),$$

其密度为

$$p(\mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{\|\mathbf{x} - \boldsymbol{\mu}\|^2}{2\sigma^2}\right).$$

参数 $\boldsymbol{\mu}$ 是均值， σ 是各向同性标准差。

仿射变换与重参数化。 若

$$\epsilon \sim \mathcal{N}(0, \mathbf{I}_d),$$

则

$$X = \boldsymbol{\mu} + \sigma \epsilon$$

满足

$$X \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_d).$$

因此在取

$$p_t(\cdot \mid \mathbf{z}) = \mathcal{N}(\alpha_t \mathbf{z}, \beta_t^2 \mathbf{I}_d)$$

时, 可用下面的重参数化形式采样:

$$X_t = \alpha_t \mathbf{z} + \beta_t \epsilon.$$

Gaussian log-density. 以下密度、log-density 与导数公式均在 $\beta_t > 0$ 的时刻成立。对

$$p_t(\mathbf{x} \mid \mathbf{z}) = \frac{1}{(2\pi\beta_t^2)^{d/2}} \exp\left(-\frac{\|\mathbf{x} - \alpha_t \mathbf{z}\|^2}{2\beta_t^2}\right),$$

取对数:

$$\log p_t(\mathbf{x} \mid \mathbf{z}) = C - d \log \beta_t - \frac{\|\mathbf{x} - \alpha_t \mathbf{z}\|^2}{2\beta_t^2}.$$

因此

$$\nabla_{\mathbf{x}} \log p_t(\mathbf{x} \mid \mathbf{z}) = -\frac{\mathbf{x} - \alpha_t \mathbf{z}}{\beta_t^2},$$

以及

$$\nabla_{\mathbf{x}} p_t(\mathbf{x} \mid \mathbf{z}) = -\frac{\mathbf{x} - \alpha_t \mathbf{z}}{\beta_t^2} p_t(\mathbf{x} \mid \mathbf{z}).$$

Gaussian 条件路径的连续性方程验证. 以下直接验证同样取 $\beta_t > 0$ 。令

$$\mathbf{y} = \mathbf{x} - \alpha_t \mathbf{z}.$$

由 log-density 对时间求导可得

$$\partial_t p_t = p_t \left[-d \frac{\dot{\beta}_t}{\beta_t} + \frac{\dot{\alpha}_t \mathbf{z}^\top \mathbf{y}}{\beta_t^2} + \frac{\dot{\beta}_t \|\mathbf{y}\|^2}{\beta_t^3} \right]. \quad (\text{A.1})$$

条件向量场还可写成

$$\mathbf{u}_t(\mathbf{x} \mid \mathbf{z}) = \dot{\alpha}_t \mathbf{z} + \frac{\dot{\beta}_t}{\beta_t} \mathbf{y}.$$

它的 divergence 为

$$\nabla \cdot \mathbf{u}_t = d \frac{\dot{\beta}_t}{\beta_t}.$$

利用

$$\nabla \cdot (p_t \mathbf{u}_t) = \nabla p_t^\top \mathbf{u}_t + p_t \nabla \cdot \mathbf{u}_t,$$

以及

$$\nabla p_t = -\frac{\mathbf{y}}{\beta_t^2} p_t,$$

得到

$$-\nabla \cdot (p_t \mathbf{u}_t) = p_t \left[-d \frac{\dot{\beta}_t}{\beta_t} + \frac{\dot{\alpha}_t \mathbf{z}^\top \mathbf{y}}{\beta_t^2} + \frac{\dot{\beta}_t \|\mathbf{y}\|^2}{\beta_t^3} \right],$$

该结果与式 (A.1) 相同，因此

$$\partial_t p_t(\mathbf{x} \mid \mathbf{z}) = -\nabla \cdot [p_t(\mathbf{x} \mid \mathbf{z}) \mathbf{u}_t(\mathbf{x} \mid \mathbf{z})].$$

端点 $\beta_t \rightarrow 0$ 。当 $\beta_t \rightarrow 0$ 且 $\alpha_t \rightarrow 1$ 时， $\mathcal{N}(\alpha_t \mathbf{z}, \beta_t^2 \mathbf{I}_d)$ 的概率质量集中到 $\mathbf{z}$ 。此时的极限不是非退化 Gaussian，而是点质量 $\delta_{\mathbf{z}}$ ；正文中“ $t = 1$ 时收缩到数据点 $\mathbf{z}$ ”均按这一极限理解。