Agent Memory 论文精读：从 RAG 到情景推理

十二篇代表性论文的核心方法与实验设置

作者：Yang kunpeng

原论文及官方开源代码来源

原论文： Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks 链接

原论文： MemGPT: Towards LLMs as Operating Systems 链接

原论文： From Local to Global: A Graph RAG Approach to Query-Focused Summarization 链接

原论文： Zep: A Temporal Knowledge Graph Architecture for Agent Memory 链接

原论文： A-MEM: Agentic Memory for LLM Agents 链接

原论文： From RAG to Memory: Non-Parametric Continual Learning for Large Language Models 链接

原论文： Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory 链接

原论文： MemOS: An Operating System for Memory-Augmented Generation (MAG) in Large Language Models 链接

原论文： MIRIX: Multi-Agent Memory System for LLM-Based Agents 链接

原论文： LightMem: Lightweight and Efficient Memory-Augmented Generation 链接

原论文： MemRL: Self-Evolving Agents via Runtime Reinforcement Learning on Episodic Memory 链接

原论文： REMem: Reasoning with Episodic Memory in Language Agent 链接

开源代码： MemGPT 官方仓库 链接

开源代码： GraphRAG 官方仓库 链接

开源代码： Zep 官方仓库 链接

开源代码： A-MEM 官方仓库 链接

开源代码： Mem0 官方仓库 链接

开源代码： MIRIX 官方仓库 链接

开源代码： MemRL 官方仓库 链接

开源代码： REMem 官方仓库 链接

目录

第一章 RAG 检索生成 **1**
1.1 双重记忆与检索入口 1
1.2 序列级与符号级边缘化 2
1.3 训练与解码的差异 2
1.4 实验设置 3

第二章 MemGPT 虚拟上下文 **5**
2.1 有限窗口的多级存储 5
2.2 自管理函数与控制循环 6
2.3 写入、召回与版本边界 6
2.4 实验设置 7

第三章 GraphRAG 图谱检索 **9**
3.1 从文档到群落摘要 9
3.2 从局部证据到全局回答 9
3.3 构建成本与查询适配 10
3.4 实验设置 10

第四章 Zep 时序图谱 **12**
4.1 情节、实体与群落 12
4.2 时间有效性与事实失效 12
4.3 混合检索和答案上下文 13
4.4 实验设置 13

第五章 A-MEM 动态链接 **15**
5.1 记忆卡片的结构 15
5.2 近邻召回与链接生成 16
5.3 旧记忆演化与最终检索 16
5.4 实验设置 17

第六章 HippoRAG 2 联想检索 **18**
6.1 概念与段落联合索引 18
6.2 查询对齐与识别记忆 18
6.3 传播评分与证据选择 19
6.4 实验设置 20

第七章 Mem0 记忆更新 **21**
7.1 候选事实的提取 21
7.2 四种更新决策 22
7.3 图记忆扩展 22
7.4 实验设置 23

第八章 MemOS 记忆资源 **24**
8.1 三类异构记忆 24
8.2 MemCube 封装 24
8.3 调度与生命周期 24

第九章 MIRIX 多类记忆 **26**
9.1 六种记忆组件 26
9.2 主动检索与写入路由 26
9.3 时间事件与资源连续性 27
9.4 实验设置 27

第十章 LightMem 轻量记忆 **29**
10.1 感知过滤与主题切分 29
10.2 短期聚合与长期索引 30
10.3 延后更新与时间约束 30
10.4 实验设置 31

第十一章 MemRL 效用学习 **32**
11.1 意图、经验与效用 32
11.2 两阶段经验检索 33
11.3 环境奖励更新记忆 33
11.4 实验设置 34

第十二章 REMem 情景推理 **35**

12.1 情节摘要与带时事实 35
12.2 检索与图探索的循环 36
12.3 情节重忆与跨事件推理 36
12.4 实验设置 37

第 1 章

RAG 检索生成

1.1 双重记忆与检索入口

RAG 将预训练生成模型的参数知识与外部文档索引结合。在知识密集型任务中，参数中已编码的信息不易逐条更新或定位来源；文档索引提供可以替换的非参数知识。设输入问题为 x，待生成的符号序列为 $y = (y_1, \ldots, y_N)$，检索得到的文档为 z。检索器 $p_\eta(z \mid x)$ 给出文档的条件概率，生成器 $p_\theta(y_i \mid x, z, y_{<i})$ 根据问题、文档与已生成前缀预测第 i 个符号，其中 η、θ 分别是两组件的可训练参数。

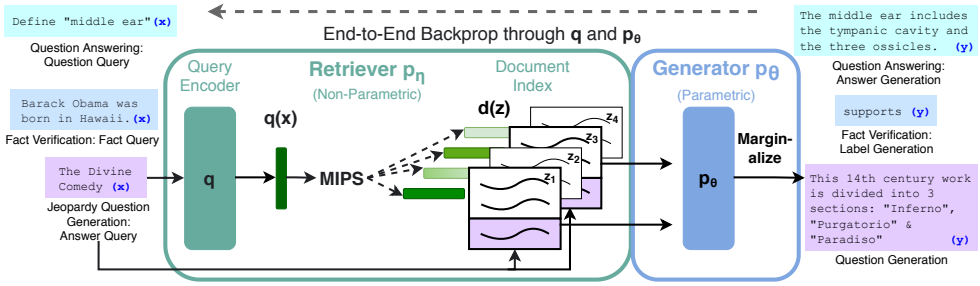


图 1.1: 问题编码、文档检索与条件生成的连接关系。原论文架构图，来源：[1]。

图 1.1 中，问题编码器与文档编码器构成 DPR 双塔检索器，文档编码器将语料预先转换为向量索引；问题编码器计算查询向量并以最大内积搜索选出前 K 个文档。令 $\boldsymbol{q}(x)$ 与 $\boldsymbol{d}(z)$ 为同维向量，其未归一化匹配分数为

$$s_\eta(x, z) = \boldsymbol{q}(x)^{\top} \boldsymbol{d}(z), \qquad p_\eta(z \mid x) \propto \exp s_\eta(x, z). \tag{1.1}$$

归一化概率在检索候选集合上计算；实际训练将全语料文档分布截断为前 K 项。生成器采用 BART，并把问题与选中文档串接为编码器输入。文档检索为生成提供证据，但对候选集以外的文档不进行精确求和。

1.2 序列级与符号级边缘化

RAG 的关键不是把检索文本直接拼到提示词，而是把证据文档 z 视为潜变量，用目标序列的概率训练检索器与生成器。设 $\mathcal{Z}_K(x)$ 为问题 x 的前 K 个候选文档。RAG-Sequence 在整段回答中使用同一个潜在文档，其近似概率为

$$p_{\text{seq}}(y \mid x) \approx \sum_{z \in \mathcal{Z}_K(x)} p_\eta(z \mid x) \prod_{i=1}^{N} p_\theta(y_i \mid x, z, y_{<i}). \tag{1.2}$$

这里必须先对每个文档计算整段回答的概率，再沿文档求和；否则会改变“整段回答共用一个文档”的假设。

RAG-Token 允许每个预测位置从不同文档吸收证据，改为先对每个位置的文档求和，再沿位置相乘：

$$p_{\text{tok}}(y \mid x) \approx \prod_{i=1}^{N} \left[\sum_{z \in \mathcal{Z}_K(x)} p_\eta(z \mid x) p_\theta(y_i \mid x, z, y_{<i}) \right]. \tag{1.3}$$

两个式子的求和与连乘通常不能交换。以两文档、两符号为例，式 (1.2)只统计“两个符号都依赖文档一”或“都依赖文档二”的分支；式 (1.3)还包含“第一个符号依赖文档一、第二个符号依赖文档二”的交叉分支。若回答只含一个符号，二者形式相同。这正是两种机制使用证据粒度不同的数学原因。

1.3 训练与解码的差异

给定训练样本 $\{(x_j, y_j)\}_{j=1}^{M}$，最大化边缘化后的答案概率，等价于最小化

$$\mathcal{L}(\theta, \eta) = -\sum_{j=1}^{M} \log p(y_j \mid x_j), \tag{1.4}$$

其中 p 取式 (1.2) 或式 (1.3) 的近似定义。训练不需要每个问题对应哪篇文档的显式标签；检索器受到生成目标的间接监督。原论文固定文档编码器和索引，只微调查询编码器与生成器，因此“端到端训练”并不意味着索引中的全部文档表示都会参与反向传播。

RAG-Token 可以把文档边缘化后的下一符号分布直接交给自回归束搜索。RAG-Sequence 的整段概率不能分解为单一的逐符号转移概率，原论文分别按候选文档执

行束搜索，再对候选回答跨文档重新计分；其快速解码近似省略了没有出现在相应文档束中的候选概率。训练公式的潜变量位置，由此决定推理阶段的候选生成方式与计算代价。

1.4 实验设置

表 1.1: RAG：开放域事实问答的实验设置

类别	名称	说明
测试数据	数据及任务	Natural Questions、TriviaQA、WebQuestions、CuratedTREC；给定自然语言问题预测短答案。
测试方法	流程与目的	用 Wikipedia 文档索引检索前 K 篇证据，比较 RAG-Sequence 和 RAG-Token；以相同任务数据训练与评估。
评价指标	任务度量	精确匹配率（EM），衡量预测答案是否与标准答案一致。
对比基线	参考方案	DPR 读取器和仅靠参数知识的生成模型，用于分离检索贡献。

表 1.2: RAG：长文本答案生成的实验设置

类别	名称	说明
测试数据	数据及任务	MS MARCO 的生成式问答子任务；答案并不局限于单个实体。
测试方法	流程与目的	对检索文档进行条件生成，比较不同边缘化方案处理自由文本答案的能力。
评价指标	任务度量	BLEU、ROUGE-L 等文本重叠指标，衡量生成答案与参考答案的接近程度。
对比基线	参考方案	不使用外部检索的预训练生成器及检索增强生成方案。

表 1.3: RAG：Jeopardy 问题生成的实验设置

类别	名称	说明
测试数据	数据及任务	Jeopardy 题目集合；根据给定事实或答案生成问题文本。
测试方法	流程与目的	固定答案条件，比较生成问题的合理性与事实依赖，并配合人工评价。
评价指标	任务度量	Q-BLEU 及人工评价维度，区分文本匹配与问题具体性、事实准确性。
对比基线	参考方案	BART 等不显式融合非参数文档的生成模型。

表 1.4: RAG：事实验证的实验设置

类别	名称	说明
测试数据	数据及任务	FEVER 事实验证数据；判断自然语言断言的证据关系。
测试方法	流程与目的	对断言检索相关维基文档，并生成或预测事实判断标签。
评价指标	任务度量	分类准确率，衡量事实判断是否与标注一致。
对比基线	参考方案	不含检索模块的模型与其他证据增强方法。

第 2 章

MemGPT 虚拟上下文

2.1 有限窗口的多级存储

MemGPT 处理长对话与长文档时的基本约束是模型可见的 token 窗口有限。其虚拟上下文管理把上下文区分为主上下文（main context）和外部上下文（external context）：前者是每次调用语言模型时真实放入提示词的内容，后者保存在模型输入窗口之外，必须通过工具读取后才能参与推理。这一划分借鉴操作系统的分层存储，但不会让语言模型自动看见外部存储中的全部数据。

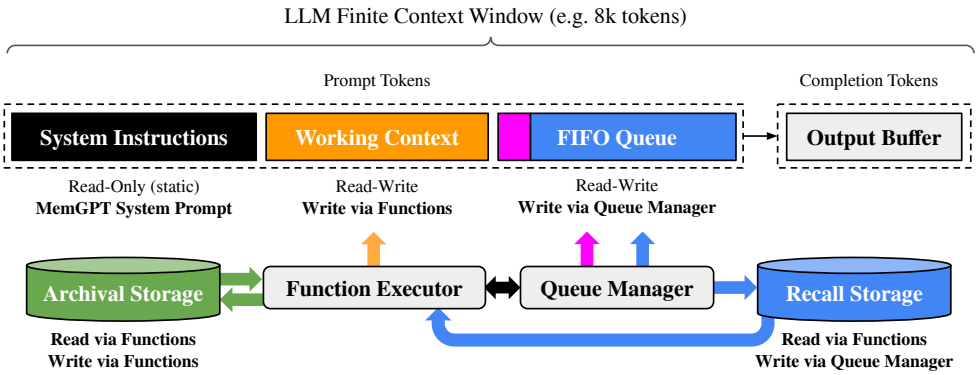


图 2.1: MemGPT 的上下文管理与函数调用流程。原论文系统流程图，来源：[2]。

主上下文包含系统指令、可编辑的核心记忆块、近期消息及必要的系统提示；外部上下文容纳移出的消息与可按需搜索的档案记忆。设窗口上限为 B 个 token，固定指令占用 b_s，当前可编辑记忆占用 b_m，近期消息占用 b_h，工具与生成预留 b_r，则需要满足

$$b_s + b_m + b_h + b_r \le B. \tag{2.1}$$

此式是窗口容量的记账关系，不是原论文训练目标。超出容量时，需要移出一部分历史内容或将其摘要，随后由检索工具在需要时恢复相关细节。摘要保留的语义与可恢复的原始历史应加以区分。

2.2 自管理函数与控制循环

图 2.1 的重要部分是语言模型可以通过函数调用管理自己的记忆。模型识别到上下文缺少信息时，可调用外部消息搜索或档案搜索；需要永久保留的信息则写入适当的记忆区。系统执行函数并将结果反馈给模型，让同一轮任务在工具结果补入主上下文后继续进行。

MemGPT 的控制流程允许一条模型消息以函数调用结束，而非直接向用户输出。调用结束后，队列管理器处理工具结果，更新对话状态，再触发下一步模型执行；只有满足返回用户答案的条件时才结束该轮任务。这样区分了*面向用户的回复*与*面向系统的记忆操作*。如果工具检索失败或返回的片段不充分，模型仍可能回答不出问题；分层存储扩展的是可访问历史的范围，不是单次注意力窗口本身。

2.3 写入、召回与版本边界

在长对话中，持久性的自我设定与用户信息可以放入经常可见的核心记忆；细粒度事件和完整旧消息适于保留在外部上下文。搜索命中后，相关片段被载入主上下文，随后重新参加语言模型的正常自回归生成。旧消息通过工具重新进入窗口，因而检索调用次数、搜索条件与摘要压缩程度直接影响可恢复的信息。

MemGPT 的贡献集中在多层记忆与工具控制，而非提出新的梯度优化算法。[2] 展示了长对话的一致性、对话开启话题、多文档问答与嵌套键值检索等任务：前两类要求跨回合回忆历史，后两类要求从超出窗口的文档或结构中定位证据。它与第 一 章的 RAG 同样访问外部文本，但 MemGPT 增加了可写入记忆及循环调用控制，具体工作负担由存储状态和搜索工具共同决定。

2.4 实验设置

表 2.1: MemGPT：跨会话信息回忆的实验设置

类别	名称	说明
测试数据	数据及任务	Multi-Session Chat（MSC），跨多轮会话查找先前发生的内容。
测试方法	流程与目的	控制可见上下文长度，测试通过外部记忆检索恢复早期会话事实的能力。
评价指标	任务度量	回忆任务的答案质量及与参考内容的一致性。
对比基线	参考方案	仅使用当前上下文窗口、截断历史的对话模型。

表 2.2: MemGPT：对话开场信息保持的实验设置

类别	名称	说明
测试数据	数据及任务	MSC 的跨会话对话开场情境。
测试方法	流程与目的	利用长期存储的历史摘要与外部记忆，在下一次会话开场时生成连续对话。
评价指标	任务度量	语义相似度及上下文相关性等对话质量指标。
对比基线	参考方案	直接将历史对话截断到窗口内的模型。

表 2.3: MemGPT：文档问答的实验设置

类别	名称	说明
测试数据	数据及任务	Natural Questions 等涉及外部文本的信息问答任务。
测试方法	流程与目的	让 Agent 通过工具加载外部材料并反复搜索，检验超出固定工作上下文的信息访问。
评价指标	任务度量	回答正确性；按数据集任务定义核对。
对比基线	参考方案	只读取当前窗口内容、单次提示词问答方案。

表 2.4: MemGPT：嵌套键值信息检索的实验设置

类别	名称	说明
测试数据	数据及任务	含大量键值对的合成输入，查询其中指定键的值。
测试方法	流程与目的	增加键值集合的长度，在上下文容量限制下使用分页和外部存储调用。
评价指标	任务度量	目标键值精确检索正确率。
对比基线	参考方案	直接把键值文本放入模型上下文的标准方案。

第 3 章

GraphRAG 图谱检索

3.1 从文档到群落摘要

[3] 文档级 RAG 擅长检索与单个问题高度相关的段落，却不容易回答“整个资料库有哪些主要主题”一类全局问题。GraphRAG 为此在离线索引阶段构造实体关系图，并为图的实体群落提前生成摘要。在线阶段无需把所有文档同时放入模型窗口，就能用分层摘要覆盖语料的不同部分。它解决的核心任务是面向查询的全局归纳，而非一般意义上的会话长期记忆。

建索引首先把文档集合 $\mathcal{D}$ 切分为文本块 $\mathcal{C}$。语言模型从文本块提取实体、关系及其描述，相同实体可跨块合并，形成知识图 $G = (V, E)$，其中 V 为实体集合，E 为关系集合。群落检测在图上寻找关系相对密集的实体组 $C_1, \dots, C_J$。对每个群落汇总实体描述、关系描述及相关文本证据，再形成可检索的群落报告 R_j。文档块决定抽取粒度，实体合并决定跨文档连接，群落报告则将图结构压缩为可直接交给生成模型的文本上下文。

3.2 从局部证据到全局回答

全局搜索以查询 q 和预先生成的报告 $\{R_j\}$ 为输入。Map 阶段对每份相关群落报告执行问题导向的局部回答，得到部分答案 a_j 及其支持信息；Reduce 阶段选取并合并这些部分答案，生成覆盖多个群落的综合回答。可以把该数据流记成

$$a_j = f_{\text{map}}(q, R_j), \qquad \widehat{y} = f_{\text{reduce}}(q, \{a_j\}_{j \in \mathcal{I}(q)}), \tag{3.1}$$

其中 $\mathcal{I}(q)$ 为当前查询实际处理的群落报告索引集；f_{map} 与 f_{reduce} 表示对应阶段的语言模型调用，式子是对原论文流程的记号化整理，不意味着两个阶段共享参数或可以一次前向完成。

这一结构的检索单元不再只是原始文本块。检索粒度从文档块扩展到实体关系、群落报告和报告中的局部回答，使“覆盖多少群落”成为影响答案全面性与

token 成本的关键因素。离线摘要对群落内事实有损压缩，故全局搜索的广泛覆盖并不自动等于对单一事实的最精确引用；遇到需要精确来源定位的事实题，仍须回到原始文本证据。

3.3 构建成本与查询适配

索引阶段的实体抽取、关系合并和群落摘要都依赖语言模型调用，成本主要发生在读取文档库及生成报告时。查询阶段则反复调用 Map 和 Reduce，使成本随着报告数量、层级与上下文预算变化。文档切块过大可能损伤抽取召回，过小又增加调用次数；群落粒度过粗会混合异质主题，过细则增加报告数量。

原论文分别评估全局问题的回答质量与覆盖多样性，所用测试问题也通过“全局 sensemaking”流程构建。GraphRAG 由图结构得到的是可供汇总的内容组织形式，其路径不同于第 四 章面向更新事实的时序图：这里的群落摘要主要服务于全库综合，而后者的事实边具有时间有效性和失效处理机制。

3.4 实验设置

表 3.1: GraphRAG：全局问题回答质量的实验设置

类别	名称	说明
测试数据	数据及任务	新闻与播客文本语料；围绕整份语料提出要求总体归纳的问题。
测试方法	流程与目的	在相同文本预算条件下，比较社区摘要由高到低的 map-reduce 全局搜索与原始文本摘要及检索式方案。
评价指标	任务度量	由语言模型评估答案全面性、观点多样性与相关支持。
对比基线	参考方案	全量文本切分后的常规检索、直接文本摘要等设置。

表 3.2: GraphRAG：社区层级与覆盖范围的实验设置

类别	名称	说明
测试数据	数据及任务	同一批长篇文本语料及其构建的多层级实体关系图。
测试方法	流程与目的	控制社区层级和候选报告数量，比较全局归纳回答中的信息覆盖与主题组织。
评价指标	任务度量	信息覆盖、回答全面性与多样性的成对判断。
对比基线	参考方案	不同社区层级及采用文本检索的替代上下文配置。

第 4 章

Zep 时序图谱

4.1 情节、实体与群落

[4] Zep 将 Agent 的交互历史转化为动态知识图 $\mathcal{G} = (\mathcal{N}, \mathcal{E}, \phi)$。$\mathcal{N}$ 与 $\mathcal{E}$ 分别为节点和边的集合，关联函数 ϕ 指定边的两端节点。图中保留三个互相连接的层次：情节（episode）节点保存原始消息、文本或 JSON 记录；实体层表示抽取并消歧后的实体以及实体间事实；群落层把相互紧密关联的实体归入簇并生成摘要。保留原始情节，意味着事实抽取之后仍能回查证据。

同一名称可能对应不同实体，不同名称也可能指向同一实体。写入新情节时，系统先提取候选实体，再与已有节点做实体解析；同样，候选事实需要与既有事实作关系解析。实体消歧发生错误会产生错误连接，事实解析遗漏则会留下互相矛盾的关系。Zep 将这两类操作放在图更新阶段，而非把检索命中当作唯一的记忆管理行为。

4.2 时间有效性与事实失效

事实会随时间变化。例如“某人住在 A 城”和“某人迁往 B 城”可能分别在不同时间段成立。Zep 的事实边区分事实对应的时间与系统接收该事实的时间，并通过有效期及失效状态表示历史变更。可用一个事实记录

$$f = (s, r, o, t_{\text{start}}, t_{\text{end}}, t_{\text{created}}) \tag{4.1}$$

帮助辨析：s、r、o 分别是主语、关系、宾语；t_{start} 和 t_{end} 是事实成立的时间边界，t_{created} 是系统获知或写入的时间。此式为字段含义的抽象示意，原系统还会记录更多时间戳与来源元信息。

写入新事实时，若它与原有关系在时间上发生冲突，系统可以使旧边失效而保留其历史记录。查询“现在居住在哪里”与“去年居住在哪里”时，应选择不同的有效时间范围；不能简单把最后写入的事实当成唯一正确的历史。时间信息也可能

由模型从对话中的相对日期表达推断，故日期解析准确性会影响图结构的历史一致性。

4.3 混合检索和答案上下文

检索阶段，Zep 综合语义相似检索、词法检索和图结构相关性，并可通过重排器调整结果次序。召回对象包括实体、事实边及群落摘要，不同任务可选择不同层级：具体事件更依赖情节证据，人物关系更依赖实体事实，概览性问题则可能使用群落文本。

给定查询 q 与已构建的图 $\mathcal{G}$，可将处理过程记为 $H = \text{Retrieve}(q, \mathcal{G})$ 和 $\widehat{y} = \text{LLM}(q, H)$，其中 H 是经过检索和重排、并转换成生成上下文的事实及摘要集合。检索到一条事实边并不意味着它在查询所需时间点仍然有效；排序应与时序约束协调。Zep 在 Deep Memory Retrieval 与 LongMemEval 上检验这条链的记忆召回及长对话问答能力，具体设置集中于末章。

4.4 实验设置

表 4.1: Zep：跨会话深度回忆的实验设置

类别	名称	说明
测试数据	数据及任务	Deep Memory Retrieval（DMR）测试集，要求跨会话找回特定信息。
测试方法	流程与目的	逐轮写入带有时序关系的事实，在查询阶段比较图谱检索与会话摘要等记忆方式。
评价指标	任务度量	问答正确性；使用模型判别答案是否匹配事实。
对比基线	参考方案	全量会话上下文、会话摘要及其他长期记忆方案。

表 4.2: Zep：长跨度时间记忆的实验设置

类别	名称	说明
测试数据	数据及任务	LongMemEval 数据中的长对话与跨会话查询。
测试方法	流程与目的	按会话顺序构建知识图谱，要求根据实体关系和时间变更检索证据。
评价指标	任务度量	问答准确性与对事件时间的正确识别。
对比基线	参考方案	直接长上下文输入、检索和摘要记忆方案。

第 5 章

A-MEM 动态链接

5.1 记忆卡片的结构

A-MEM 借鉴 Zettelkasten 的原子卡片与双向关联思想。每次交互形成一条相对独立的记忆笔记，同时由语言模型生成关键词、标签和上下文描述，使系统不局限于对原句进行向量相似搜索。第 i 条记忆可表示为

$$m_i = (c_i, t_i, K_i, G_i, X_i, e_i, L_i), \tag{5.1}$$

其中 c_i 为原始交互内容，t_i 为时间戳，K_i 为关键词，G_i 为标签，X_i 为上下文描述，e_i 为语义嵌入，L_i 为与其他记忆笔记的链接集合。关键词、标签和上下文描述由语言模型根据交互内容及构造提示生成；嵌入由编码器根据这些文本字段计算。链接字段存储的是关系对象，不能与嵌入向量混同。

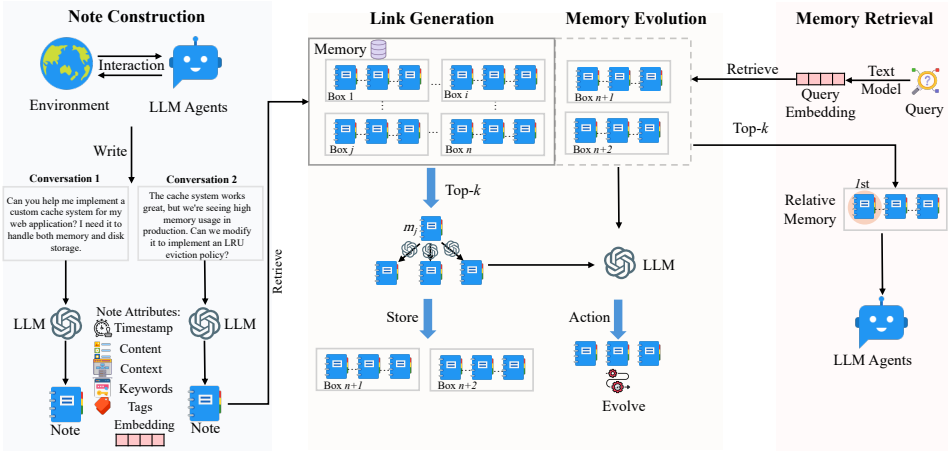


图 5.1: 新记忆的构建、链接生成及对旧记忆的演化操作。原论文框架图，来源：[5]。

5.2 近邻召回与链接生成

新笔记 m_n 写入后，系统先以余弦相似度寻找候选旧笔记。若向量 e_n 和 e_j 的范数非零，则

$$s_{n,j} = \frac{e_n^{\mathsf{T}} e_j}{\|e_n\|_2 \|e_j\|_2}, \qquad \mathcal{M}_{\text{near}}^n = \text{TopK}_j(s_{n,j}). \tag{5.2}$$

$\mathcal{M}_{\text{near}}^n$ 表示按相似度选取的近邻笔记集合；TopK 是取前 k 个候选的操作。语言模型随后根据新笔记与近邻笔记的语义关系决定具体链接，因而近邻检索只提供筛选范围，并不直接宣告每个近邻都具有真正的知识关联。

相比纯相似检索，链接可以表达不同笔记之间的关联路径。若两个事件在词面上差异很大，但共享目标、对象或背景，链接生成可能把它们连在一起；这也带来误链风险，尤其是模型根据模糊上下文推断出未明示的关系时。图 5.1 将候选检索与链接判断分开，正体现了两次决策的不同职责。

5.3 旧记忆演化与最终检索

A-MEM 在建立新链接后，还会让语言模型检查近邻旧笔记是否需要修改关键词、标签和上下文描述。设 m_j 是候选旧笔记，其更新可抽象为

$$m_j^* = F_{\text{evolve}}(m_j, m_n, \mathcal{M}_{\text{near}}^n \setminus \{m_j\}), \tag{5.3}$$

其中 F_{evolve} 代表原论文由提示驱动的语言模型演化操作。若执行更新，m_j^* 替换存储中的对应笔记；演化范围由候选集合及提示限制。由此，新事件不仅增加新节点，也可能改变既有卡片的组织方式。

回答问题时，系统把当前查询编码为 e_q，按与已有 e_i 的余弦相似度取前 k 条记忆加入提示上下文。写入时的链接构建与更新机制影响了记忆库内部的组织；实际最终召回仍依赖查询与笔记向量的匹配。应区分写入阶段的记忆演化和问答阶段的记忆选取，不能把两者视作同一次图遍历。

5.4 实验设置

表 5.1: A-MEM：长程对话问答的实验设置

类别	名称	说明
测试数据	数据及任务	LoCoMo 长对话及其单跳、多跳、时间等问题类别。
测试方法	流程与目的	逐条生成记忆笔记及链接，检索与问题有关的笔记来回答多类别问题。
评价指标	任务度量	F1 与 BLEU-1 等答案匹配指标，按问题类型统计。
对比基线	参考方案	MemoryBank、MemGPT、ReadAgent 等记忆方案。

表 5.2: A-MEM：跨场景对话模拟的实验设置

类别	名称	说明
测试数据	数据及任务	DialSim 多轮对话评测环境，要求恢复先前交互中的信息。
测试方法	流程与目的	比较逐条记忆链接与固定摘要 / 其他长期记忆策略对相关信息的召回。
评价指标	任务度量	问答的 F1、BLEU-1 等文本匹配评价。
对比基线	参考方案	基于长上下文、摘要以及既有记忆模块的方案。

第 6 章

HippoRAG 2 联想检索

6.1 概念与段落联合索引

HippoRAG 2 在开放知识图中同时保留概念短语与原始段落的上下文。离线阶段，语言模型从段落抽取关系三元组，将短语组织为图节点；每段原始文本还成为段落节点，并通过 *contains* 关系连接至其包含的短语。这样，概念层利于跨段落联想，段落层保留实体关系出现时的具体语境。

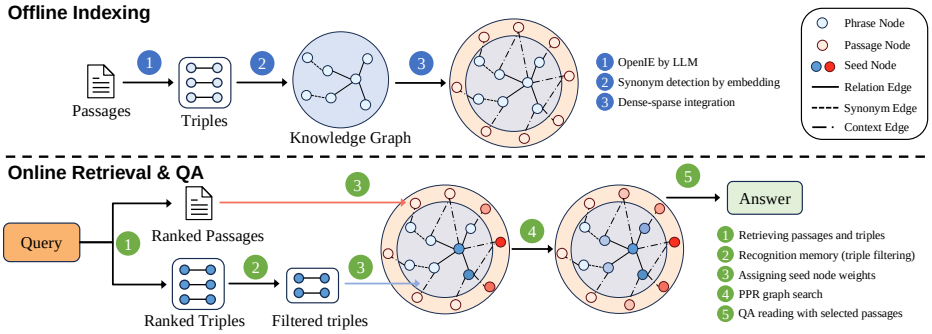


图 6.1: HippoRAG 2 的检索机制及概念、上下文组合。原论文方法图，来源：[6]。

这种双层索引解决了只对短语作图检索时的上下文损失。一个短语在不同段落里可能承载不同事实，若只保留概念节点，则跨段落路径即使相通也无法保证答案证据准确；连接原始段落后，系统可以把图中传播的关联程度重新映射到具体段落。

6.2 查询对齐与识别记忆

在线检索先把问题与图中关系三元组作向量匹配，得到候选三元组集合 T。语言模型再根据问题过滤无关三元组，形成 $T' \subseteq T$。这一步被称为 recognition memory（识别记忆）：初步语义召回扩大候选范围，第二次筛选降低“词义近似、所需关系

却不相符”的噪声。原论文还比较了“先提取问题实体再匹配节点”“整句直接匹配节点”和“整句匹配关系三元组”三种查询连接方式，默认采用三元组匹配。

从 T' 中选出短语种子节点；段落节点也可以根据与问题的嵌入相似度获得初始权重。随后在联合图上运行 Personalized PageRank（PPR）来传播相关性。设 P 为图随机游走的列随机转移矩阵，r 为归一化重启分布，$\alpha \in (0,1)$ 为继续游走概率，则 PPR 向量 $\boldsymbol{\pi}$ 满足

$$\boldsymbol{\pi} = \alpha P \boldsymbol{\pi} + (1-\alpha)\boldsymbol{r}. \tag{6.1}$$

该式是 PPR 的标准固定点表达；原方法的重要决策是如何从短语与段落相关性构造 $\boldsymbol{r}$，而非改变 PPR 的基本定义。若三元组过滤后没有可用种子，原论文采用直接检索高分段落的回退方式。

6.3 传播评分与证据选择

执行 PPR 后，段落节点的分数用于对候选证据排序，高分段落作为问答模型上下文。图 6.1 中，过滤结果限制了有意义的短语入口，而段落向量初始权重保持了直接的语义匹配通道。因而图传播既能利用多跳连接，也不会完全放弃单段落直接命中的信息。

HippoRAG 2 的增量学习主要发生在非参数索引中：新增语料可被抽取并加入图结构，问答模型权重保持不变。其验证任务包含简单事实问答、多跳问答及长篇叙事理解；三类任务对图中关联传播和原始语境的依赖程度不同。PPR 结果是图上的相关性排序，不能直接等同于答案真实性，最终回答仍依赖段落证据及生成模型。

6.4 实验设置

表 6.1: HippoRAG 2：单跳知识回忆的实验设置

类别	名称	说明
测试数据	数据及任务	Natural Questions 和 PopQA 的开放域问答样例。
测试方法	流程与目的	将检索材料转为包含短语与段落的图谱，以 Personalized PageRank 排序关联段落。
评价指标	任务度量	答案 F1 与相关段落 Recall@5。
对比基线	参考方案	BM25、密集检索器以及不使用图传播的检索方案。

表 6.2: HippoRAG 2：跨文档多跳检索的实验设置

类别	名称	说明
测试数据	数据及任务	MuSiQue、2WikiMultiHopQA、HotpotQA 等多跳问答数据。
测试方法	流程与目的	结合查询与知识图谱节点，测试多步关系传播对证据定位的影响。
评价指标	任务度量	答案 F1 与支持证据的召回。
对比基线	参考方案	BM25、DPR 类密集检索及其他图增强检索方法。

第 7 章

Mem0 记忆更新

7.1 候选事实的提取

Mem0 将长期对话记忆拆为两个连续过程：从新交互中提取候选事实，再与既有记忆比较并执行更新。系统处理的输入通常是一组相邻消息 (m_{t-1}, m_t)，并结合近期历史消息及对话摘要 S 构造记忆提取上下文。设近期窗口长度为 h，可将输入组织为

$$P_t = (S, m_{t-h}, \ldots, m_{t-2}, m_{t-1}, m_t), \qquad \Omega_t = \phi(P_t), \tag{7.1}$$

其中 ϕ 是用语言模型实现的事实提取操作，$\Omega_t = \{\omega_1, \ldots, \omega_n\}$ 是候选记忆集合。摘要提供跨轮对话的总体背景，短窗口保存尚未归纳的近期细节；抽取对象仍是本次新交互中值得持久保存的信息。

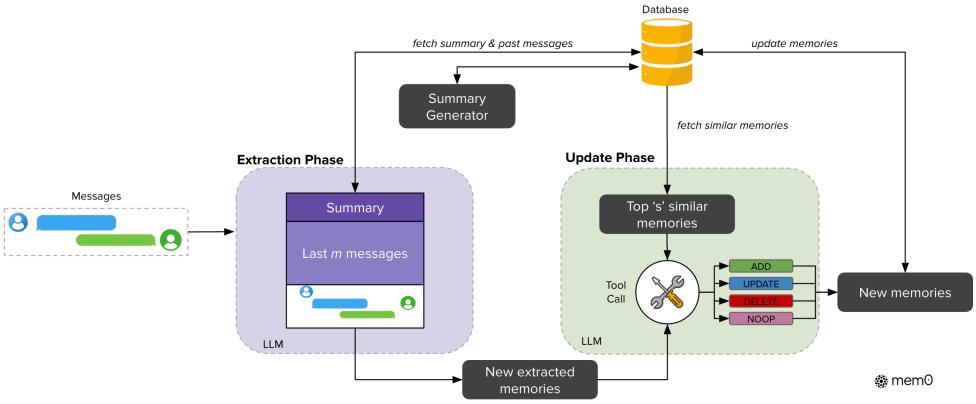


图 7.1: Mem0 的事实提取、相似记忆召回与更新流程。原论文方法图，来源：[7]。

7.2 四种更新决策

对每条候选事实 ω_i，系统先从记忆数据库检索最相似的 s 条已有记忆，再将候选与近邻一起交给语言模型。模型通过函数调用选择四种更新动作：ADD 新建记忆，UPDATE 合并或改写已有记忆，DELETE 删除与新信息冲突的旧记忆，NOOP 保持不变。动作的依据是新旧记忆间的语义关系，而非单独比较一个余弦相似度阈值。

例如，“我喜欢咖啡”和“我现在改喝茶”相似度很高，却可能要求更新或删除旧偏好；两次表达内容相同则应避免重复插入。图 7.1 所示的检索仅负责提供候选比较范围，真正的冲突处理仍由更新决策完成。若近邻召回漏掉原有冲突事实，更新机制也可能无法保持全局一致；这一区别决定了记忆检索质量不仅影响回答，还影响记忆库自身的写入质量。

7.3 图记忆扩展

Mem0 的图扩展版本将对话事实转化为带关系标签的有向图 $G = (V, E, L)$，其中 V 为实体节点，E 为节点间关系，L 为实体类型标签。每条语义关系可写为三元组 (v_s, r, v_o)；v_s、v_o 分别为源实体与目标实体，r 为关系。写入时先识别实体及其类型，再抽取关系，对照已有节点做合并，并对冲突关系进行失效处理。

图检索包含两种相互补充的入口。实体中心检索先定位问题涉及的实体，再扩展邻接关系；三元组语义检索则把整个查询与关系三元组进行向量匹配。前者适合具体主体及其关联问题，后者有助于找出没有直接命中实体名称的相关关系。与第 五 章的 A-MEM 不同，Mem0 的基础记忆更新具有明确的增删改不动四类动作，图扩展版进一步给实体与关系独立的存储表示。

7.4 实验设置

表 7.1: Mem0：多类型长期记忆问答的实验设置

类别	名称	说明
测试数据	数据及任务	LoCoMo 多会话对话；涵盖单跳、多跳、时间与开放域问题。
测试方法	流程与目的	逐轮提取原子事实，执行新增、修改、删除或不更新，再用相关记忆回答问题。
评价指标	任务度量	LLM-as-a-Judge 的回答准确性；分类别统计。
对比基线	参考方案	全上下文、RAG、其他记忆更新系统。

表 7.2: Mem0：记忆构建与查询代价的实验设置

类别	名称	说明
测试数据	数据及任务	与长期对话问答相同的会话历史和问题集合。
测试方法	流程与目的	分别记录存储更新、记忆检索与最终问答开销，比较上下文使用代价。
评价指标	任务度量	输入输出 token 数、响应时间及内存占用等成本指标。
对比基线	参考方案	全历史输入、常规检索及其他可运行的记忆配置。

第 8 章

MemOS 记忆资源

8.1 三类异构记忆

MemOS 将大型语言模型相关的记忆区分为参数记忆、激活记忆与明文记忆。参数记忆位于模型权重中，修改通常涉及参数更新或模型编辑；激活记忆来自推理过程的运行状态，如 KV cache；明文记忆由外部文本、事实或结构化记录构成，能够独立于模型参数持久存储。这三类资源的存储格式、生命周期与可迁移性不同，统一管理的目标是给任务提供一致的资源接口。

这里的三类记忆描述的是系统管理对象，不要求它们共享一个向量空间或具有相同的读写原语。明文知识可通过检索写入当前上下文；激活记忆在复用时依赖模型结构与上下文状态；参数记忆的修改则受训练或编辑机制约束。将三者抽象为资源，并不会消除这些技术前提。

8.2 MemCube 封装

MemCube 是 MemOS 对单元记忆及其管理信息的封装抽象。除了实际记忆载荷，记忆单元还携带类型、来源、状态、生命周期以及访问权限等管理元数据，使不同记忆具有可追踪的身份与调用入口。图 8.1 表达了记忆载荷与管理元信息的组合关系。

可用 $C = (D, M)$ 描述这一组合，其中 D 是承载具体记忆内容的资源，M 是描述该资源的管理字段。这是对 MemCube 的简化记号，不是声称所有记忆都由同一种数据结构实例化。记忆请求首先定位符合权限与任务条件的资源，然后由相应转换或加载机制将其提供给模型。

8.3 调度与生命周期

MemOS 将记忆处理组织为生成、管理、检索、调用和更新等过程。调度器根据任务需要、存储层次和访问策略选择可用记忆，管理层还负责版本、共享与资源治理。

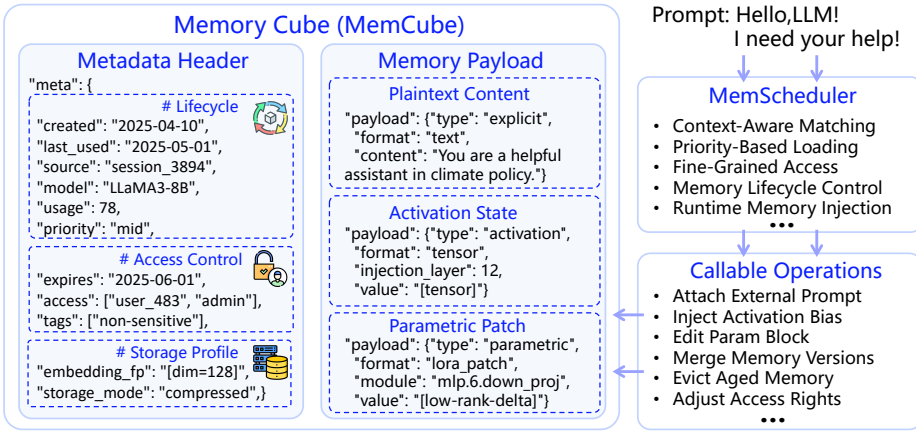


图 8.1: MemCube 的记忆内容与管理元信息。原论文图，来源：[8]。

对于明文记忆，典型执行路径包括检索文本、装配上下文与生成答案；对于激活记忆，复用涉及运行时状态的加载条件；参数记忆则需要相容的参数化操作。

因此，MemOS 的核心技术问题是跨表示的可管理性：何种记忆可以被调用，何时需要迁移或转换，以及修改后如何追踪版本。它关注的层次高于第 二 章 MemGPT 的虚拟上下文函数；前者提出跨类型的资源框架，后者给出了围绕文本窗口的具体工具控制路径。

第 9 章

MIRIX 多类记忆

9.1 六种记忆组件

MIRIX 把 Agent 在持续交互中积累的内容划分到六类组件，各组件的存储对象及可用于推理的方式不同。Core Memory 保存长期稳定且需要常驻上下文的信息，包括 persona 与 human 记忆块；Episodic Memory 保存带时间信息的事件；Semantic Memory 保存抽象事实和实体知识；Procedural Memory 保存目标导向的操作流程；Resource Memory 保留文档、对话记录等资源；Knowledge Vault 用于存储需要较严格访问控制的敏感或原样信息。

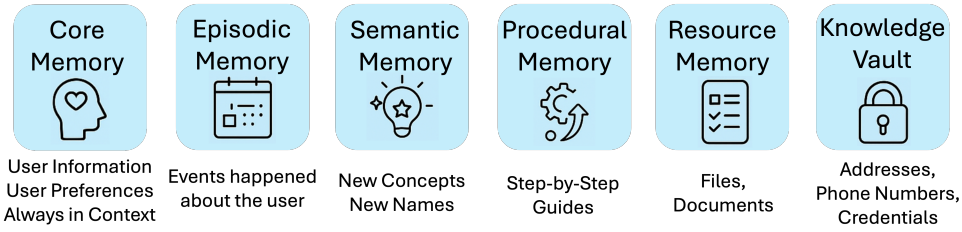


图 9.1: MIRIX 的六类记忆组件。原论文组件图，来源：[9]。

图 9.1 的划分由信息用途决定：一次会议是情节事件，会议中形成的稳定事实可进入语义记忆，会议纪要全文属于资源记忆，而固定执行流程适于放入程序性记忆。同一交互可同时产生不同类型的条目，但条目自身的描述、索引字段与更新策略应与其所属组件相适应。

9.2 主动检索与写入路由

MIRIX 使用多 Agent 工作流承担内容抽取、记忆管理与查询处理。新输入进入系统后，相关模块判断其中是否存在需要持久保存的信息，并选择一个或多个目标记忆组件。历史问答时，检索不必对所有存储一视同仁：含时间线索的问题优先查找情节记忆，询问操作步骤可定位程序性记忆，询问文档原文则需要资源记忆。

此过程可以用类型路由函数 $\rho(q)$ 记号化：查询 q 首先被路由到候选组件集合 $\rho(q) \subseteq \mathcal{T}$，其中 $\mathcal{T}$ 是六类组件的集合；随后在选中组件内检索并组合结果。ρ 是对原论文主动检索思路的抽象，并不表示论文训练了一个具有该符号名称的分类网络。多组件检索能降低不必要的跨库匹配，但错误路由会直接漏掉正确记忆。

9.3 时间事件与资源连续性

Episodic Memory 对“什么时候发生了什么”保留时间戳和事件描述，便于跨会话定位顺序；Resource Memory 可以保存较长的文档或多模态资源，避免将整段材料都压成短事实；Procedural Memory 以明确的步骤结构支持后续任务执行。组件之间的分工允许系统对同一问题组合事件、文档与操作流程，而不要求所有内容压缩成相同格式。

MIRIX 的实验一方面考察屏幕活动持续记忆后的问答，另一方面以 LoCoMo 检查多会话对话记忆。与 MemOS 的跨类型资源操作系统抽象相比，MIRIX 给出了服务于个人助理任务的六类语义化存储单元及多 Agent 协调方式；二者描述的层次和实现目标不同。

9.4 实验设置

表 9.1: MIRIX：屏幕活动视觉记忆的实验设置

类别	名称	说明
测试数据	数据及任务	ScreenshotVQA；三名参与者的连续桌面截图与人工编写的问题。
测试方法	流程与目的	以时间序列逐步写入多组件记忆，最后根据截图历史回答用户问题。
评价指标	任务度量	GPT-4.1 评审的答案准确率；额外记录存储体积。
对比基线	参考方案	Gemini 长上下文截图输入；SigLIP 取前 50 张相关截图再由 Gemini 回答。

表 9.2: MIRIX：长对话回忆的实验设置

类别	名称	说明
测试数据	数据及任务	LoCoMo；每段多会话对话约数百轮并附人工答案。
测试方法	流程与目的	逐次注入对话写入多类记忆，再进行单跳、多跳、时序及开放域问答。
评价指标	任务度量	由 GPT-4.1 判定的答案准确率。
对比基线	参考方案	LangMem、RAG-500、Mem0、Zep 及 Full-Context。

第 10 章

LightMem 轻量记忆

10.1 感知过滤与主题切分

LightMem 的第一层 Light1 在写入前去除重复或可预测的输入 token，再根据话题边界划分交互内容。设原始序列 $\boldsymbol{x} = (x_1, \ldots, x_n)$，压缩模型参数为 θ，第 i 个 token 的保留概率为 $p_i = P(\text{keep } x_i \mid \boldsymbol{x}; \theta)$。以阈值 τ 选择的保留序列为

$$\widehat{\boldsymbol{x}} = (x_i \in \boldsymbol{x} : \; p_i > \tau) \, . \tag{10.1}$$

阈值由目标压缩比例所对应的保留分数分位点决定；序列顺序应保持不变。原论文以 LLMLingua-2 等压缩器估计 token 保留概率。过度过滤可能使实体、日期或否定词丢失，因而压缩成本与记忆完整性存在直接约束。

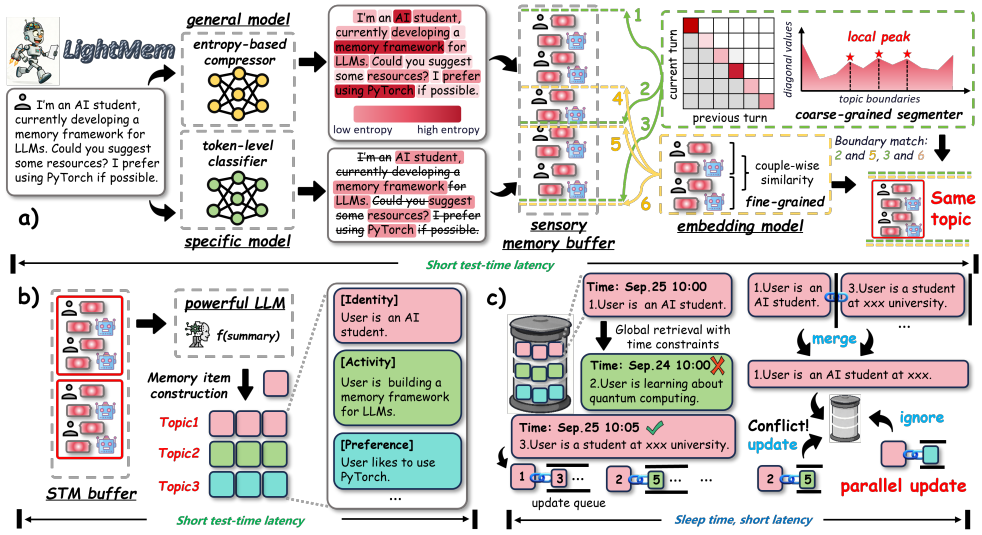


图 10.1: Light1、Light2、Light3 与延后更新的处理链。原论文框架图，来源：[10]。

图 10.1 表明预压缩、主题切分与延后整理位于不同时间尺度，因而能把在线延迟与离线整理成本分开计算。

主题切分结合注意力信息与相邻片段的语义相似度。原论文把两种方式提出的边界集合记为 $\mathcal{B}_1$、$\mathcal{B}_2$，最终使用二者交集：

$$\mathcal{B} = \mathcal{B}_1 \cap \mathcal{B}_2. \tag{10.2}$$

交集要求边界同时获得两类信号支持，因此比简单取并集更保守；得到的每个话题片段将成为下一阶段短期记忆的处理单位。

10.2 短期聚合与长期索引

Light2 将话题片段暂存于短期缓冲区，并在累计 token 数达到阈值时生成话题内摘要。记第 i 个话题片段为 S_i，摘要模型为 f_{sum}，则

$$\text{sum}_i = f_{\text{sum}}(S_i), \qquad \boldsymbol{e}_i = \text{Embed}(\text{sum}_i). \tag{10.3}$$

其中 $\boldsymbol{e}_i$ 用于后续相似检索；长期记忆条目还保存话题及对应的用户与模型消息，因而摘要是索引入口，不等于丢弃全部原始会话内容。相同话题下的多轮交互先合并再摘要，减少逐轮写入与反复调用模型的开销，同时把跨话题内容混合的风险限制在片段之内。

10.3 延后更新与时间约束

Light3 让新的长期记忆先直接插入，再在延后阶段处理旧记忆的整合。对目标条目 e_i，系统只从时间不早于它的候选中搜索可能更新它的记忆。若条目时间戳为 t_i、嵌入为 $\boldsymbol{v}_i$，则候选集合满足

$$\mathcal{Q}_i \subseteq \{e_j : \ j \neq i, \ t_j \geq t_i\}, \tag{10.4}$$

并根据 $\text{sim}(\boldsymbol{v}_i, \boldsymbol{v}_j)$ 选取相似度最高的候选，建立更新队列。时间约束的含义是*较新的信息可以更新较旧的信息*，不是允许较旧事件无条件覆盖后来发生的变化。更新队列准备完成后可在离线阶段并行执行，在线阶段仅保留必要的直接写入与检索，降低每次对话等待记忆重整的时间。

10.4 实验设置

表 10.1: LightMem：LongMemEval-S 问答的实验设置

类别	名称	说明
测试数据	数据及任务	LongMemEval-S 长期会话记忆测试集。
测试方法	流程与目的	按对话轮次增量输入，结合预压缩、主题切分和睡眠期整理后检索回答。
评价指标	任务度量	由 GPT-4o-mini 评判的 ACC。
对比基线	参考方案	Full Text、Naive RAG、LangMem、A-MEM、MemoryOS、Mem0。

表 10.2: LightMem：LoCoMo 问答的实验设置

类别	名称	说明
测试数据	数据及任务	LoCoMo 多会话问题集合。
测试方法	流程与目的	使用与 LongMemEval-S 一致的逐轮写入流程；比较不同底座模型的回忆质量。
评价指标	任务度量	答案 ACC，使用语言模型评判。
对比基线	参考方案	Full Text、Naive RAG、LangMem、A-MEM、MemoryOS、Mem0。

表 10.3: LightMem：处理代价与模块消融的实验设置

类别	名称	说明
测试数据	数据及任务	LongMemEval-S 上的写入与检索流程；按会话自然边界提供分段参考。
测试方法	流程与目的	分别改变预压缩保留率、主题切分策略及感觉缓冲区阈值，观察写入成本与问答正确率。
评价指标	任务度量	摘要与更新阶段输入、输出 token 数；API 调用次数、运行时间、ACC 和切分准确率。
对比基线	参考方案	去掉主题切分的模型；仅注意力或仅相似度切分；不同缓冲阈值配置。

第 11 章

MemRL 效用学习

11.1 意图、经验与效用

MemRL 的目标是在不修改基础语言模型参数的情况下，使 Agent 从运行过程的任务反馈中逐步提高经验选择质量。记忆库被表示为

$$\mathcal{M} = \{(z_i, e_i, Q_i)\}_{i=1}^{|\mathcal{M}|}, \tag{11.1}$$

其中 z_i 表示经验适用的意图或任务描述，e_i 保存一次任务轨迹或求解经验，Q_i 是该经验在相似意图下的估计效用。Q_i 不等于文本嵌入的相似度，它来自环境返回的奖励信号；即便两段经验在表面语义上相近，实际完成任务的贡献也可能不同。

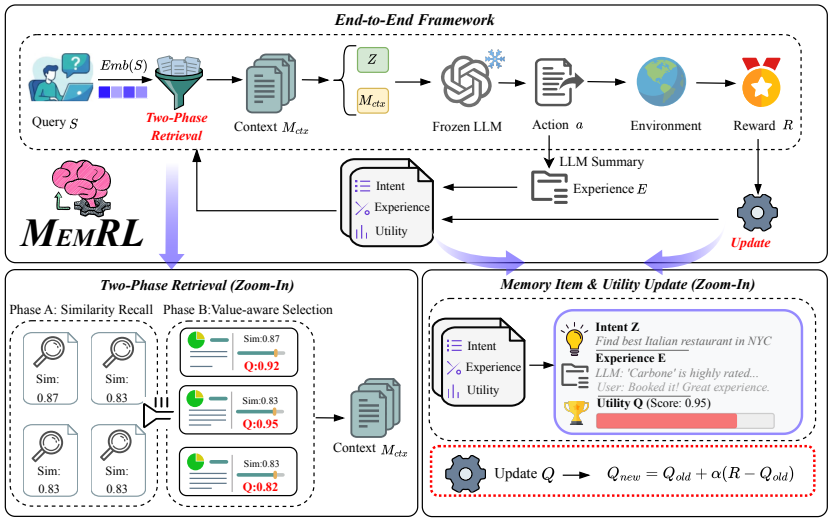


图 11.1: MemRL 的候选经验召回、效用选择与在线反馈更新。原论文框架图，来源：[11]。

图 11.1 展示了先按相似度召回，再按奖励效用选择经验，并依据环境反馈更新记忆的完整循环。

11.2 两阶段经验检索

第一阶段根据当前状态或任务描述 s 与记忆意图 z_i 的向量相似度取候选集 $\mathcal{C}(s)$，并要求相似度超过阈值 δ。若候选集为空，则不强行注入无关经验，而是让冻结的语言模型直接探索。第二阶段在候选集中综合语义匹配和经验效用，选出最终写入模型上下文的 k_2 条经验。原论文将综合得分写为

$$\text{score}(s,i) = (1-\lambda)\widehat{\text{sim}}(s,z_i) + \lambda \widehat{Q}_i, \quad 0 \le \lambda \le 1, \tag{11.2}$$

其中 $\widehat{\text{sim}}$ 和 $\widehat{Q}_i$ 是经标准化的相似度与效用值，λ 控制两者权重。只有在先按语义过滤的候选集合内部比较效用，才能避免一个对当前任务完全无关、但历史奖励很高的经验被直接选入。

11.3 环境奖励更新记忆

执行带经验上下文的 Agent 策略后，环境给出奖励 r，MemRL 用指数移动平均形式更新所选经验的效用估计：

$$Q_{\text{new}} = Q_{\text{old}} + \alpha(r - Q_{\text{old}}), \qquad 0 < \alpha \le 1. \tag{11.3}$$

α 是效用更新步长。将上式改写为 $(1-\alpha)Q_{\text{old}} + \alpha r$ 可看出，新估计是旧估计与当次反馈的凸组合；当 $r > Q_{\text{old}}$ 时效用提高，反之降低。运行过程中还可以将新任务轨迹提炼为经验，连同初始效用值写入记忆库，形成候选经验持续增补的过程。

基础模型参数在运行时保持冻结，学习发生于外部记忆条目的选择和效用更新。原论文通过多轮任务与跨任务迁移考察这一非参数强化学习路径。固定权重不意味着策略行为始终不变：随着 $\mathcal{M}$ 的内容与 Q_i 变化，进入模型上下文的经验会变化，实际行动分布也随之变化。

11.4 实验设置

表 11.1: MemRL：记忆效用的在线学习的实验设置

类别	名称	说明
测试数据	数据及任务	BigCodeBench、ALFWorld、LifelongAgentBench 等 Agent 任务。
测试方法	流程与目的	随交互积累情景记忆，根据使用后任务反馈更新检索项效用，比较有无效用更新的完成情况。
评价指标	任务度量	成功率及完成条件成功率等任务层指标。
对比基线	参考方案	原始检索记忆、静态记忆选择及无在线强化学习的 Agent。

表 11.2: MemRL：跨任务记忆迁移的实验设置

类别	名称	说明
测试数据	数据及任务	在多任务 Agent 环境中训练或积累的记忆及未见任务。
测试方法	流程与目的	复用已有经验在新任务中检索，并对比继续执行时是否能利用成功与失败反馈。
评价指标	任务度量	任务成功率及跨任务泛化成功率。
对比基线	参考方案	不迁移记忆、仅基于相似度的记忆检索等设置。

第 12 章

REMem 情景推理

12.1 情节摘要与带时事实

REMem 面向需要回忆具体经历及其时间、参与者、地点和事件顺序的问题。离线索引阶段从每段交互或事件中提取简明情节描述（gist），并抽取可独立查询的事实三元组。一个事实可用 (s, p, o) 表示，分别为主语、谓词和宾语；对于涉及时间的事实，还保留 `point_in_time`、`start_time` 或 `end_time` 等时间限定字段。相对日期在具有参照日期时被转换为绝对时间，以减少跨会话推理的歧义。

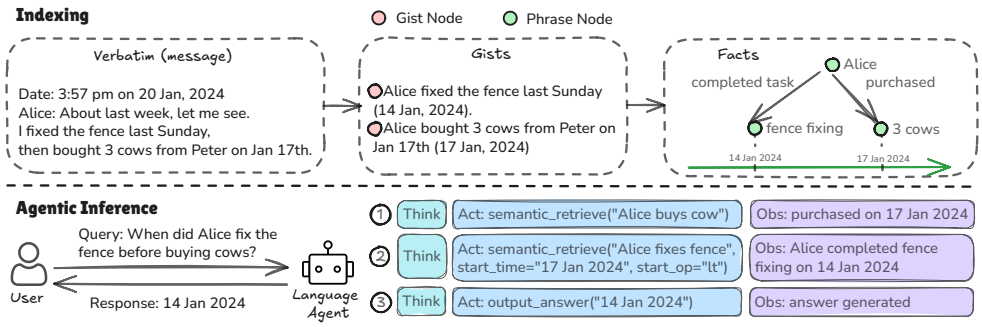


图 12.1: REMem 的情景索引与基于工具的推理流程。原论文方法图，来源：[12]。

图 12.1 将情景事件定位与后续推理操作相连接：检索给出证据入口，推理步骤负责在事件间传递约束。

该记忆图保留两种互补表示：情节摘要说明事件的整体语境，事实节点和关系边使指定人物、事件与时间范围能够被筛选。即使同一事实随时间改变，也无需只保留最新版本；历史事实对回答“当时发生什么”仍有价值。与只将问题同整段历史文本求相似度的方法相比，带时事实为比较事件次序提供明确的检索对象。

12.2 检索与图探索的循环

在线推理采用带工具的多步过程。第一阶段执行语义检索或 BM25 词法检索，获得种子节点和局部上下文；第二阶段调用图探索工具，根据事件或实体找到更精确的关联证据，并可施加时间范围等筛选条件；第三阶段在证据足够时调用输出工具形成答案。工具反馈可以影响下一步检索目标，因此复杂问题不必只执行一次固定的相似搜索。

设用户查询为 q，第 t 次检索后的证据集合为 H_t，下一次工具调用为 a_{t+1}。循环可以抽象为

$$a_{t+1} = \pi_{\text{tool}}(q, H_t), \qquad H_{t+1} = \text{Tool}(a_{t+1}, H_t), \tag{12.1}$$

其中 π_{tool} 是决定调用何种检索或图探索工具的语言模型策略，Tool 表示真实工具返回的证据增量。此记号说明顺序与数据依赖，并非原论文额外训练的显式递推模型。

12.3 情节重忆与跨事件推理

情节重忆要求从历史中找出事件、人物或时间细节；情节推理则要求在多个事件之间施加顺序、时间跨度及逻辑组合约束。例如询问“某次搬家之后、下一次旅行之前发生了什么”时，需要先定位两个时间锚，再在中间范围搜索相关情节，并校对候选事实的时间限定。单条高相似度记忆不足以直接回答这类问题。

REMem 的工具组合把初步召回与面向问题的图扩展分开，既可限制搜索范围，也允许在新的证据出现后继续查找。原论文区分迭代式 REMem-I 与只执行单次向量召回的 REMem-S，并分别评估对话情节重忆和复杂时间推理。结果的正确性取决于情节抽取是否充分、时间信息是否规范化、工具检索是否覆盖所需事件，以及模型是否正确使用召回证据；多步工具本身并不保证最终推理成立。

12.4 实验设置

表 12.1: REMem：LoCoMo 情景证据回忆的实验设置

类别	名称	说明
测试数据	数据及任务	LoCoMo 长期多轮对话和需追溯历史事件的问答。
测试方法	流程与目的	对事件建立情景记忆，按问题查询并在检索证据上进行推理，检查跨轮一致性。
评价指标	任务度量	F1、BLEU-1 和语言模型评判等问答质量指标。
对比基线	参考方案	RAG、Mem0 等长期记忆与证据检索方案。

表 12.2: REMem：REALTalk 事件推理的实验设置

类别	名称	说明
测试数据	数据及任务	REALTalk 的情景记忆与真实对话类问题。
测试方法	流程与目的	把历史事件组织为可供因果与时间关联的记忆，测量推理回答与证据的一致性。
评价指标	任务度量	答案正确性及情景信息的利用质量。
对比基线	参考方案	仅相似度检索和不显式运行情景推理的记忆模型。

表 12.3: REMem：复杂时间推理的实验设置

类别	名称	说明
测试数据	数据及任务	Complex-TR、Test of Time 等涉及时间与跨事件组合的问题。
测试方法	流程与目的	按时间、事件关系检索多条经历，逐步整合后生成最终答案。
评价指标	任务度量	精确匹配和问答正确性等任务指标。
对比基线	参考方案	不进行多事件推理的 RAG 与记忆检索基线。

参考文献

[1] Retrieval-augmented generation for knowledge-intensive nlp tasks. arXiv:2005.11401, 2020.

[2] Memgpt: Towards llms as operating systems. arXiv:2310.08560, 2023.

[3] From local to global: A graph rag approach to query-focused summarization. arXiv:2404.16130, 2024.

[4] Zep: A temporal knowledge graph architecture for agent memory. arXiv:2501.13956, 2025.

[5] A-mem: Agentic memory for llm agents. arXiv:2502.12110, 2025.

[6] From rag to memory: Non-parametric continual learning for large language models. arXiv:2502.14802, 2025.

[7] Mem0: Building production-ready ai agents with scalable long-term memory. arXiv:2504.19413, 2025.

[8] Memos: An operating system for memory-augmented generation (mag) in large language models. arXiv:2505.22101, 2025.

[9] Mirix: Multi-agent memory system for llm-based agents. arXiv:2507.07957, 2025.

[10] Lightmem: Lightweight and efficient memory-augmented generation. arXiv:2510.18866, 2025.

[11] Memrl: Self-evolving agents via runtime reinforcement learning on episodic memory. arXiv:2601.03192, 2026.

[12] Remem: Reasoning with episodic memory in language agent. arXiv:2602.13530, 2026.