从对比学习到表征分散

Dispersive Loss 数学推导

Diffuse and Disperse

作者：Yang kunpeng

从 InfoNCE 的正负样本分解出发，
逐步推导批次表征分散损失，
解析 Hinge、Covariance 与原论文实验。

前言

本书介绍 Wang 与 He 提出的 Dispersive Loss：在保持原有图像生成回归训练不变的前提下，为生成网络的中间特征添加分散正则化。正文按数学原理、不同损失形式、训练实现与实验分析三个章节展开，依次推导 InfoNCE 的代数拆分、分散正则化目标以及不同变体，并介绍 PyTorch 实现和原论文实验。

主要论文

Runqian Wang、Kaiming He，*Diffuse and Disperse: Image Generation with Representation Regularization*，arXiv:2506.09027v2（论文）。本书正文公式及插图依据该论文的 arXiv v2 源码。

核心公式

$$\begin{aligned}\mathcal{L}_{\text{Contrast}} &= \frac{\mathcal{D}(z_i, z_i^+)}{\tau} + \log \sum_j e^{-\mathcal{D}(z_i, z_j)/\tau} \\ &\longrightarrow \mathcal{L}_{\text{Disp}} = \log \mathbb{E}_{i,j}\left[e^{-\mathcal{D}(z_i, z_j)/\tau}\right] \\ &\longrightarrow \mathcal{L}_{\text{total}} = \mathbb{E}[\mathcal{L}_{\text{Diff}}] + \lambda \mathcal{L}_{\text{Disp}}.\end{aligned}$$

符号约定

符号	含义
$X = \{x_i\}$	一个批次的加噪输入图像
$z_i = f(x_i)$	在生成网络中间层提取的特征
z_i^+	普通对比学习中的正样本特征
$\mathcal{D}(z_i, z_j)$	两个特征之间的不相似度
τ	InfoNCE 分散损失的温度参数
λ	分散正则化的权重
$\mathcal{L}_{\text{Diff}}$	原始扩散或流生成模型的回归损失
$\mathcal{L}_{\text{Disp}}$	施加在一个批次中间特征上的分散损失
N, D	批次大小与展平后的特征维数
ϵ	Hinge Loss 中的间隔值；此处不表示高斯噪声
Cov_{mn}	特征维度之间的协方差元素

目录

前言 ii

符号约定 iii

第一章 Dispersive Loss 的数学原理 1
1.1 表征坍缩与分散正则化 . . . 1
1.2 从 InfoNCE 到 Dispersive Loss . . . 2

第二章 Dispersive Loss 的不同形式 6
2.1 InfoNCE-L2 . . . 6
2.2 InfoNCE-Cosine . . . 7
2.3 Hinge Loss 与 Covariance Loss . . . 7

第三章 Dispersive Loss 的实现与实验 9
3.1 PyTorch 实现与训练细节 . . . 9
3.2 原论文实验与结果分析 . . . 11

第 1 章

Dispersive Loss 的数学原理

1.1 表征坍缩与分散正则化

扩散模型与 Flow Matching 模型的训练目标通常是一个回归损失：模型接收加噪后的输入，预测噪声、去噪结果或速度。以速度回归为例，设 x_i 表示输入的加噪样本，y_i 是相应监督信号，模型输出为 $g_\theta(x_i)$，那么典型损失可写成

$$\mathcal{L}_{\text{Diff}}(x_i) = \|g_\theta(x_i) - y_i\|_2^2.$$

这里是为了说明回归的结构；原论文用 $\mathcal{L}_{\text{Diff}}$ 统称原有生成回归损失，并没有规定它必须是上述某一种速度预测形式。训练回归损失的目的，是让输出逼近给定目标。然而，只使用输出误差，不代表网络的中间特征必然具有良好的几何结构。

我们用 f 表示网络中负责提取特征的一部分，令

$$z_i = f(x_i).$$

同一个批次中，若很多不同输入对应的 z_i 聚集在隐藏空间的一小块区域，网络可能难以利用中间表征充分区分这些输入。论文希望通过额外正则化，使特征分布更加分散。这是方法动机，不是“所有回归模型必然发生表征坍缩”的定理。

论文的 $z_i = f(x_i)$ 是中间层特征表示，不是生成结果，也不是模型最终输出的速度向量。假设某一 Transformer 层输出形状为 $H \times W \times C$，把空间和通道维度展平后，整个批次的特征可写为

$$Z = \begin{bmatrix} z_1^\top \\ z_2^\top \\ \vdots \\ z_N^\top \end{bmatrix} \in \mathbb{R}^{N \times D}, \qquad D = HWC.$$

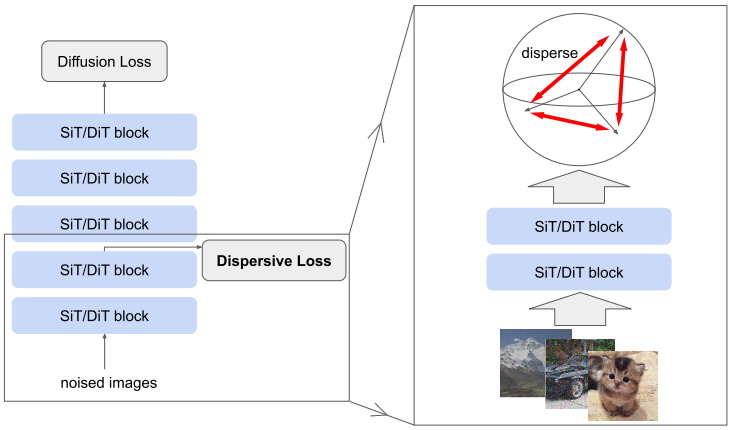


图 1.1: 原论文的结构示意图。Dispersive Loss 直接施加于生成网络中间层，共用原有批次与网络计算。

网络仍然使用相同批次进行原来的生成回归，分散损失只额外利用已经计算出的中间激活。因此论文强调：不需要另外的预训练特征编码器，不需要正样本增强视图，也不需要附加可学习的投影头。

传统对比学习会对一个训练样本构造两种视图 x_i, x_i^+，并要求它们的特征 z_i, z_i^+ 靠近。不同样本的特征则被视为负样本，受到分离约束。可以理解为两个方向同时起作用：

- 对齐（alignment）：让同一数据样本的两个视图在特征空间中靠近。
- 分散（dispersion）：让不同样本的特征不要无差别地堆叠在一起。

图像生成训练本来需要采样噪声等级、加入噪声并计算回归目标。若为了对比学习再额外产生第二份增强视图，可能与原来的噪声采样策略发生冲突。论文实验也显示，直接引入不同噪声级别的正样本对未必改善生成质量。

本文的核心设计是：原本的生成回归损失继续负责预测目标，额外的表征正则化只强调特征间的分散，不要求显式构造正样本对。它不同于说“回归损失在数学上与对比学习的对齐项完全相同”；作者提出的是一种训练分工。

1.2 从 InfoNCE 到 Dispersive Loss

标准 InfoNCE。

原论文以 InfoNCE 为出发点。记 z_i 为锚点特征，z_i^+ 为正样本特征，z_j 为用于归一化的各个样本特征，$\mathcal{D}(a,b)$ 表示不相似度，$\tau > 0$ 为温度。源码中的 InfoNCE 是

$$\mathcal{L}_{\text{Contrast}} = -\log \frac{\exp\big(-\mathcal{D}(z_i, z_i^+)/\tau\big)}{\sum_j \exp\big(-\mathcal{D}(z_i, z_j)/\tau\big)}.$$

直观上，$\mathcal{D}$ 越小，$\exp(-\mathcal{D}/\tau)$ 越大。希望正样本对应的相似度权重较高，同时其他样本不要全部与锚点过于接近。

对数拆分。

推导的核心是使用两条初等对数恒等式：

$$-\log \frac{A}{B} = -\log A + \log B, \qquad \log(e^s) = s.$$

将 InfoNCE 的分子记为 A，分母记为 B，即上式的指数项及其求和项。逐项展开：

$$\begin{aligned}
\mathcal{L}_{\text{Contrast}} &= -\log A + \log B \\
&= -\left(-\frac{\mathcal{D}(z_i, z_i^+)}{\tau}\right) + \log \sum_j \exp\left(-\frac{\mathcal{D}(z_i, z_j)}{\tau}\right) \\
&= \frac{\mathcal{D}(z_i, z_i^+)}{\tau} + \log \sum_j \exp\left(-\frac{\mathcal{D}(z_i, z_j)}{\tau}\right).
\end{aligned}$$

这恰好给出两部分。第一项希望正样本距离变小；第二项对锚点与其他样本的距离施加惩罚。当很多样本离锚点很近时，指数项较大，对数求和也较大，最小化它就有推动特征分散的作用。

去除正样本吸引项。

作者保留对比损失中的第二项，从而得到面向一个参考特征 z_i 的分散损失：

$$\mathcal{L}_{\text{Disp}} = \log \sum_j \exp\big(-\mathcal{D}(z_i, z_j)/\tau\big).$$

这个动作不是“把正样本的特征设置成零”，也不是“在生成任务中没有任何监督目标”。真实情况是：只删除额外对比损失中的正样本吸引项；生成模型原有的 $\mathcal{L}_{\text{Diff}}$ 保持不变。

作者也指出一种等价解释：如果人为使两个正样本视图完全相同，即 $z_i^+ = z_i$，其不相似度就成为常数（例如平方欧氏距离为零），因此正样本项不再贡献可学习的梯度。

从单锚点到批次目标。

设一个批次中有 N 个用于 j 求和的样本，则

$$\frac{1}{N}\sum_j \exp(-\mathcal{D}(z_i, z_j)/\tau) = \mathbb{E}_j[\exp(-\mathcal{D}(z_i, z_j)/\tau)].$$

因而

$$\begin{aligned}\log \sum_j \exp(-\mathcal{D}_{ij}/\tau) &= \log\left[N\,\mathbb{E}_j \exp(-\mathcal{D}_{ij}/\tau)\right] \\ &= \log N + \log \mathbb{E}_j \exp(-\mathcal{D}_{ij}/\tau).\end{aligned}$$

$\log N$ 在批次大小固定时是常数，不改变梯度。于是单锚点形式可以写成原文的

$$\mathcal{L}_{\text{Disp}} = \log \mathbb{E}_j\big[\exp\big(-\mathcal{D}(z_i, z_j)/\tau\big)\big].$$

接下来，作者为了让整个批次只计算一次损失，将定义推广为

$$\mathcal{L}_{\text{Disp}} = \log \mathbb{E}_{i,j}\big[\exp\big(-\mathcal{D}(z_i, z_j)/\tau\big)\big].$$

这里需要严格区分：从求和改成期望，二者只差常数；而从 “固定一个 i” 改成 “对 i, j 一起求期望” 是批次目标的重新定义。特别是 $\mathbb{E}_i[\log \mathbb{E}_j(\cdot)]$ 和 $\log \mathbb{E}_{i,j}(\cdot)$ 通常不相等，不能把后者说成仅靠交换对数和期望得到。

对数与期望的次序。

对数是非线性函数，因此一般有

$$\log\left(\frac{a+b}{2}\right) \neq \frac{\log a + \log b}{2}.$$

这正是必须把 “单锚点损失” 与 “整个批次的重新定义” 区分开的原因。不能随意移动 log 与 $\mathbb{E}$ 的位置。

与生成回归损失的联合训练。

设一个批次的加噪图像为 $X = \{x_i\}$。原论文的总体目标为

$$\mathcal{L}(X) = \mathbb{E}_{x_i \in X}[\mathcal{L}_{\text{Diff}}(x_i)] \; + \; \lambda \mathcal{L}_{\text{Disp}}(X).$$

其中 $\mathcal{L}_{\text{Diff}}$ 是原有单样本生成回归损失，$\mathcal{L}_{\text{Disp}}$ 是依赖整个批次的表征分散损失；λ 决定分散正则项的权重。特别地，$\lambda = 0$ 时，训练目标恢复到原始生成模型。

请注意两个粒度：原回归损失按样本计算后求平均，而 Dispersive Loss 需要比较同一个批次中的不同特征，因此不是逐样本完全独立的损失。

第 2 章

Dispersive Loss 的不同形式

2.1 InfoNCE-L2

论文首先采用平方欧氏距离

$$\mathcal{D}(z_i, z_j) = \|z_i - z_j\|_2^2.$$

代回批次目标就得到

$$\mathcal{L}_{\text{Disp}}^{\ell_2} = \log \mathbb{E}_{i,j}\left[\exp\left(-\frac{\|z_i - z_j\|_2^2}{\tau}\right)\right].$$

平方欧氏距离有一个容易混淆的地方。例如 $z_1 = (0, 0)$、$z_2 = (3, 4)$，欧氏距离是 5，平方欧氏距离则是 25。这里代入指数的是 25，不是 5。

自配对与温度参数。

当 $i = j$ 时，平方欧氏距离恒为零，所以 $\exp(-\mathcal{D}_{ii}/\tau) = 1$。论文说明不必显式删除这些自配对：它们在对数内部提供常数项，批次较大时影响通常减小。不过，自配对是否纳入会改变精确数值与梯度权重，不能把 “可以保留” 理解为 “纳入或删除在数学上完全相同”。

温度 τ 调节距离进入指数的尺度。对于 τ 较小时，较小距离对应的项相对更突出；对高维特征，不能只凭数值大小判断温度是否合适，还要考虑特征尺度。

最小化方向及距离梯度。

一个常见误解是 “损失越小，两个特征应该越靠近”。对这里的分散损失恰好相反。若距离从 $d = 1$ 增大到 $d = 4$，在 $\tau = 1$ 时指数权重从 $e^{-1} \approx 0.368$ 减小到 $e^{-4} \approx 0.018$；因此较远的特征对贡献更小。即使对数最终为负数，它仍然可以作为正常的优化目标。损失值是否为负，并不能说明优化方法有问题。

批次大小与样本对。

若保留 $i = j$ 项，一个由 N 个不同特征组成的批次含 N^2 个有序样本对。其中 N 个是自配对，其平方距离恒为零，剩下 $N(N-1)$ 个为不同样本间配对。为了准

确复现公式，应在实现中约定是否纳入自配对、是否使用有序样本对、以及是否对全部项取平均。

2.2 InfoNCE-Cosine

原论文还研究负余弦相似度：

$$\mathcal{D}(z_i, z_j) = -\frac{z_i^\top z_j}{\|z_i\|_2 \, \|z_j\|_2}.$$

定义 $\cos(z_i, z_j) = z_i^\top z_j / (\|z_i\|_2 \|z_j\|_2)$，代入可得

$$\mathcal{L}_{\text{Disp}}^{\cos} = \log \mathbb{E}_{i,j} \left[\exp\left(\frac{\cos(z_i, z_j)}{\tau} \right) \right].$$

这里的正号并非写错：它来自不相似度本身带有的负号。余弦相似度越高，指数项越大，最小化损失就会压制许多特征之间过高的方向相似度。

余弦版本主要约束方向；而论文使用的 InfoNCE-ℓ_2 不对特征进行 ℓ_2 归一化，距离还受到特征范数的影响。作者在实验中发现 ℓ_2 版本更好，并将其作为后续默认设置；这只是论文特定设置的经验结果，不能推成普遍最优。

2.3 Hinge Loss 与 Covariance Loss

Hinge Loss。

对比学习中的 Hinge 形式包括正样本吸引项，以及负样本之间的间隔惩罚。作者移除正样本项后，保留

$$\mathcal{L}_{\text{Disp}}^{\text{Hinge}} = \mathbb{E}_{i,j} \left[\max\big(0, \epsilon - \mathcal{D}(z_i, z_j)\big)^2 \right].$$

这里 $\epsilon > 0$ 是论文使用的间隔阈值（margin），不是前面其他论文中代表高斯噪声的随机变量。只要 $\mathcal{D}(z_i, z_j) \geq \epsilon$，这一对样本的惩罚就是零。

例如取 $\epsilon = 2$，两组特征的距离分别是 1 与 3。对应损失分别为

$$\max(0, 2-1)^2 = 1, \qquad \max(0, 2-3)^2 = 0.$$

Hinge 的特点是明确设定分离阈值，而不是要求距离永远增大。

Covariance Loss。

论文还把基于跨视图特征统计的 Barlow Twins 类损失改造成单视图形式。设一个批次的特征有 D 个维度，定义协方差矩阵 Cov $\in \mathbb{R}^{D\times D}$，其第 (m,n) 个元素是 Cov_{mn}。

原文表格给出的分散形式是

$$\mathcal{L}_{\mathrm{Disp}}^{\mathrm{Cov}} = \sum_{m,n} \mathrm{Cov}_{mn}^2.$$

直觉上，这类损失希望不同特征维度不要高度耦合；协方差越大，对应平方惩罚越大。注意论文正文把这一构想解释为侧重非对角元素，但表格保留 $\sum_{m,n}$ 的全矩阵求和写法。二者在一般情况下并不完全相同；只有对角项被归一化约束为常数等附加条件成立时，才可能在梯度意义上不影响非对角项优化。这里保留原表公式，并将这种实现细节作为源码核对时需要注意的地方。

四种正则化形式的比较。

变体	$\mathcal{D}$ 或计算对象	主要限制	论文实验观察
InfoNCE-ℓ_2	$\|z_i - z_j\|_2^2$	包含距离大小与特征范数	本文主要实验中表现最好
InfoNCE-Cosine	负余弦相似度	重点在特征方向	本文实验有提升
Hinge	$\max(0, \epsilon - \mathcal{D})^2$	只处罚低于间隔的样本对	本文实验有提升
Covariance	协方差矩阵元素平方和	约束不同特征维度的相关统计	本文实验有提升

“Dispersive Loss” 不是唯一固定的损失公式，而是一类鼓励内部特征分散的正则化目标。论文主要使用 InfoNCE-ℓ_2，但还验证了其他形式。

第 3 章

Dispersive Loss 的实现与实验

3.1 PyTorch 实现与训练细节

中间层特征与总损失。

作者强调即插即用的训练结构：原生成模型先按原方式抽取批次、采样噪声并得到预测结果；与此同时，在指定 Transformer block 取得中间特征 Z。然后计算

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{Diff}} + \lambda \mathcal{L}_{\text{Disp}}.$$

对于 InfoNCE-ℓ_2，论文伪代码的三个主要运算是：计算特征间距离的平方；对 $-D/\tau$ 取指数并求平均；最后取对数。原论文的伪代码表示为 `D = pdist(Z, p=2)**2` 和 `log(mean(exp(-D/tau)))`。

PyTorch 实现。

以下示例使用 `torch.cdist` 构造全部 $N \times N$ 距离矩阵，与论文式（4）包含 $i = j$ 的定义一致。为了数值稳定，使用 `logsumexp` 代替直接 `log(mean(exp()))`：

```python
import math
import torch
import torch.nn.functional as F


def dispersive_l2(Z: torch.Tensor, tau: float = 0.5):
    # Z: [batch, ...] -> [N, D]
    Z = Z.flatten(start_dim=1)
    D = torch.cdist(Z, Z, p=2).square()
    scores = -D / tau
    return torch.logsumexp(scores.flatten(), dim=0) - math.log(scores.numel())


def train_loss(pred, target, features, weight=0.5, tau=0.5):
```

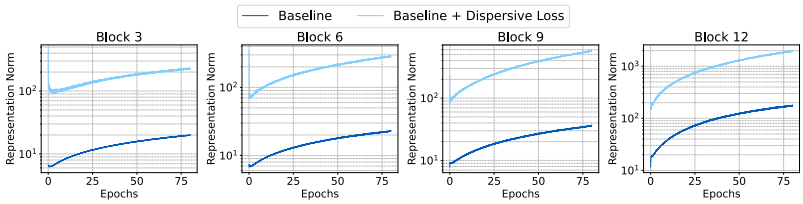


图 3.1: 原论文的中间特征范数图。图中比较了使用和未使用 Dispersive Loss 的表示范数。

```
    loss_diff = F.mse_loss(pred, target)
    loss_disp = dispersive_l2(features, tau)
    return loss_diff + weight * loss_disp
```

这里 `torch.cdist` 会包含对角线。与之不同，PyTorch 的 `torch.pdist` 默认只返回不重复的非对角样本对；如果直接替换，计算的批次目标就与上述代码不同。论文源码使用抽象的 `pdist` 伪代码，并未在这段伪代码中规定 PyTorch API 的调用约定，实际复现应明确样本对集合与是否包含对角线。

对高维 Z，全部两两距离的内存开销随批次大小大致以 N^2 增长，因此“无额外参数”和“训练开销可以忽略”并不意味着任意批次规模下计算一定免费。

超参数与特征位置。

论文主实验的默认设置为 $\lambda = 0.5$、$\tau = 0.5$，采用 ImageNet 256×256 图像以及 SiT、DiT 生成模型，并在多数消融实验中训练 80 个 epoch、不使用 CFG。论文在不同 λ、τ 的组合下都观察到了相对基线的改进。

对于 12-block SiT-B/2，作者在不同 block 上施加正则化，发现多个位置均有收益。后续实验通常选用整个网络前四分之一附近的一层施加分散损失。

未归一化的欧氏距离与特征尺度。

对于余弦相似度，整体乘上正数不会改变方向相似性；对于平方欧氏距离，放大特征向量的范数通常会增大距离。论文特别注明，在使用 InfoNCE-ℓ_2 时不对特征做 ℓ_2 归一化。因而除了改变方向外，模型也可以通过改变特征尺度影响分散损失。

原文专门报告了中间特征范数的变化。在只对 Block 3 施加正则化的设置中，范数增长不仅发生在直接施加损失的层，也传播到其他层。

这说明损失会显著影响特征的数值尺度，但范数变大本身不等于证明模型学到了更好的语义。论文以生成质量的实验证据支持正则化有益，不能只根据范数增长作出因果结论。

特征尺度与正则化边界。

对于未归一化的 ℓ_2 特征，增大向量范数往往也能扩大距离，因此分散正则化确实可能鼓励特征尺度变大。但是原有网络结构、生成回归损失以及训练超参数共同决定最终优化行为。原论文的结果说明它在研究设置下有帮助，而不是证明任意 λ、任意特征规模都安全。

3.2 原论文实验与结果分析

不同损失形式的比较。

原论文在 ImageNet 256×256、SiT-B/2、80 epochs、无 CFG 的配置下报告以下 FID-50k（越低越好）：

训练方法	FID-50k ↓
不使用 Dispersive Loss 的基线	36.49
InfoNCE-ℓ_2 Dispersive	32.35
InfoNCE-Cosine Dispersive	34.33
Hinge Dispersive	33.93
Covariance Dispersive	35.82

相对于 36.49 的基线，InfoNCE-ℓ_2 降低了 4.14 FID，约为 11.35% 的相对改善。论文还报告，使用独立噪声视图的传统对比学习版本在测试的四种设置中未改善基线，这支持了作者避免额外正样本视图的设计动机。以上结论对应论文中的具体实验，不能推成所有生成模型上的普遍排序。

不同生成模型规模。

原论文还在 DiT 与 SiT 的不同模型规模上研究分散损失。其报告显示，不同规模上均可以获得改善，其中某些较强的 SiT 基线也取得可观的收益。

这里要区分：分散损失是训练过程中的附加项；它不会自动把需要多步采样的 DiT 或 SiT 变成 One-Step。采样步数主要取决于基础生成模型本身。

MeanFlow 相关实验。

这是和你之前研究的 MeanFlow 最直接的联系。原论文不仅测试普通扩散 / 流模型，还把 Dispersive Loss 加到当时的 MeanFlow 上，报告如下结果（ImageNet 256×256，FID-50k）：

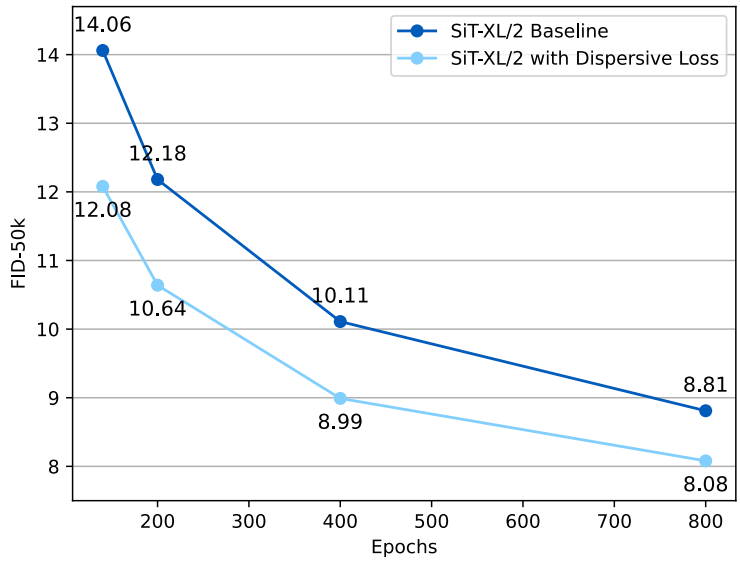


图 3.2: 原论文的训练过程中 FID 曲线，比较 SiT-XL/2 基线与加入分散损失的版本。

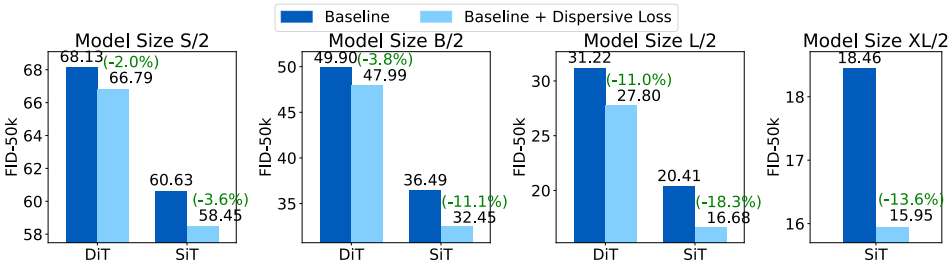


图 3.3: 原论文展示不同 DiT、SiT 模型规模及 Dispersive Loss 改进的实验图。

MeanFlow 模型与训练轮次	原始基线	+ Dispersive Loss
MF-B/4，80 epochs	18.78	17.61
MF-B/2，80 epochs	9.77	8.97
MF-B/2，240 epochs	6.17	5.69
MF-XL/2，240 epochs	3.43	3.21

在 MF-XL/2 实验中，作者受计算资源限制，从训练到 180 epochs 的 MeanFlow 检查点继续训练 60 epochs 并加入 Dispersive Loss，而不是全部从头训练。因此阅读这些实验时，应区分“从头训练”和“在已有检查点上继续训练”。该组 MeanFlow 实验使用的 λ 也不是统一的 0.5：论文分别为 B/4、B/2、XL/2 设置了 0.25、1.0 和 1.5。

MeanFlow 本身负责预测平均速度，实现一步生成；Dispersive Loss 只对训练中的内部特征施加附加约束。两者的职责不一样：

$$\text{原有 MeanFlow 回归训练} \quad + \quad \lambda \mathcal{L}_{\text{Disp}} \quad \longrightarrow \quad \text{保持原有一步生成形式.}$$

论文中的 MeanFlow-XL/2 + Disp 保持 NFE=1，同时 FID 从 3.43 降至 3.21。Dispersive Loss 不是 MeanFlow Identity 的组成部分，也不是 One-Step 推理所必须计算的内容。