GR00T N1

论文精读笔记

模型架构、LAPA 与 IDM、训练及推理

作者：Yang kunpeng

GR00T N1 原论文：arXiv:2503.14734

目录

第一章 GR00T N1 模型架构 **1**

1.1 双系统与整体数据流 1

1.2 Eagle-2 视觉语言模块 2

1.3 DiT 与具身专属接口 2

1.4 机器人状态、动作与动作块 3

第二章 数据构建：LAPA 与 IDM **4**

2.1 四类数据如何进入训练 4

2.2 LAPA：以视频重建学习潜在动作 5

2.3 IDM：从前后图像推断机器人动作 6

2.4 LAPA 与 IDM 的关系 7

第三章 GR00T N1 训练流程 **8**

3.1 训练样本与监督信号 8

3.2 策略前向计算与损失 9

3.3 多具身预训练 9

3.4 面向目标任务的后训练 10

3.5 哪些参数接受梯度 10

第四章 GR00T N1 推理流程 **11**

4.1 一次动作块预测 11

4.2 动作块执行与闭环 12

4.3 核心推理伪代码 13

参考资料 **14**

第 1 章

GR00T N1 模型架构

GR00T N1 是以图像、任务语言和机器人本体状态为条件，输出连续机器人动作的视觉语言动作模型（Vision-Language-Action，VLA）。模型划分为视觉语言模块（System 2）和动作模块（System 1）。System 2 提供任务相关的多模态特征，System 1 将这些特征与机器人当前状态、带噪声的动作块结合，预测动作生成所需的向量场。两者通过特征交互连接，而不是必须先由语言模型生成文字计划，再将文字计划转换成动作。

1.1 双系统与整体数据流

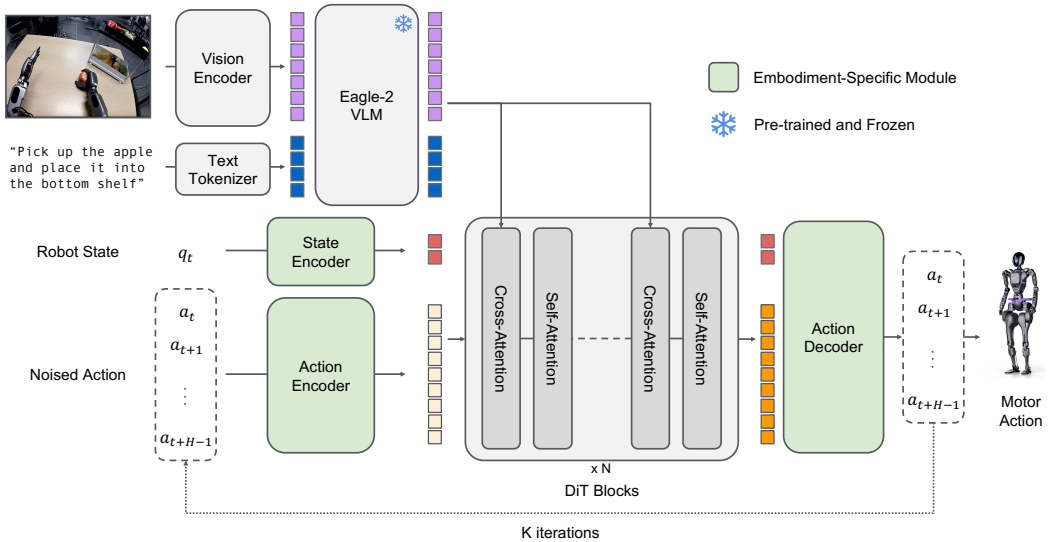


图 1.1: 论文原图：Eagle-2、具身专属状态/动作编码器、交替的 Cross-Attention 与 Self-Attention、动作解码器及迭代生成过程。

图1.1对应论文的主要计算关系。图像和文字首先送入 Eagle-2，得到视觉语言特征 ϕ_t；机器人状态 s_t 经过状态编码器成为状态 Token；动作块的带噪声版本 A_t^τ 和流匹配时间步 τ 经过动作编码器成为动作 Token。DiT 中的 Self-Attention 处理状

态与动作 Token，Cross-Attention 使这些 Token 读取视觉语言特征。最后，动作解码器将 DiT 的动作 Token 映射回目标机器人的动作空间。

模型公开的 N1 版本约有 2.2B 参数，其中 VLM 约 1.34B。它支持不同机器人形态，不依赖所有机器人有完全相同的关节数量或动作维度；实现这一点的接口是**具身专属的状态编码器、动作编码器与动作解码器**，共享的是 VLM 和 DiT 主体。

1.2 Eagle-2 视觉语言模块

Eagle-2 由 SigLIP-2 图像编码器和基于 SmolLM2 的语言模型构成。原论文将输入图像处理为 224×224 分辨率，经过图像编码与 Pixel Shuffle 后，每帧产生 64 个图像 Token；任务文本与图像 Token 在语言模型中共同编码。如果有多视角或多帧图像，总 Token 数会相应改变，不能把“每帧 64 个”误认为全部多模态输入只有 64 个 Token。

视觉语言输出形状为

$$\phi_t \in \mathbb{R}^{B\times L\times d_v}, \tag{1.1}$$

其中 B 为批量大小，L 为图像与文字的联合 Token 长度，d_v 为 VLM 隐藏维度。论文使用 Eagle-2 **第 12 层**的表示，而不是最后一层隐藏状态，作为 DiT 的条件特征。这样得到的是高维表征，不是语言模型解码出的动作描述或显式文本计划。论文观察到选择中间层能改善下游性能和推理速度。

1.3 DiT 与具身专属接口

机器人形态（embodiment）可能使用不同的状态维度 d_s 和动作维度 d_a。对某个具身 e，状态编码器与动作编码器可抽象成

$$q_t = E_s^{(e)}(s_t), \tag{1.2}$$

$$z_t^\tau = E_a^{(e)}(A_t^\tau, \tau). \tag{1.3}$$

这里 q_t 表示输入 DiT 的状态表示，不应与通常表示关节角的符号 q^{joint} 混淆。论文使用**每个具身独立的 MLP** 将状态和动作投影到共享嵌入维度；动作编码器还处理流匹配时间步。Self-Attention 作用于状态与带噪声动作嵌入，Cross-Attention 读取 ϕ_t，DiT 内利用自适应层归一化注入流匹配时间步条件。

设经过 DiT 的动作 Token 为 h_t^τ，则具身专属动作解码器输出

$$V_\theta(\phi_t, A_t^\tau, q_t) = D_a^{(e)}(h_t^\tau). \tag{1.4}$$

这里 V_θ 是流匹配向量场预测，不是机器人此时已执行的控制命令。动作块还要经过迭代更新，才形成策略的最终动作输出。

1.4 机器人状态、动作与动作块

机器人状态不等于仅有关节角。机器人本体状态（proprioception）通常记录与当前机器人配置相关的关节位置、末端执行器位姿、夹爪闭合量等；具体字段由数据集和控制方式决定。原论文的标准化部分明确涉及关节状态、末端位置、末端姿态及夹爪信息，其中末端状态旋转使用 6D 表示，末端动作旋转采用轴角表示。若某个机器人只给关节位置，就不能凭空认为输入中还有速度、力矩或末端位姿；这些字段以对应数据集的模态配置为准。

表 1.1: 状态与动作的语义区别（字段为论文涉及的示例，非所有具身的固定格式）。

对象	回答的问题	可能的表示
状态 s_t	机器人当前在哪里、处于何种姿态	关节位置、末端位置/旋转、夹爪闭合量
动作 a_t	控制器下一时刻要接收什么	关节目标、末端动作、夹爪动作等

GR00T N1 不只预测一个 a_t，而是一次预测长度为 H 的动作块：

$$A_t = [a_t, a_{t+1}, \ldots, a_{t+H-1}], \qquad A_t \in \mathbb{R}^{H \times d_a}, \quad H = 16. \tag{1.5}$$

动作块长度 $H = 16$ 是时间长度；动作向量维度 d_a 是该机器人每一步需要的控制量个数。二者不能混淆。时间上的 16 个动作与生成动作时的 4 次流匹配迭代也不是同一种计数。

跨具身训练的要点是先把不同的原始输入映射到共享隐藏空间，再用具身专属解码器恢复相应动作空间。这并不意味着不同机器人的原始关节动作可以直接互换。

第 2 章

数据构建：LAPA 与 IDM

真实机器人数据提供图像、状态和动作；人类视频与神经生成视频通常没有可直接用于机器人控制的动作记录。GR00T N1 使用 LAPA 从视频学习潜在动作，并训练 IDM 为生成的机器人视频预测动作伪标签。两种机制都使用前后图像，却具有不同的监督目标与输出空间。

2.1 四类数据如何进入训练



图 2.1: 论文原图：数据金字塔由人类视频、生成与仿真轨迹以及真实机器人演示共同构成。

真实机器人演示带有真实动作标签；仿真轨迹可从仿真环境得到动作与状态；人类视频缺少机器人动作，因此主要通过 LAPA 提供潜在动作监督；视频生成模型产生的 Neural Trajectories 本身也无实际执行时的动作记录，需要通过 LAPA 或 IDM 提取动作目标。论文将约 88 小时的内部遥操作数据扩展成约 827 小时神经生成视频，后者的时长是生成结果，不是额外实机遥操作的时间。

仿真路径使用 DexMimicGen：将少量演示拆成物体中心的操作片段，对新的物体位姿变换并重放，采用插值连接各片段，最终只保留成功的仿真轨迹。它的作用是扩充已有机器人动作标签的数据，不属于 LAPA 或 IDM 的组成部分。

2.2 LAPA：以视频重建学习潜在动作

Latent Action Pretraining（LAPA）首先训练 VQ-VAE。给定起始帧 x_t 与未来帧 x_{t+H_L}，编码器输出连续潜在向量

$$z_e = E_\psi(x_t, x_{t+H_L}), \tag{2.1}$$

其中 H_L 为 LAPA 提取前后帧时使用的固定窗口，**不必与 VLA 的 16 步动作块长度混为一谈**。VQ-VAE 通过码本进行向量量化，选择最接近的码本向量

$$z_q = e_{k^*}, \qquad k^* = \arg\min_k \|z_e - e_k\|_2^2. \tag{2.2}$$

解码器使用当前帧与量化后的表示重建未来帧：

$$\hat{x}_{t+H_L} = D_\psi(x_t, z_q). \tag{2.3}$$

编码器必须从前后帧中提取有助于解释变化的信息，重建目标才可能成立。VQ-VAE 还包含码本学习与量化承诺等损失；GR00T N1 论文没有在正文给出它们的精确组合系数，因此不把标准 VQ-VAE 的某一组超参数写成 GR00T N1 专属设置。

关键实现区别：训练 VQ-VAE 时使用量化后的 z_q 来完成重建；在为 GR00T N1 生成训练标签时，论文提取的却是**量化前的连续编码** z_e。因此后续策略学习的目标不是码本中的离散编号，而是连续潜在动作：

$$z_{\text{LAPA}} = E_\psi(x_t, x_{t+H_L}). \tag{2.4}$$

论文将 VQ-VAE 在异构视频上联合训练，期望获得跨具身共享的运动表示。图2.2说明此表示与运动方向存在可观察的相关性；但这种表示**不能直接视为某个机器人可执行的关节控制命令**。预训练 GR00T N1 时，潜在动作以独立的 LAPA embodiment 作为 Flow Matching 的监督目标，从而让无原生动作标签的人类视频也参与训练。

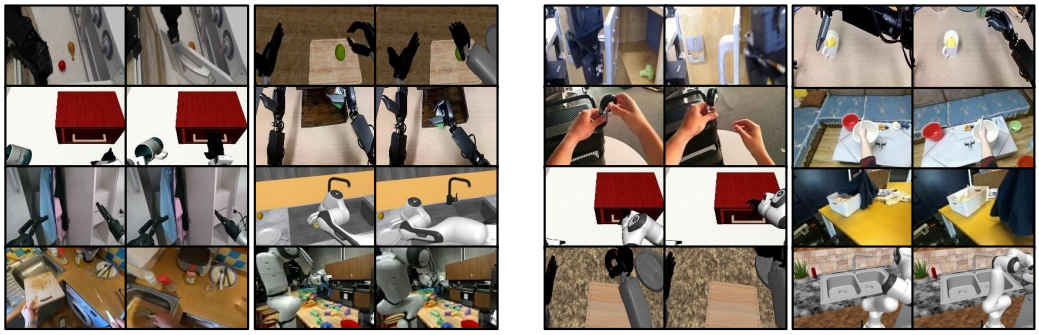


图 2.2: 论文原图：不同人类与机器人具身中，相似的左右运动可对应相近的潜在动作嵌入。

2.3 IDM：从前后图像推断机器人动作

逆动力学模型（Inverse Dynamics Model，IDM）把目标从“视频运动的潜在表示”改成“某种机器人动作空间中的动作块”。其训练样本同时包含两帧图像和两帧之间真实记录的动作：

$$(x_t, x_{t+H_I}, A_{t:t+H_I}). \tag{2.5}$$

网络学习条件分布中合理的动作生成：

$$(x_t, x_{t+H_I}) \longmapsto \hat{A}_{t:t+H_I}. \tag{2.6}$$

这里的 H_I 是 IDM 使用的动作跨度，训练和伪标注时保持一致；其输出维度由目标机器人动作空间决定。

论文附录中的 IDM 采用 **SigLIP-2 视觉特征 + System 1 DiT + Flow Matching 目标**。与 LAPA 的视频重建训练不同，IDM 需要真实机器人动作作为监督信号，分别对不同具身训练。论文报告训练 30K 或 60K 步，取决于数据规模；初步实验中增加机器人状态或更多图像帧，并未明显改善验证集动作预测。

训练完成后，将生成视频分割成前后图像对，由 IDM 预测中间的动作块，作为 Neural Trajectories 的**伪动作标签**。同一终点可能有多条不同的可行动作轨迹，故 IDM 推断出的动作并不保证是唯一、真实发生过的轨迹；对生成视频而言，本来就不存在实际机器人执行记录。

2.4 LAPA 与 IDM 的关系

表 2.1: 两类从图像推断动作的方法。

比较项	LAPA	IDM
训练输入	前后视频帧	前后视频帧、真实机器人动作
训练目标	VQ-VAE 重建未来帧	Flow Matching 生成真实动作块
输出标签	连续潜在动作 z_e	具身专属动作块 $\hat{A}$
适用数据	人类与机器人等无动作标注视频	对应具身的生成机器人视频
在 VLA 中	独立 LAPA embodiment 的动作监督	目标具身的伪动作监督

论文也把训练好的 LAPA 编码器称为一种 *inverse dynamics model*：它同样根据起止两帧恢复运动信息。但正文与附录中单独提及的 IDM，是需要真实动作监督并生成机器人原生动作块的专门网络。两者名称上可能相似，使用场景与训练目标不同。

Neural Trajectories 的流程为：真实遥操作视频用于微调图像到视频模型；视频生成器根据初始帧和新的语言提示产生操作视频；多模态模型对视频进行筛选或重新描述；LAPA/IDM 提供动作标签；这些带监督信号的数据再参与 VLA 的预训练或后训练。**LAPA 和 IDM 是离线数据处理与监督构建组件，不是 GR00T N1 在线执行动作的必经模块**。

第 3 章

GR00T N1 训练流程

GR00T N1 的训练流程可以分为三个环节：准备真实或生成的动作监督，使用多具身混合数据进行预训练，再针对特定具身和任务后训练。LAPA、IDM 和视频生成模型是数据构建阶段使用的辅助模型；主策略训练对象是 Eagle-2 与 DiT 构成的 VLA 以及各具身接口。两次策略训练使用同一类 Flow Matching 动作生成目标，并非预训练用一种算法、后训练换另一种算法。

3.1 训练样本与监督信号

对于具有真实动作的具身，单条策略训练样本可抽象为 (I_t, L, s_t, A_t)：I_t 为一个或多个摄像头观察，L 是任务文本，s_t 是当前状态，$A_t \in \mathbb{R}^{16\times d_a}$ 是未来动作块。对于人类视频，动作目标可替换成 LAPA 连续潜在动作；对于神经生成视频，动作目标可采用 LAPA 结果或某个机器人具身的 IDM 伪动作。不同的监督目标通过具身标识及相应的编码器、解码器处理，**并不要求所有数据的动作维度或物理意义相同**。

表 3.1: 原论文明确给出的各数据源动作监督方式。

数据源	预训练时的监督目标
人类视频	LAPA 提取的潜在动作
真实机器人	真实机器人动作及 LAPA 潜在动作
Neural Trajectories	LAPA 潜在动作及 IDM 预测的机器人动作
仿真机器人轨迹	仿真系统给出的机器人动作监督

从而，策略通过共享 DiT 接触到大量动作相关训练样本，而具身专属模块保留不同控制空间的语义。图像和文本仍然经过 Eagle-2，而不是 LAPA/IDM 直接替代 VLM。

3.2 策略前向计算与损失

设真实动作块为 A_t，高斯噪声为 $\epsilon \sim \mathcal{N}(0, I)$，流匹配插值时间为 $\tau \in [0, 1]$。论文原式将带噪声动作记为

$$A_t^\tau = \tau A_t + (1 - \tau)\epsilon. \tag{3.1}$$

训练前向先提取 $\phi_t = \text{Eagle2}(I_t, L)$ 和 $q_t = E_s^{(e)}(s_t)$，再由动作编码器处理 A_t^τ 与 τ；DiT 根据 Self-Attention、Cross-Attention 和时间步条件输出预测向量场。原文的 Flow Matching 损失写为

$$\mathcal{L}_{\text{fm}}(\theta) = \mathbb{E}_\tau \left[\| V_\theta(\phi_t, A_t^\tau, q_t) - (\epsilon - A_t) \|_2^2 \right]. \tag{3.2}$$

V_θ 表示主模型的预测，$(\epsilon - A_t)$ 是原文列出的监督向量。对单个 batch 计算均方误差并反向传播，从而优化 DiT、具身模块以及未被冻结的主干参数。为了增强空间定位，附录另给出可选的辅助目标检测项：对目标物体包围框中心归一化坐标 $\boldsymbol{x}_{\text{gt}}$，用 VLM 输出上接的线性头预测 $\boldsymbol{x}_{\text{pred}}$，

$$\mathcal{L}_{\text{det}} = \| \boldsymbol{x}_{\text{pred}} - \boldsymbol{x}_{\text{gt}} \|_2^2, \qquad \mathcal{L} = \mathcal{L}_{\text{fm}} + \mathcal{L}_{\text{det}}. \tag{3.3}$$

论文使用 OWL-v2 提供检测标注；没有这类标注的数据不能自动假定都计算了相同的检测损失。

原文符号的核对点。按式(3.1) 对 τ 求导得到 $\mathrm{d}A_t^\tau / \mathrm{d}\tau = A_t - \epsilon$，与式(3.2) 中的监督向量 $\epsilon - A_t$ 互为相反数；原文的正向 Euler 更新却使用 $+V_\theta$。三者的方向约定不能直接同时视作一致的 ODE。笔记保留论文原式，不擅自调整符号；实际复现必须对照原始 N1 代码中的采样时间方向、目标速度定义和积分符号。

3.3 多具身预训练

预训练使用真实机器人、仿真机器人、神经生成视频与人类运动视频的混合数据。数据源对应不同的具身标识及不同动作目标，而共享 VLM/DiT 学习条件化的动作生成规律。这种联合学习与将所有机器人动作补零拼成同维向量不同：原始状态、动作由专属 MLP 对齐到共享表征空间，输出再由专属解码器回到自身动作空间。

原论文附录给出的训练配置为：AdamW 优化器，学习率 10^{-4}，权重衰减 10^{-5}，余弦调度与 5% warmup；预训练全局 batch size 为 16,384，训练约 200,000 步。参数冻结方面，正文明确称在预训练和后训练时保持 VLM 的语言部分冻结，并微调

模型其余部分；附录表明确标出 vision encoder 为 unfrozen、DiT 为 unfrozen，而将 text tokenizer 标为 frozen。**Tokenizer 与整个语言模型不是同一层级的参数对象**，因此在复现时不能仅凭附录这一项推断语言模型所有权重的冻结配置。

3.4 面向目标任务的后训练

后训练从预训练权重出发，选择**单一机器人具身**及其目标任务的示范数据进行微调，继续使用动作生成的 Flow Matching 损失。与预训练相比，主要变化是训练数据集中在指定机器人/任务，批量大小更小，以减少低数据量环境下的过拟合。论文附录给出的后训练 batch size 为 128 或 1024，训练 20,000–60,000 步；并非每个下游任务都一定使用全部步数。

在后训练样本不足时，论文还尝试：利用少量任务演示适配视频生成模型，合成新任务轨迹，再用 LAPA 或 IDM 补充动作标签；训练时真实轨迹与神经生成轨迹按 1 : 1 的采样比例联合使用。该增强路径为**可选**，不能把“生成视频”理解为每次后训练都需要在线运行视频模型，也不能把伪动作视为等质量的真实执行数据。

3.5 哪些参数接受梯度

主训练中的动作生成损失经过具身动作解码器、DiT、动作/状态编码器传播，并在被设置为可训练时进一步传播到 VLM 的相关可训练模块；被冻结模块不更新参数。论文明确指定了视觉编码器与 DiT 的可训练状态，并说明语言部分冻结，但没有用足够精确的官方实现细节逐层列出所有 LLM 参数的冻结掩码。阅读训练代码时应以实际 `requires_grad`、优化器参数组与分布式包裹边界核对，而不应把论文架构示意图中的雪花标识直接解释成整个 VLM 在所有阶段永久冻结。

第 4 章

GR00T N1 推理流程

在线推理只使用已经训练好的 Eagle-2、DiT 和当前机器人具身的状态/动作接口。LAPA、IDM、视频生成模型负责离线提供训练目标，**不参与正常在线控制的前向链路**。推理与训练的本质区别在于：没有真实未来动作块 A_t 作为目标，模型必须从随机噪声出发，通过数次迭代生成动作块。

4.1 一次动作块预测

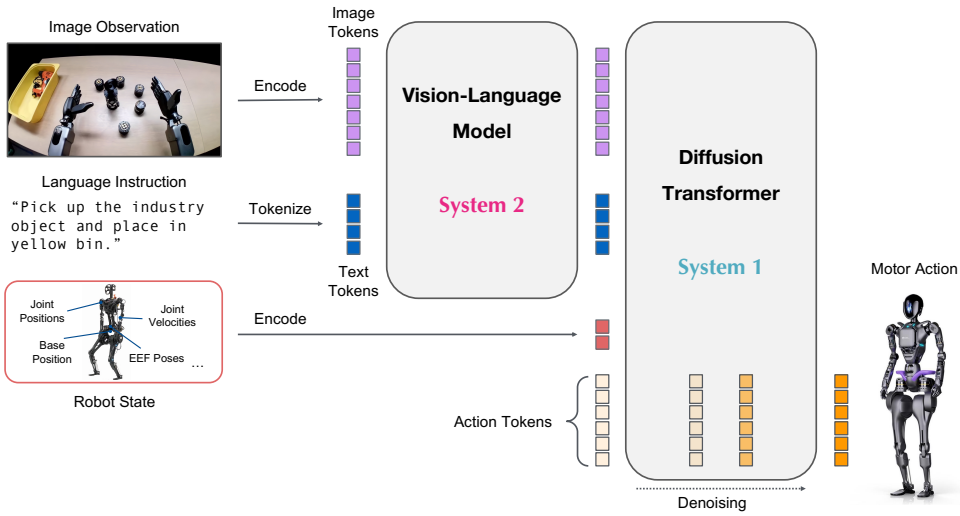


图 4.1: 论文原图：视觉/语言条件、机器人状态与动作生成网络构成一条前向推理链路。

在控制时刻 t，输入包括摄像头图像 I_t、任务语言 L 和实时机器人状态 s_t。Eagle-2 生成视觉语言特征 ϕ_t，状态编码器生成 q_t。动作生成器以形状为 $16 \times d_a$ 的高斯噪声初始化

$$A_t^0 \sim \mathcal{N}(0, I). \tag{4.1}$$

随后 DiT 循环使用当前动作估计、状态 Token、视觉语言 Token 和流匹配时间步。论文给出的采样更新为

$$A_t^{\tau+1/K} = A_t^{\tau} + \frac{1}{K} V_\theta(\phi_t, A_t^{\tau}, q_t), \qquad K = 4. \tag{4.2}$$

一次更新作用于**整段 16 步动作块**；$K = 4$ 表示网络迭代采样次数，而非只产生 4 个机器人动作。完整迭代后得到目标具身动作空间中的动作块，交给机器人控制接口。式(4.2)沿用论文原文记号；它与第 3 章指出的损失符号方向问题应在复现时一起核对。

论文报告在 L40 GPU、BF16 条件下采样包含 16 个动作的一个动作块约需 63.9ms。这个时间不是控制器执行完 16 步动作的时长，也不是整个机器人任务的完成时间。

4.2 动作块执行与闭环

设本次预测得到 $\hat{A}_t = [\hat{a}_t, \ldots, \hat{a}_{t+15}]$。执行系统需要决定从中下发多少步，再使用新的摄像头观察与本体状态重新调用模型。预测动作块的长度 16 并不自动规定控制器必须一次执行全部 16 步；**执行步数、动作缓冲和控制频率由具体部署接口决定**。论文给出动作块生成和推理延迟，但没有在主方法式中统一规定适用于全部机器人的执行跨度，故不应补写一个固定的控制调度方案。

由此，在线过程可理解为观察 → 条件动作生成 → 执行选定动作 → 再观察。闭环的作用是允许模型在后续调用中根据新的视觉与本体信息修正下一段动作，而不是一次规划并无反馈地执行完整任务。

4.3 核心推理伪代码

下列代码是与论文模型接口一致的**概念级伪代码**，省略机器人驱动、批量处理、动作归一化与详细的采样时间方向；这些步骤的具体实现以对应 N1 发布代码为准。它重点表达 VLM 条件在动作块生成中的作用、四次迭代与闭环反馈的相互关系。

```
# Conceptual pseudocode, not an official source excerpt.
H = 16
K = 4

while task_active:
    image = camera.read()
    state = robot.read_state()

    vl_tokens = eagle2_features(image, instruction)
    state_tokens = state_encoder(state, embodiment_id)

    actions = gaussian_noise(shape=(H, action_dim))
    for k in range(K):
        tau = k / K
        noised_tokens = action_encoder(
            actions, tau, embodiment_id
        )
        velocity = dit(
            noised_tokens, state_tokens, vl_tokens, tau
        )
        actions = euler_step(actions, velocity, tau)

    selected = actions[:execution_horizon]
    robot.execute(selected)
    # Read fresh observations at the next iteration.
```

其中 action_dim 取决于目标机器人动作空间；execution_horizon 是部署时选取的动作执行长度，须满足 $1 \le \text{execution_horizon} \le 16$。euler_step 需要落实与模型权重一致的时间方向和符号约定，不能只凭伪代码替代经过核对的采样实现。

参考资料

NVIDIA et al. *GR00T N1: An Open Foundation Model for Generalist Humanoid Robots*. arXiv:2503.14734v2, 原论文 §2.1–2.3 及附录中的 Dataset Formats、Standardized Action Spaces、Additional Training Details、Hyperparameters。
官方代码仓库：`https://github.com/NVIDIA/Isaac-GR00T`；原始 N1 发布版本：`https://github.com/NVIDIA/Isaac-GR00T/tree/n1-release`。正文使用的结构、公式和数字以用户提供的 v2 论文源码为准；伪代码明确按论文内容整理，并非官方代码逐行摘录。