GuidedVLA

结构化注意力引导的机器人动作生成

模型结构、监督机制与损失函数

作者：Yang kunpeng

目录

第一章 模型、监督数据与训练 **1**
1.1 动作生成结构 1
1.2 Flow Matching 与动作采样 2
1.3 Object Mask 和 Skill Label 的生成 2
1.4 训练目标与代码配置 3

第二章 注意力分工与三个核心模块 **4**
2.1 Attention Head Specialization 4
2.2 Object Head：目标区域负对数似然 4
2.3 Skill Head：动作块分布的 KL 监督 5
2.4 Depth Head：几何键值与动作梯度 6
2.5 归纳偏置、标注偏倚与泛化边界 7

第 1 章

模型、监督数据与训练

1.1 动作生成结构

GuidedVLA 建立在预训练视觉—语言—动作模型 π_0 上 [1]。输入为相机图像 I、任务指令 ℓ 和机器人状态 s，输出连续动作块 $a \in \mathbb{R}^{H \times d_a}$；$H$ 是预测步数，d_a 是单步动作维度。PaliGemma 视觉语言主干编码图像与指令，Gemma Action Expert 根据状态和带噪动作生成动作速度场。二者通过联合注意力交互，而不是先预测离散技能、再把技能送给独立控制器。

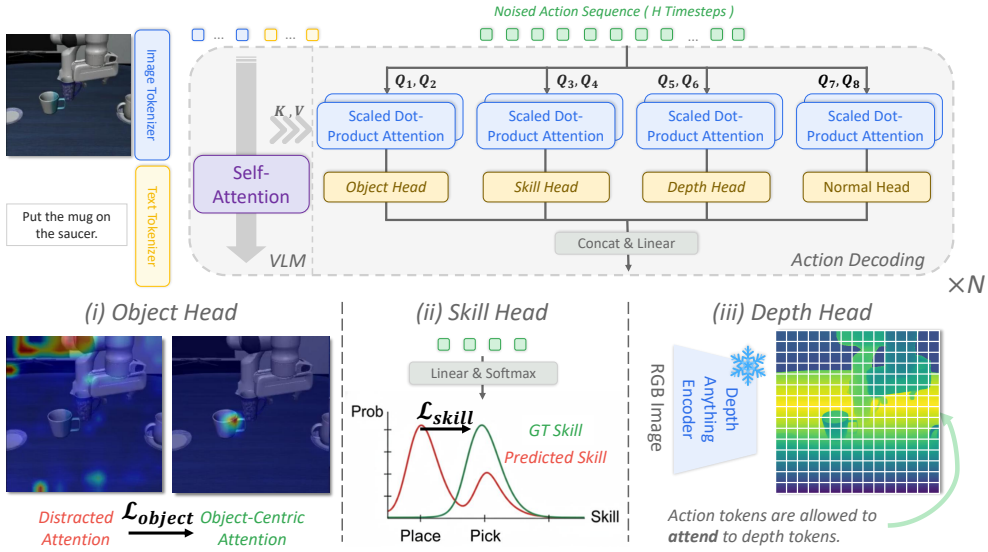


图 1.1: GuidedVLA 架构：Object、Skill 与 Depth 对动作注意力施加不同约束。

GuidedVLA 在部分 Action Expert 注意力头引入三种任务相关因素：Object 约束动作查询关注目标物体的图像区域；Skill 让头输出能够预测动作块的技能阶段分布；Depth 让指定头从冻结的空间编码器读取几何特征。三个模块不直接输出三条动作轨迹，而是共同影响同一个动作生成网络。

设批量为 B，单头隐藏维度为 d_h，动作查询数为 T_a，完整键序列长度为 T_k。一层注意力概率形状为 $[B, N_h, T_a, T_k]$，包含视觉、语言和动作等可访问的键。Object

Mask 必须与其中图像 Patch 的实际键位置对齐，而不是直接把图像 Mask 当成全部键的 Mask。

1.2 Flow Matching 与动作采样

训练时，从真实动作 a 和同形状的高斯噪声 $\epsilon \sim \mathcal{N}(0, I)$ 构造

$$x_t = (1-t)a + t\epsilon, \qquad u_t = \epsilon - a, \qquad t \sim U[0,1]. \tag{1.1}$$

$t = 0$ 对应真实动作，$t = 1$ 对应噪声。给定观测 $o = (I, \ell, s)$，动作专家预测 $v_\theta(x_t, t \mid o)$，以流匹配均方误差训练：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{o,a,t,\epsilon}\left[\|v_\theta(x_t, t \mid o) - (\epsilon - a)\|_2^2\right]. \tag{1.2}$$

因此网络不是逐步分类下一个离散 Action Token，而是一次预测整个动作块的速度张量 $[B, H, d_a]$。推理从 $x_1 \sim \mathcal{N}(0, I)$ 出发，用负步长沿 $t = 1 \to 0$ 积分：

$$x_{n+1} = x_n - \frac{1}{N} v_\theta(x_n, 1 - n/N \mid o), \qquad n = 0, \ldots, N-1. \tag{1.3}$$

N 是求解器迭代次数，不是动作块长度 H。官方推理实现复用视觉语言 Prefix KV Cache；启用 Depth Head 时，深度 KV 也可在同一个动作块的迭代计算中复用。

1.3 Object Mask 和 Skill Label 的生成

两种辅助标签均来自训练示范轨迹的离线处理，并不是推理时要求机器人先运行分割和技能识别模型。

Object Mask。示范轨迹先按操作过程分阶段，每个阶段指定任务相关物体。Qwen3-VL 根据阶段描述在起始帧给出目标点提示，SAM2 进行分割并向阶段内其余帧传播，之后人工核验。像素分割 $M^{\text{pix}}(x, y)$ 转换为视觉 Patch 标注：

$$r_p = \frac{1}{|p|} \sum_{(x,y) \in p} M^{\text{pix}}(x, y), \qquad M_p = \mathbf{1}\{r_p \geq \tau\}. \tag{1.4}$$

其中 p 是 Patch，τ 是前景占比阈值。该设置使用 16×16 Patch 网格，单视角对应 256 个标记。遮挡、阶段切换或目标选择错误会影响监督，因而标注的阶段相关性是 Object Loss 的前提。

Skill Soft Label。 Qwen3-VL 根据预定义技能表及阶段描述分配离散 Skill ID，经核验后扩展到各时间步。对未来 T 步标签 $s_1, \ldots, s_T$，统计类别频率

$$c_k = \sum_{t=1}^{T} \mathbf{1}\{s_t = k\}, \qquad y_k = \frac{c_k}{\sum_{j=0}^{K_s-1} c_j}, \quad k = 0, \ldots, K_s - 1. \tag{1.5}$$

$y \in \mathbb{R}^{K_s}$ 是动作块级经验分布，不是 Qwen3-VL 的输出置信度。官方数据变换使用直方图计数与归一化来构造该标签。LIBERO 配置使用 $K_s = 4$（三个有效任务级类别及一个背景/空标签）；四个数字类别与具体技能名称之间没有公开的完整统一映射。比如标签 $(0, 0, 1, 1)$ 与 $(1, 1, 0, 0)$ 都产生 $y = (.5, .5, 0, 0)$：这一监督保留比例，但丢失顺序。

1.4 训练目标与代码配置

模型同时优化动作速度和两个辅助目标：

$$\mathcal{L} = \mathcal{L}_{\text{FM}} + \lambda_o \mathcal{L}_{\text{object}} + \lambda_s \mathcal{L}_{\text{skill}}. \tag{1.6}$$

Depth Head 没有独立的 Depth Loss，而是沿动作预测计算图由 $\mathcal{L}_{\text{FM}}$ 等适用梯度更新可训练投影。Depth Anything 3 编码器保持冻结；Qwen3-VL、SAM2 只生产训练标签，不参加反向传播。物体损失只在存在有效目标区域的样本上计算。

官方完整 LIBERO 配置使用引导层索引 $[9, 10, 11, 12]$，Object、Depth、Skill 的 Head 索引依次为 $[0, 1]$、$[4, 5]$、$[6, 7]$，且 $\lambda_o = \lambda_s = 0.001$。Object、Skill 在主注意力分支接受监督；Depth 在控制分支读取几何特征。

两阶段训练先微调 π_0，再加入结构化引导；公开默认配置则直接加载 `pi0_base`，未自动串联两阶段，复现时须指定相应初始权重。推理不需要 Mask、Skill 标签、Qwen3-VL 或 SAM2，但启用 Depth 时须运行冻结的深度编码器。

第 2 章

注意力分工与三个核心模块

2.1 Attention Head Specialization

对动作查询，单个注意力头的基本运算为

$$P_h = \mathrm{softmax}\left(\frac{Q_h K_h^\top}{\sqrt{d_h}} + C_h\right), \qquad A_h = P_h V_h. \tag{2.1}$$

$Q_h \in \mathbb{R}^{B\times T_a\times d_h}$，$K_h, V_h \in \mathbb{R}^{B\times T_k\times d_h}$，$C_h$ 是可见性 Mask。普通多头注意力没有规定每个头必须学习何种信息。GuidedVLA 则为 Object、Skill、Depth 分配互不重叠的头集合 $\mathcal{H}_o, \mathcal{H}_s, \mathcal{H}_d$：Object 使用概率 P_h，Skill 使用聚合特征 A_h，Depth 使用不同来源的 K, V。这三条路径的监督对象并不相同。

论文还采用 ControlNet 式残差注入 [2]，其概念形式是

$$A_{\text{out}} = A_{\text{main}} + W_0 A_{\text{guided}}, \qquad W_0 \text{ 初始为零}. \tag{2.2}$$

零初始化使引导分支初始时不改变主分支前向输出，随后通过学习 W_0 逐步注入新特征。这是残差引导的概念结构。LIBERO 配置中 Object 和 Skill 的辅助损失来自主分支，Depth 使用控制分支。

2.2 Object Head：目标区域负对数似然

设 $P_{b,h,t,k}$ 为第 b 个样本、Object Head h、动作查询 t 对完整键轴位置 k 的概率；$M_{b,k} \in \{0,1\}$ 表示目标物体对应的 Patch。先对 Object Heads 平均，再求落在目标区域内的概率质量：

$$\bar{P}_{b,t,k} = \frac{1}{|\mathcal{H}_o|}\sum_{h\in\mathcal{H}_o} P_{b,h,t,k}, \qquad m_{b,t} = \sum_{k=1}^{T_k} \bar{P}_{b,t,k} M_{b,k}. \tag{2.3}$$

若 M 为二值 Mask，$m_{b,t}$ 表示一个按注意力分布抽取的键落在目标物体中的概率。最大化该事件的似然等价于最小化

$$\mathcal{L}_{\text{object}} = -\frac{1}{\sum_b v_b\, T_a} \sum_b v_b \sum_{t=1}^{T_a} \log\big(\max(m_{b,t}, \epsilon)\big), \tag{2.4}$$

其中 v_b 表示存在有效目标 Mask，ϵ 避免 $\log 0$。只约束目标区域的概率总量，不规定区域内部哪个 Patch 应获得最大注意力。

该 Loss 的方向可由 Softmax 梯度直接验证。在单头、单查询、二值 Mask 情形下，令 $p_i = \text{softmax}(z)_i$、$m = \sum_i p_i M_i$，有

$$\frac{\partial m}{\partial z_j} = p_j(M_j - m), \tag{2.5}$$

$$\frac{\partial(-\log m)}{\partial z_j} = p_j - \frac{p_j M_j}{m}. \tag{2.6}$$

若 $M_j = 0$，梯度为正，梯度下降压低背景分数；若 $M_j = 1$ 且 $m < 1$，梯度为负，提升目标分数。例如 $p = (.1, .2, .2, .5)$、$M = (1, 1, 0, 0)$ 时，$m = .3$，单查询 Loss 为 $-\log .3 \approx 1.204$。这种概率监督无法自行校验 Mask 是否选对了物体。

实现时必须先对完整键序列做 *Softmax*，再取对应图像位置的概率。若把抽取的图像概率重新归一化，文本和其他键占据的质量会被抹除，优化目标随之改变。下列为与上述公式对应的最小 PyTorch 计算（P 已取出图像位置，未重新归一化）：

```
# P: [B, Ho, A, V, 256]; M: [B, V, 256]
mask = M[:, None]                              # [B,1,V,256]
mass = (P.mean(1) * mask).sum((-1, -2))   # [B,A]
valid = M.sum((-1, -2)) > 0               # [B]
loss_object = -mass[valid].clamp_min(1e-6).log().mean()
```

空有效集合需单独跳过损失；实际工程还要应用视角有效标志并对受监督层聚合。

2.3 Skill Head：动作块分布的 KL 监督

Skill Head 不使用 P_h 的空间概率直接做分类，而是取指定头对 *Value* 加权后的输出特征。记第 ℓ 层、头 h、动作查询 t 的特征为 $f_{b,\ell,h,t} \in \mathbb{R}^{d_h}$。论文在受监督层、Skill Heads 和动作查询维度上平均：

$$\bar{f}_b = \frac{\sum_{\ell\in\mathcal{L}_g} \sum_{h\in\mathcal{H}_s} \sum_{t=1}^{T_a} f_{b,\ell,h,t}}{|\mathcal{L}_g|\,|\mathcal{H}_s|\,T_a}, \qquad \hat{p}_b = \text{softmax}(W\bar{f}_b + q). \tag{2.7}$$

$W \in \mathbb{R}^{K_s \times d_h}$、$q \in \mathbb{R}^{K_s}$ 是分类器参数，$\hat{p} \in \mathbb{R}^{B \times K_s}$。监督目标 y 是式(1.5)由未来动作窗口生成的技能频率，Loss 为

$$\mathcal{L}_{\text{skill}} = \frac{1}{B}\sum_{b=1}^{B} D_{\text{KL}}(y_b \| \hat{p}_b) = \frac{1}{B}\sum_{b}\sum_{k=0}^{K_s-1} y_{b,k} \log \frac{y_{b,k}}{\hat{p}_{b,k}}. \tag{2.8}$$

对 $y_k = 0$ 的项取极限值 0。恒等式 $D_{\text{KL}}(y\|\hat{p}) = H(y,\hat{p}) - H(y)$ 表明：在目标分布固定时，最小化 KL 等价于最小化软标签交叉熵。对分类器 Logit z_k，

$$\frac{\partial \mathcal{L}_{\text{skill}}}{\partial z_k} = \hat{p}_k - y_k \tag{2.9}$$

（式中省略批量平均因子）。预测某类的概率低于真实占比时，梯度下降会提高相应 Logit。梯度继而沿 W、$\bar{f}$ 返回相关可训练的注意力参数。

F.kl_div 接收的是对数预测概率和普通目标概率，不能调换两者位置：

```
# logits [B,K]; soft_label [B,K]
logp = torch.nn.functional.log_softmax(logits.float(), dim=-1)
loss_skill = torch.nn.functional.kl_div(
    logp, soft_label, reduction="batchmean")
```

Skill Loss 监督的是动作块内类别所占比例，不是逐时间步的类别顺序；它也没有把连续控制转换成固定的四种离散动作。动作时序仍由 Flow Matching 主目标学习。

2.4 Depth Head：几何键值与动作梯度

Depth Head 从冻结的 Depth Anything 3 编码器 [3] 抽取 $F_d \in \mathbb{R}^{B \times T_d \times d_d}$，经可训练线性投影形成专用深度键值：

$$K_d = W_K \,\text{Norm}(F_d), \qquad V_d = W_V \,\text{Norm}(F_d). \tag{2.10}$$

张量重排后 $K_d, V_d \in \mathbb{R}^{B \times |\mathcal{H}_d| \times T_d \times d_h}$；动作查询 $Q_{\text{act}} \in \mathbb{R}^{B \times |\mathcal{H}_d| \times T_a \times d_h}$ 读取

$$A_d = \text{softmax}\left(\frac{Q_{\text{act}} K_d^{\top}}{\sqrt{d_h}}\right) V_d. \tag{2.11}$$

深度键长 T_d 无须等于普通键长 T_k，因为两种注意力聚合后都输出 $[B, |\mathcal{H}|, T_a, d_h]$ 特征。Depth Head 没有深度预测误差项；主任务动作梯度通过 A_d 更新 W_K, W_V 及相连的可训练网络，冻结的深度编码器权重不更新。

区别于训练期的 Qwen3-VL、SAM2，Depth Anything 3 在启用 Depth Head 的推理中仍需前向，因而增加模型计算与显存消耗。是否符合实际控制频率必须测量端到端时延，不能用机器人底层控制指令发送频率替代模型推理速度。

2.5 归纳偏置、标注偏倚与泛化边界

表 2.1: 结构化引导的先验条件及潜在局限

问题	机制	边界与风险
归纳偏置	Object、Skill、Depth 专用头优先学习预设的任务因素。	预设因素可能不能覆盖未见操作中的关键变量；不等于已经观察到失败。
标注偏倚	Qwen3-VL 选择阶段目标及 Skill ID；SAM2 分割并传播物体区域。	错误目标、阶段边界和 Mask 会产生系统性的辅助监督误差。
数据集偏倚	示范轨迹的物体、场景与技能种类覆盖有限。	同任务的布局、背景变化测试不能替代未见物体类别与未见技能测试。
几何先验偏差	Depth Head 依赖冻结深度编码器的特征。	透明、反光、遮挡等场景可能造成几何表征误差；在线推理有额外计算开销。
泛化证据边界	已有测试强调任务内扰动和特定环境随机化。	开放世界泛化仍需跨物体类别、跨技能的独立测试；不能由现有结果直接推出。

参考文献

[1] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0: A vision-language-action flow model for general robot control. In *RSS*, 2025.

[2] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 3836–3847, 2023.

[3] Haotong Lin, Sili Chen, Jun Hao Liew, Donny Y. Chen, Zhenyu Li, Guang Shi, Jiashi Feng, and Bingyi Kang. Depth anything 3: Recovering the visual space from any views. *arXiv preprint arXiv:2511.10647*, 2025.