

Tactile-VLA

从多模态前缀到力控制与 OOD 泛化

个人学习笔记

核心主线: S_t 多模态融合 $\rightarrow$ tactile-aware action expert $\rightarrow (P_{\text{target}}, F_{\text{target}}) \rightarrow$
hybrid controller

前言

这份笔记按照三个问题组织 Tactile-VLA：模型是什么样；关键公式和训练目标如何理解；数据与实验如何验证“触觉泛化”这个核心主张。CFM 部分只保留 Tactile-VLA 明确给出的训练设定，并用 π_0 的标准 Flow Matching 定义补足数学背景。

一句话概括。 Tactile-VLA 在 π_0 风格 VLA 上加入触觉历史，将视觉、语言和触觉统一成 prefix sequence，再让 tactile-aware action expert 同时生成运动学目标与目标接触力；低层 hybrid position-force controller 把目标力转成位置修正，从而让 VLM 中的语言/物体语义知识真正落到力控制上。




图 1: Tactile-VLA 概览：语言力度泛化、隐式物理常识和触觉参与的失败推理。

符号约定

符号	含义
t	真实机器人控制时间步
H	Tactile-VLA 输入端使用的历史窗口长度；论文未给出具体数值
I_t	时刻 t 的视觉图像
T_t	时刻 t 的触觉/力信号
L_t	当前语言指令
E'_{vis}	预训练 ViT 视觉编码器
E'_{ψ}	触觉编码器，论文描述为简单 MLP
S_t	视觉、语言、触觉 token 拼接后的统一 prefix sequence
P_{target}	action expert 预测的目标位置
F_{target}	action expert 预测的目标接触力
ΔF	力误差 $F_{\text{target}} - F_{\text{measured}}$
K	hybrid controller 的 gain matrix
τ	hybrid controller 中的力误差死区阈值；注意它与 Flow Matching 时间变量不是同一个 τ
$\mathbf{A}_t$	π_0 中的 action chunk；Tactile-VLA 将 force dimension 一并纳入 action space
τ_{fm}	本笔记用于表示 Flow Matching 的连续时间，以避免和控制器阈值 τ 混淆

目录

前言	ii
符号约定	iii
第一章 模型架构	1
1.1 整体结构：从多模态输入到物理动作	1
1.2 Tactile-VLA-CoT：在失败后显式推理	2
第二章 关键公式： S_t 、Hybrid Controller 与 Loss	4
2.1 Prefix sequence S_t 的定义	4
2.2 从 prefix 到 force-aware action	5
2.3 Hybrid Position-Force Controller	5
2.4 Conditional Flow Matching：训练目标怎么理解？	6
2.5 π_0 的 Conditional Flow Matching Loss	6
2.6 CFM 到 Tactile-VLA：force dimension 被一起建模	7
第三章 数据采集、实验设置与基线模型	8
3.1 数据采集：为什么普通 teleoperation 不够？	8
3.2 实验问题与基线模型	9
3.3 三组任务与训练数据规模	10
3.4 实验一：Tactile-Relevant Instruction Following	10
3.5 实验二：Tactile-Relevant Common Sense 与 OOD 物体	11
3.6 实验三：Tactile-Involved Reasoning	13
3.7 复现时仍缺少的关键参数	13
整条主线总结	15

模型架构

1.1 整体结构：从多模态输入到物理动作

问题：Tactile-VLA 相比普通 VLA 到底多了什么？

普通 VLA 的核心是

$$(\text{vision}, \text{language}) \longrightarrow \text{action}.$$

Tactile-VLA 把触觉作为原生输入模态，并把 force 直接放入动作输出，因此主链变成

$$\begin{aligned} &(\text{vision history}, \text{language}, \text{tactile history}, \text{proprioception}) \\ &\longrightarrow (P_{\text{target}}, F_{\text{target}}) \longrightarrow P_{\text{hybird}}. \end{aligned}$$




图 1.1: Tactile-VLA 架构图。原图标注了预训练 VLM（Gemma 2.6B）与 tactile-aware action expert（300M），并展示视觉、语言、触觉和 proprioceptive state 的独立编码入口。

模块逐层看。


- 1. 视觉分支：最近 H 帧图像分别通过 ViT 编码，每一帧形成一组视觉 token。

2. **语言分支**: 语言指令通过 tokenizer 形成 language tokens。
3. **触觉分支**: 最近 H 个触觉测量先拼接, 再由一个 MLP 编成单个 fused tactile token, 用于表示短期接触动态。
4. **Transformer trunk**: prefix 内采用 non-causal attention, 视觉、语言和触觉 token 可以自由 cross-attend。
5. **Tactile-aware action expert**: 产生增强动作, 显式包含目标位置与目标接触力。
6. **Hybrid controller**: 不直接把网络输出的力值当成电机命令, 而是依据力误差修正位置目标, 再由 PID 驱动关节。

直觉: 高层模型回答“应该怎样接触”; 低层控制器负责“怎样稳定地实现这个接触”。这把语义理解与实时反馈控制分开。

1.2 Tactile-VLA-CoT: 在失败后显式推理

Tactile-VLA-CoT 在基础架构上再利用 VLM 自己的预训练 decoder 产生显式 reasoning。触觉不再只是 policy observation, 还被当成判断失败原因的证据。其流程是: 固定间隔触发检查 → 判断任务是否成功 → 若失败则分析不同力分量 → 生成新的 corrective instruction → 再执行。



Human: “Clean the blackboard.”

Q: Has the board been cleaned up?

A: Nope. There still remains some markings.

Q: What should I do next?

A: Shear force should be larger, while normal force is sufficient.

图 1.2: Tactile-VLA-CoT 在擦板任务中的 reasoning / replanning 流程。

易错点：论文写的是“fixed intervals”触发 CoT，而不是一个连续运行的 failure detector。因此更准确地说，它是周期性高层重规划，而非每个控制周期都进行语言推理。

关键公式： S_t 、Hybrid Controller 与 Loss

2.1 Prefix sequence S_t 的定义

论文把统一输入前缀写为

$$S_t = [E'_{vis}(I_{t-H+1}), \dots, E'_{vis}(I_t), E_{\text{lang}}(L_t), E'_\psi([T_{t-H+1}, \dots, T_t])] \quad (2.1)$$

问题：这串式子到底在做什么？

它做的不是复杂运算，而是把三种模态都变成 Transformer 能接收的 token，然后按顺序拼成一个 prefix。

如果 $H = 4$ ，则视觉部分就是

$$E'_{vis}(I_{t-3}), E'_{vis}(I_{t-2}), E'_{vis}(I_{t-1}), E'_{vis}(I_t),$$

而触觉部分先形成

$$[T_{t-3}, T_{t-2}, T_{t-1}, T_t],$$

再一次送入 E'_ψ 。

视觉和触觉历史的处理不同。 视觉是“每一帧分别编码”，触觉是“先把 H 帧拼起来，再整体编码”。因此触觉 token 更像一个短时间窗内的动态摘要，例如压力从小到大、剪切力是否出现持续变化等。

$$\underbrace{I_{t-H+1:t}}_{\text{逐帧 ViT}} + \underbrace{L_t}_{\text{language tokens}} + \underbrace{T_{t-H+1:t}}_{\text{拼接后 MLP}} \longrightarrow S_t.$$

自检： S_t 是模型 “做动作前拥有的多模态上下文”，不是最终动作。真正动作还要经过 Transformer trunk 和 action expert 才产生。

2.2 从 prefix 到 force-aware action

论文明确写到 tactile-aware action expert 输出增强动作向量，其中显式包含

$$a_t \supset (P_{\text{target}}, F_{\text{target}}). \quad (2.2)$$

这里的 P_{target} 表示期望运动学目标， F_{target} 表示期望接触力。二者都来自 expert demonstrations 的监督。

2.3 Hybrid Position-Force Controller

网络产生 P_{target} 和 F_{target} 后，先计算

$$\Delta F = F_{\text{target}} - F_{\text{measured}}. \quad (2.3)$$

然后使用分段控制律：

$$P_{\text{hybird}} = P_{\text{target}} + \begin{cases} K \cdot \Delta F & \text{if } \|\Delta F\| > \tau \\ \mathbf{0} & \text{if } \|\Delta F\| \leq \tau \end{cases} \quad (2.4)$$

问题：为什么要做成分段函数？

τ 相当于 deadband (死区)。若力误差很小，就允许它存在，不做位置补偿；若误差超过阈值，才用 $K\Delta F$ 改位置。这样可以避免传感器小波动导致机器人不停抖动修正。

两个独立力控制通道。 论文进一步把力分成两类：

- **net external force:** 通过 gripper 的 Cartesian position 调节，例如向桌面多压一点来增大法向力；
- **internal grasping force:** 通过 gripper width 调节，决定物体被夹持得多紧。

随后 PID 控制器将动态更新后的 P_{hybird} 转成关节执行命令。

2.4 Conditional Flow Matching: 训练目标怎么理解？

问题： Tactile-VLA 的训练目标展开到了什么程度？

训练描述明确给出：共享组件从预训练 π_0 初始化；新加入的 tactile encoder 和 modified action expert 随机初始化；整个模型用 imitation learning 做 end-to-end finetuning, 并采用 Conditional Flow Matching (CFM) objective, loss 同时约束 action sequence 中的 kinematic dimensions 和 force dimensions。

这里没有进一步展开具体 CFM 公式，所以接下来直接沿用 π_0 的标准 CFM 定义来理解这一训练目标。

2.5 π_0 的 Conditional Flow Matching Loss

π_0 用 CFM 建模条件动作分布 $p(\mathbf{A}_t \mid o_t)$ 。设 clean expert action chunk 为 $\mathbf{A}_t$ ，高斯噪声为

$$\epsilon \sim \mathcal{N}(0, I),$$

Flow Matching 连续时间记作 $\tau_{\text{fm}} \in [0, 1]$ 。线性路径可写为

$$\mathbf{A}_t^{\tau_{\text{fm}}} = \tau_{\text{fm}} \mathbf{A}_t + (1 - \tau_{\text{fm}}) \epsilon. \quad (2.5)$$

因此对 τ_{fm} 求导得到目标速度场

$$\frac{d\mathbf{A}_t^{\tau_{\text{fm}}}}{d\tau_{\text{fm}}} = \mathbf{A}_t - \epsilon. \quad (2.6)$$

原始 π_0 的 CFM 目标可写成

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E} \left[\|\mathbf{v}_\theta(\mathbf{A}_t^{\tau_{\text{fm}}}, o_t, \tau_{\text{fm}}) - (\mathbf{A}_t - \epsilon)\|_2^2 \right]. \quad (2.7)$$

更一般地，可以把它理解成预测 velocity field $\mathbf{v}_\theta$ 去拟合条件 vector field $\mathbf{u}$ 。

直觉： CFM 不直接问“最终动作是多少”，而是反复问“当前 noisy action 应该朝哪个方向移动”。推理时从高斯噪声开始，沿学到的 velocity field 积分，最终得到 action chunk。

符号冲突要特别小心。 π_0 的 action chunk horizon 也常写 H (典型配置为 50), 而 Tactile-VLA 又用 H 表示视觉/触觉历史窗口。这里最好把它们记成 H_{act} 和 H_{hist} , 避免误认为是同一个量。

2.6 CFM 到 Tactile-VLA: force dimension 被一起建模

Tactile-VLA 的关键变化是动作空间不再只有运动学量, 而是把力维度加入动作序列。概念上可以写成

$$\mathbf{A}_t = [\mathbf{A}_t^{\text{kin}}, \mathbf{A}_t^{\text{force}}]. \quad (2.8)$$

于是同一套 CFM 速度回归同时覆盖两部分。为了解释, 可以把式(2.7) 的平方误差拆成

$$\mathcal{L}_{\text{CFM}} \approx \mathcal{L}_{\text{kin}} + \mathcal{L}_{\text{force}}, \quad (2.9)$$

但这只是教学上的拆解。**Tactile-VLA** 论文没有报告两部分是否使用独立权重, 也没有给出 $\lambda_{\text{kin}}, \lambda_{\text{force}}$ 等超参数。

表 2.1: Tactile-VLA 的训练设定与 π_0 CFM 定义之间的对应关系。

项目	Tactile-VLA 中明确的设定	π_0 CFM 定义
训练范式	imitation learning + end-to-end finetuning	–
基础初始化	shared components from pre-trained π_0	–
新模块初始化	tactile encoder、modified action expert 随机初始化	–
目标函数名称	Conditional Flow Matching	–
监督范围	kinematic + force dimensions	–
CFM 数学公式	未展开	式(2.5)–(2.7)
kin/force 权重	未说明	不应自行假定
action horizon、优化器、LR、batch size	未完整说明	不应自行假定

数据采集、实验设置与基线模型

3.1 数据采集：为什么普通 teleoperation 不够？

论文的核心判断是：如果人类示范者在 teleoperation 时没有直接 force feedback，那么人的动作本身就不是根据触觉闭环产生的。即使事后把传感器数值记录下来，也很难期待 policy 真正学到“依赖触觉改变动作”的关系。

因此在 Universal Manipulation Interface (UMI) 基础上改造了便携式采集装置，在 gripper 上增加双高分辨率触觉传感器，用于捕获 normal force 与 shear force，使示范本身受到接触力反馈影响。




图 3.1: 数据采集装置：GoPro camera、3D printed gripper 与 tactile sensor。

时间同步。 采集前对各数据流时间戳对齐；触觉以 100 Hz 采集，视觉以 20 Hz 采集，再把高频 tactile signal 下采样并与相应视觉帧对齐。最后形成同步的 VLA-T 数据：

vision + language + tactile + action trajectories.

3.2 实验问题与基线模型

论文用三个 Research Questions 组织实验：

1. **RQ1:** force-related language 能否跨任务泛化？
2. **RQ2:** 能否利用 VLM commonsense 给陌生物体推断合理抓力？
3. **RQ3:** 触觉反馈能否支持失败推理并自动调整 force strategy？

表 3.1: 论文使用的比较方法。

模型	定位	tactile-fusion	reasoning
π_0 -base	通用 VLA flow model, 主要外部 baseline	无 本文 fusion	tactile- 否
π_0 -fast	论文称为 π_0 -base 的一个变体；正文 implementation details 未进一步展开具体配置	无 本文 fusion	tactile- 否
Tactile-VLA	本文主方法	有	否
Tactile-VLA-CoT	本文 reasoning 变体, 更准确地属于增强版 / ablation comparison	有	有

易错点：不要把 Tactile-VLA-CoT 当成外部 baseline。它是作者自己的增强版本，用来回答 RQ3。

3.3 三组任务与训练数据规模

表 3.2: 正文明确给出的训练示范数量。

任务	训练数据	关键控制变量
USB / Charger 插拔	USB soft 100; USB hard 100; Charger basic motion 100	Charger 训练时不给 force-related language，用来测跨任务语言力度 zero-shot transfer
Tabletop grasping	6 个 ID 物体，每个 50 demonstrations，共 300	测试再引入 6 个未见 OOD 物体
Wiping the Board	Whiteboard success 100 + failure 100	Blackboard wiping 训练中从未出现，测试 failure reasoning / force adaptation

按各任务给出的数字逐项相加，这三组实验涉及约 800 条 demonstrations；但没有明确说明这些数据是否被合成一个统一训练集联合训练，实验叙述更像是围绕不同任务分别组织训练/评估。因此不应简单把“800 条”理解成单一模型的一次统一训练集规模。

3.4 实验一：Tactile-Relevant Instruction Following




图 3.2: 实验任务：(a) Charger/USB 插拔；(b) 抓取任务中的部分 ID 物体。

训练阶段，Task A (USB) 显式给 force adverbs，例如 *softly* / *hard*；Task B (Charger) 只给 kinematic demonstrations，不给与 force 有关的语言。测试时再要求 Charger 执行 *softly* / *hard*，从而检验语言语义是否能迁移到新的物理任务。

评价指标是：**Success Rate** 和 **Applied Insertion Force (N)**。

表 3.3: USB / Charger 成功率 (%)。

Model	USB	Charger
π_0 -base	5	40
π_0 -fast	0	25
Tactile-VLA	35	90

表 3.4: 不同语言指令下的施加力 (N)。

Model	softly	hard	gently	firmly	rigidly	harder	Charger softly	Charger hard
π_0 -base	2.41	2.68	2.35	2.72	2.53	2.29	6.61	5.69
π_0 -fast	2.61	2.33	2.79	2.45	2.26	2.58	7.37	6.42
Tactile-VLA	0.51	2.57	0.75	1.98	2.42	2.94	4.68	9.13

这里最重要的并不是某个绝对 Newton 数，而是 learned / unseen adverbs 在力大小上形成合理排序，并且 *softly/hard* 能从 USB 迁移到 Charger。

3.5 实验二：Tactile-Relevant Common Sense 与 OOD 物体

作者把物体按物理属性分成三类：

Solid & Heavy / Solid & Light / Fragile & Light.

训练物体 (ID) 与测试新增物体 (OOD) 如下。

表 3.5: 抓取任务的 ID / OOD 划分。

类别	ID (训练可见)	OOD (训练未见)
Solid & Heavy	Iron cube, Battery	Nail, Steel Ball
Solid & Light	Wood block, Charger	Plastic, Toy
Fragile & Light	Pitaya, Melon	BlueBerry, PaperBox

成功定义为：**single attempt securely lifted** 且没有 **observable deformation**。每个物体成功率由 10 次 trial 计算；力值图中每根柱是 5 次 trial 的均值，误差线为标准差。

表 3.6: 各物体抓取成功率 (%)，每个物体 10 trials。

Model	Solid & Heavy				Solid & Light				Fragile & Light			
	Iron cube	Battery	Nail	Steel Ball	Wood block	Charger	Plastic	Toy	Pitaya	Melon	BlueBerry	PaperBox
π_0 -base	100	80	30	60	60	70	40	30	50	0	0	0
π_0 -fast	70	60	10	70	70	50	30	40	40	10	0	0
Tactile-VLA	100	90	100	90	90	100	80	90	90	80	100	90




图 3.3: 各类物体的平均抓取力，用于比较 heavy / light / fragile 类别的力尺度以及 ID 到 OOD 的泛化。

直觉: OOD 的重点不是“物体长得完全随机”，而是训练时没见过具体实例，但它与训练物体共享可由 VLM 语义理解的物理属性。作者借此测试是否能把“BlueBerry 很脆弱”“Steel Ball 较重”这类视觉语言先验映射成合理力。

3.6 实验三：Tactile-Involved Reasoning

训练只在 whiteboard wiping 上进行，数据包含 100 成功和 100 失败示范。失败案例配 supervisory reasoning text，例如指出 “force too light, 需要更强 force”，用于训练 CoT reasoning 模块。测试时换成训练阶段从未出现的 blackboard + chalk。




图 3.4: 从 whiteboard 到 blackboard 的 zero-shot reasoning transfer: 第一次力不足, 随后根据触觉反馈增大压力并完成擦除。

表 3.7: Whiteboard (ID) 与 Blackboard (OOD) 成功率 (%)。

Model	Whiteboard (ID)	Blackboard (OOD)
π_0 -base	40	0
π_0 -fast	45	0
Tactile-VLA	80	15
Tactile-VLA-CoT	75	80

Blackboard zero-shot 中，第一次使用默认 3.5 N 失败；CoT 判断需要更大力后提高到 6.7 N。6.7 N 比 whiteboard training 中相关尝试的 5 N 高 34%，说明这里不是简单复制训练力值，而是根据新场景继续适应。

3.7 复现时仍缺少的关键参数

整体方法已经比较清楚，但要严格复现仍有一些关键参数没有完整给出：

- 历史窗口 H 的具体取值；
- tactile MLP 的层数、hidden dimension；

- optimizer、learning rate、batch size、训练 steps / epochs;
- force dimension 与 kinematic dimension 在 CFM loss 中是否有独立权重;
- hybrid controller 中 K 与 deadband τ 的具体数值;
- action horizon、推理时 CFM integration 配置是否完全沿用 π_0 ;
- π_0 -fast baseline 的具体实现/配置在正文 implementation details 中没有展开。

易错点：因此，这篇论文足以理解“方法思想和实验逻辑”，但并不足以仅凭正文做到无歧义工程复现。

整条主线总结

Tactile-VLA 的核心不是简单地“给 VLA 加一个传感器”，而是构造一条从语义先验到物理力控制的通路：

$$\begin{aligned} \text{Vision + Language + Tactile History} &\rightarrow S_t \\ &\rightarrow \text{Transformer / Action Expert} \\ &\rightarrow (P_{\text{target}}, F_{\text{target}}) \rightarrow P_{\text{hybird}} \end{aligned}$$

训练时采用从 π_0 继承的 Conditional Flow Matching 思路，并把 force dimension 纳入 action sequence；但具体 loss 公式和训练超参数没有进一步展开。实验则通过三类 OOD/generalization 逐层验证：**语言词泛化、物体物理常识泛化、失败后的 tactile reasoning 与 force adaptation。**

自检：最值得记住的三个公式是：prefix S_t （多模态上下文）、 $\Delta F = F_{\text{target}} - F_{\text{measured}}$ 与 P_{hybird} （力到位置的闭环修正）、以及 π_0 CFM velocity regression（动作 + 力的生成式训练）。