

# 从加噪到反向生成

**Score Matching 推导**

**–作者: Yang kunpeng**

算法核心：训练时从已知数据构造可计算的条件去噪目标，  
学到随时间变化的边缘得分函数，再用它定义反向扩散过程。

# 前言

---

**生成模型的目标。** 设真实数据来自未知的数据分布

$$\mathbf{Z} \sim p_{\text{data}}.$$

生成模型的目标不是复现某一个固定训练样本，而是构造一个可计算的采样过程，使新的样本仍然服从目标数据分布。训练数据集只提供来自  $p_{\text{data}}$  的有限样本，通常并不给出  $p_{\text{data}}(\mathbf{x})$  的解析表达式。

**扩散模型的路线。** 扩散模型先规定一个从数据到噪声的正向随机过程，将复杂的数据分布逐渐变为容易采样的简单噪声分布。训练阶段利用这一已知的加噪机制构造监督信号，学习每个噪声水平上的得分函数 (score function)；生成阶段再把学到的得分函数代入反向随机动力学，从噪声逐步恢复数据。

全书沿以下逻辑展开：

$$\begin{aligned} p_{\text{data}} &\longrightarrow \text{Gaussian 加噪} \longrightarrow \mathbf{X}_t \longrightarrow p_t \longrightarrow \text{score}, \\ \text{score} &\longrightarrow \text{Denoising Score Matching} \longrightarrow \text{reverse-time SDE} \longrightarrow p_{\text{data}}. \end{aligned}$$

**正文与数学附录的分工。** 正文只保留扩散模型本身需要的定义、推导与训练/采样关系。概率论、向量微积分、Brownian motion、SDE、Fokker–Planck equation 与时间反演所需的数学基础集中放在附录；正文第一次使用相关工具时给出交叉引用。这样可以连续阅读算法主线，也可以在需要时返回附录补充数学细节。

**本书的范围。** 本书聚焦连续状态空间中的 Gaussian 扩散模型与 score-based diffusion 的基础理论，不展开 classifier-free guidance、latent diffusion、DiT 或离散扩散模型。相关主题可以在掌握本书主线后单独学习。

# 符号约定

| 符号                                         | 含义                                                                            |
|--------------------------------------------|-------------------------------------------------------------------------------|
| $\mathbf{Z}$                               | 数据随机变量, 满足 $\mathbf{Z} \sim p_{\text{data}}$                                  |
| $z$                                        | 一次具体采样得到的干净数据样本                                                               |
| $\epsilon$                                 | 标准 Gaussian 随机噪声, $\epsilon \sim \mathcal{N}(0, \mathbf{I})$                  |
| $t$                                        | 扩散时间; 本书采用 $t = 0$ 为数据、 $t$ 增大为噪声的约定                                          |
| $\mathbf{X}_t$                             | 时刻 $t$ 的随机 noisy state                                                        |
| $\mathbf{x}_t$                             | 一次具体采样得到的 noisy sample                                                        |
| $p_t(\mathbf{x} \mid \mathbf{z})$          | 给定干净数据 $\mathbf{z}$ 后, 时刻 $t$ 的条件加噪密度                                         |
| $p_t(\mathbf{x})$                          | 对数据分布边缘化后的 noisy marginal density                                             |
| $\mathbf{s}_t(\mathbf{x} \mid \mathbf{z})$ | conditional score, $\nabla_{\mathbf{x}} \log p_t(\mathbf{x} \mid \mathbf{z})$ |
| $\mathbf{s}_t(\mathbf{x})$                 | marginal score, $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$                    |
| $\mathbf{s}_t^\theta(\mathbf{x})$          | 神经网络对 marginal score 的近似                                                      |
| $\mathbf{W}_t$                             | Brownian motion / Wiener process                                              |
| $\mathbf{u}_t$                             | forward SDE 中的 drift                                                          |
| $\sigma_t$                                 | forward SDE 中的 diffusion coefficient                                          |

**关于  $\epsilon$  的记号。** 概率论里常用大写字母表示随机变量、小写字母表示实现值, 但生成模型文献通常直接用  $\epsilon$  表示随机 Gaussian 噪声。本书保留这一字母习惯, 同时用向量语义宏明确它是  $d$  维随机向量:

$$\epsilon \sim \mathcal{N}(0, \mathbf{I}_d).$$

因此,  $\epsilon$  虽然是小写希腊字母, 在带有分布声明时仍表示随机量; 当需要强调一次具体采样时, 上下文会明确说明。

# 目录

|                              |     |
|------------------------------|-----|
| 前言                           | ii  |
| 符号约定                         | iii |
| 第一章 正向扩散：从数据分布到噪声分布          | 1   |
| 1.1 数据分布与正向扩散过程              | 1   |
| 1.2 Gaussian 加噪与条件分布         | 2   |
| 1.3 连续时间随机扩散过程               | 4   |
| 1.4 正向扩散中的概率密度演化             | 5   |
| 第二章 反向扩散：从得分学习到数据生成          | 7   |
| 2.1 得分函数与概率密度结构              | 7   |
| 2.2 Gaussian 条件得分与边缘得分       | 7   |
| 2.3 Denoising Score Matching | 9   |
| 2.4 得分函数与反向扩散动力学             | 13  |
| 2.5 扩散模型的训练与采样               | 15  |
| 附录 A 扩散模型推导所需的数学基础           | 18  |
| A.1 随机变量、概率密度与期望             | 18  |
| A.2 联合概率、条件概率与 Bayes 公式      | 18  |
| A.3 条件期望与 MSE                | 19  |
| A.4 Gaussian 分布与重参数化         | 20  |
| A.5 普通导数、偏导数与链式法则            | 20  |
| A.6 Gradient 与对数梯度           | 21  |
| A.7 Divergence 与 Laplacian   | 22  |
| A.8 随机过程与 Brownian Motion    | 22  |
| A.9 随机微分方程                   | 23  |
| A.10 Euler-Maruyama 方法       | 23  |
| A.11 Fokker-Planck Equation  | 23  |

---

|                                       |    |
|---------------------------------------|----|
| A.12 时间反演与 Reverse-Time SDE . . . . . | 24 |
| 全书公式索引                                | 29 |
| Flow Matching 与 Score Matching 对照     | 30 |

# 正向扩散：从数据分布到噪声分布

## 1.1 数据分布与正向扩散过程

生成模型的目标是从目标数据分布中得到新的样本。若真实数据随机变量记为

$$\mathbf{Z} \sim p_{\text{data}},$$

那么生成问题可以表述为：构造一个可计算的随机过程，使得从某个简单分布出发时，最终能够得到服从  $p_{\text{data}}$  的样本。

扩散模型采取的路线不是直接写出复杂数据分布的显式密度，而是先定义一个容易控制的**正向加噪过程**：从真实数据出发，逐渐加入随机扰动，使分布越来越简单，最终接近一个可以直接采样的噪声分布。随后利用训练得到的得分函数构造反向随机过程。

本书采用扩散模型文献中常见的时间方向：

$$t = 0 : \text{data}, \quad t \text{ 增大} : \text{noise 增强}.$$

因此，正向过程写成

$$\text{data} \longrightarrow \text{partially corrupted data} \longrightarrow \text{noise},$$

而生成阶段需要执行相反方向：

$$\text{noise} \longrightarrow \text{less noisy sample} \longrightarrow \text{data}.$$

**正向加噪过程的作用。** 真实数据分布通常只通过有限数据集给出，直接计算  $p_{\text{data}}(\mathbf{x})$  或其归一化常数并不现实。相反，若我们自己规定一个随机加噪机制，那么给定干净样本  $\mathbf{z}$  后，某一时刻的扰动分布  $p_t(\mathbf{x} | \mathbf{z})$  可以具有简单解析形式。训练时就可以从数据集中取  $\mathbf{z}$ ，再按已知机制生成对应的 noisy sample。

这一步把难以直接监督的反向生成目标，转化为容易构造的训练对：

$$z \longrightarrow x_t.$$

真正需要学习的反向信息将在第二章从这些训练对中提取。

## 1.2 Gaussian 加噪与条件分布

先从数据分布取随机变量

$$Z \sim p_{\text{data}},$$

并把一次具体 realization 记为  $z$ 。再取标准 Gaussian 噪声

$$\epsilon \sim \mathcal{N}(0, I).$$

考虑构造

$$X_t = \alpha_t z + \beta_t \epsilon. \quad (1.1)$$

这里  $\alpha_t$  与  $\beta_t$  是人为选定的时间函数，也称为 schedule 的一部分。 $\alpha_t$  控制保留多少数据成分， $\beta_t$  控制噪声尺度。

**对应的条件分布。** 因为  $\epsilon \sim \mathcal{N}(0, I)$ ，Gaussian 的仿射变换给出

$$X_t \mid Z = z \sim \mathcal{N}(\alpha_t z, \beta_t^2 I).$$

因此条件密度可以记为

$$p_t(x \mid z) = \mathcal{N}(x; \alpha_t z, \beta_t^2 I). \quad (1.2)$$

式 (1.2) 是**分布形式**，规定给定  $z$  时  $X_t$  的条件分布；式 (1.1) 是**采样形式**，给出从该分布直接生成样本的计算方式。

可以用一句固定规则记住二者的关系：

$$\mathcal{N}(\mu, \sigma^2 I) \iff \mu + \sigma \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

在当前场景中， $\mu = \alpha_t z$ ， $\sigma = \beta_t$ 。

数学基础提示：多元 Gaussian 与重参数化，详见附录 A.4。

**端点约束。** 在 diffusion time convention 下，理想化的理论边界取

$$\alpha_0 = 1, \quad \beta_0 = 0,$$

于是  $\mathbf{X}_0 = \mathbf{Z}$ 。随着时间增加，通常让  $\alpha_t$  逐渐减小、 $\beta_t$  逐渐增大；在有限终端时刻  $T$ ，常设计为

$$\alpha_T \approx 0, \quad \beta_T \approx 1,$$

从而

$$p_T \approx \mathcal{N}(0, \mathbf{I}).$$

注意：当  $\beta_0 = 0$  时，条件 Gaussian 在端点退化，包含  $1/\beta_t$  或  $1/\beta_t^2$  的 score / DSM 目标不在  $t = 0$  定义。因此本书把这些公式理解为  $t > 0$  上的关系；训练与数值计算默认使用  $t \in [t_{\min}, T]$ ，其中  $t_{\min} > 0$ 。实际 schedule 的精确形式可以不同，本书只使用其共同结构：数据成分逐渐衰减，噪声成分逐渐增强。

$\mathbf{X}_t$  与  $\mathbf{x}_t$ 。式 (1.1) 中  $\mathbf{X}_t$  表示随机状态。若训练时已经具体采样到一条  $\mathbf{z}$ 、一条  $\epsilon$  和一个时间  $t$ ，则得到的具体 noisy sample 可写作

$$\mathbf{x}_t = \alpha_t \mathbf{z} + \beta_t \epsilon. \quad (1.3)$$

两者结构相同，但含义层次不同： $\mathbf{X}_t$  是随机变量， $\mathbf{x}_t$  是一次 realization。

**任意时刻的直接采样。** 如果  $p_t(\mathbf{x} \mid \mathbf{z})$  的边缘分布已经有式 (1.2) 这样的闭式形式，那么训练时可以先采样  $t$ ，再一次性按式 (1.3) 得到  $\mathbf{x}_t$ 。这比从 0 到  $t$  模拟很多微小 SDE 步骤更直接。

因此正向加噪在训练中的核心接口是

$$(\mathbf{z}, t, \epsilon) \longrightarrow \mathbf{x}_t = \alpha_t \mathbf{z} + \beta_t \epsilon.$$

到这里，任意噪声水平的训练输入已经可以直接构造。下一步转向 noisy distribution 的时间演化，并明确反向生成所需要的分布信息。

### 1.3 连续时间随机扩散过程

上一节给出了任意时刻的 Gaussian noisy sample。为了描述随机状态随时间连续演化的过程，引入随机过程  $\{\mathbf{X}_t\}_{t \geq 0}$ 。同一个初始状态在不同随机扰动下可以产生不同轨迹，因此扩散模型中的随机性不仅存在于初始采样，也持续出现在时间演化中。

**小时间步上的随机更新。** 在一个很短的时间间隔  $h > 0$  上，可以先把连续随机过程理解为

$$\mathbf{X}_{t+h} \approx \mathbf{X}_t + h \mathbf{u}_t(\mathbf{X}_t) + \sigma_t \sqrt{h} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}). \quad (1.4)$$

式中  $\mathbf{u}_t(\mathbf{X}_t)$  决定平均移动趋势， $\sigma_t$  控制随机扰动强度。确定性变化与时间长度  $h$  成正比，而随机扰动的典型尺度是  $\sqrt{h}$ 。

**Brownian increment。** Brownian motion 记为  $\mathbf{W}_t$ 。它在长度为  $h$  的时间区间上的增量满足

$$\mathbf{W}_{t+h} - \mathbf{W}_t \sim \mathcal{N}(0, h\mathbf{I}),$$

因此可以写成

$$\mathbf{W}_{t+h} - \mathbf{W}_t = \sqrt{h} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}).$$

将这种连续时间随机增量记为  $d\mathbf{W}_t$ ，式 (1.4) 的极限形式写成

$$d\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) dt + \sigma_t d\mathbf{W}_t.$$

本书与课件统一使用  $\mathbf{u}_t(\mathbf{X}_t)$  表示漂移项，使用  $\sigma_t$  表示扩散系数。

**Gaussian path 与该 SDE 的兼容关系。** 上一节的 Gaussian 加噪并不是与 SDE 无关的另一套描述。若正向过程采用线性漂移

$$\mathbf{u}_t(\mathbf{x}) = f_t \mathbf{x}, \quad f_t = \frac{\dot{\alpha}_t}{\alpha_t} = \frac{d}{dt} \log \alpha_t,$$

并令扩散系数满足

$$\sigma_t^2 = \frac{d}{dt} \beta_t^2 - 2f_t \beta_t^2 \geq 0,$$

那么在  $\alpha_0 = 1, \beta_0 = 0$  时，该线性 SDE 的条件转移分布正是上一节的 Gaussian kernel。换言之， $\alpha_t, \beta_t$  与  $\mathbf{u}_t, \sigma_t$  不能彼此任意独立指定；若后文把同一族  $p_t$  的 score

放入 reverse-time SDE，就默认它们满足上述兼容关系。正文后续仍保留一般记号  $\mathbf{u}_t$ ，以便时间反演公式适用于更一般的漂移。

数学基础提示：Brownian motion、Brownian increment 与随机微分方程，详见附录 A.9。

**Euler–Maruyama 离散化。** 计算机不能直接执行无穷小量  $dt$  和  $d\mathbf{W}_t$ ，因此需要数值离散。步长为  $h$  时，最基本的 Euler–Maruyama 更新为

$$\mathbf{X}_{t+h} = \mathbf{X}_t + h \mathbf{u}_t(\mathbf{X}_t) + \sigma_t \sqrt{h} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}).$$

它正是式 (1.4) 的数值实现。随机项使用  $\sqrt{h}$  而不是  $h$ ，因为 Brownian increment 的方差与时间长度  $h$  成正比。

数学基础提示：Euler–Maruyama 方法，详见附录 A.10。

随机微分方程描述单条随机状态轨迹。所有随机轨迹共同形成时刻  $t$  的概率密度  $p_t(\mathbf{x})$ ，其时间演化由 Fokker–Planck equation 描述。

## 1.4 正向扩散中的概率密度演化

正向 SDE

$$d\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) dt + \sigma_t d\mathbf{W}_t$$

描述随机状态轨迹。与之对应的概率密度  $p_t(\mathbf{x})$  也随时间演化，而反向过程必须按照相反方向恢复这组边缘分布。

**Fokker–Planck 方程。** 在  $\sigma_t$  只依赖时间、各向同性的常见情形下，SDE 对应的密度满足

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla \cdot (\mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x})) + \frac{\sigma_t^2}{2} \Delta p_t(\mathbf{x}).$$

第一项由 drift 引起，第二项由随机噪声产生。 $\Delta$  是 Laplacian：

$$\Delta p = \sum_{i=1}^d \frac{\partial^2 p}{\partial x_i^2}.$$

它描述局部密度差异被随机扰动不断“摊平”的效应。

数学基础提示：Divergence、Laplacian 与 Fokker–Planck 方程，详见附录 A.11。

**反向过程的信息缺口。** 正向扩散的随机规则由我们自己规定，因此给定当前位置  $\mathbf{x}$  时，向前再加一个小噪声并不困难。反向过程不同：从一个 **noisy state** 往“更像数据”的方向移动，需要知道当前 **noisy distribution** 的局部结构。

设时刻  $t$  的边缘密度为  $p_t(\mathbf{x})$ 。如果某个位置处  $p_t(\mathbf{x})$  很低，而邻近某个方向上的概率密度更高，那么反向去噪需要利用这种密度信息。描述这种局部信息的量正是

$$\nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

这就是第二章要学习的对象：score function。

**第一章的结论与第二章的入口。** 第一章已经得到正向加噪机制：

$$\mathbf{z} \longrightarrow \mathbf{x}_t = \alpha_t \mathbf{z} + \beta_t \epsilon.$$

生成阶段需要在给定当前 **noisy state**  $\mathbf{x}_t$  和时间  $t$  时获得可用于反向随机动力学的局部分布信息。第二章从 **score function** 开始构造这一信息。

# 反向扩散：从得分学习到数据生成

## 2.1 得分函数与概率密度结构

对一个光滑概率密度  $q(\mathbf{x})$ ，定义它的 score function 为

$$\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} \log q(\mathbf{x}).$$

对时刻  $t$  的 noisy marginal density  $p_t(\mathbf{x})$ ，记

$$\mathbf{s}_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

**得分函数的几何意义。**  $\log$  是单调函数，因此  $\log p_t(\mathbf{x})$  与  $p_t(\mathbf{x})$  在同一个位置取得极值。梯度

$$\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$$

给出对数密度增大最快的局部方向。它不直接告诉我们某个样本“属于哪个训练样本”，而只描述当前 noisy distribution 在位置  $\mathbf{x}$  附近的局部形状。

数学基础提示：Gradient、对数梯度与多元链式法则，详见附录 A.6。

## 2.2 Gaussian 条件得分与边缘得分

**Gaussian 条件得分。** 边缘分布  $p_t(\mathbf{x})$  通常无法写成简单解析式，但给定干净数据  $\mathbf{z}$  后，Gaussian conditional density 已知：

$$p_t(\mathbf{x} | \mathbf{z}) = \frac{1}{(2\pi\beta_t^2)^{d/2}} \exp\left(-\frac{\|\mathbf{x} - \alpha_t \mathbf{z}\|^2}{2\beta_t^2}\right).$$

取对数：

$$\log p_t(\mathbf{x} | \mathbf{z}) = -\frac{d}{2} \log(2\pi) - d \log \beta_t - \frac{1}{2\beta_t^2} \|\mathbf{x} - \alpha_t \mathbf{z}\|^2.$$

对于  $\mathbf{x}$  求梯度时，前两项与  $\mathbf{x}$  无关，所以

$$\begin{aligned}\nabla_{\mathbf{x}} \log p_t(\mathbf{x} | \mathbf{z}) &= -\frac{1}{2\beta_t^2} \nabla_{\mathbf{x}} \|\mathbf{x} - \alpha_t \mathbf{z}\|^2 \\ &= -\frac{\mathbf{x} - \alpha_t \mathbf{z}}{\beta_t^2}.\end{aligned}\tag{2.1}$$

因此 conditional score 为

$$\mathbf{s}_t(\mathbf{x} | \mathbf{z}) = -\frac{\mathbf{x} - \alpha_t \mathbf{z}}{\beta_t^2}.$$

数学基础提示：平方范数的梯度与 Gaussian log-density 求导，详见附录 A.6。

**代入采样形式。** 训练时  $\mathbf{x}_t$  由

$$\mathbf{x}_t = \alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}$$

构造，因此

$$\mathbf{x}_t - \alpha_t \mathbf{z} = \beta_t \boldsymbol{\epsilon}.$$

代入式 (2.1):

$$\mathbf{s}_t(\mathbf{x}_t | \mathbf{z}) = -\frac{\boldsymbol{\epsilon}}{\beta_t}.\tag{2.2}$$

这条关系直接建立了“score learning”与“noise prediction”之间的联系：给定 Gaussian noising 机制后，conditional score 与当初加入的噪声只差一个已知的时间尺度因子。

**从条件得分到边缘得分。** 真正反向生成时并不知道干净数据  $\mathbf{z}$ 。因此不能把

$$\mathbf{s}_t(\mathbf{x} | \mathbf{z})$$

直接作为生成阶段的函数；需要的是只依赖当前  $(\mathbf{x}, t)$  的 marginal score  $\mathbf{s}_t(\mathbf{x})$ 。

首先，noisy marginal density 为

$$p_t(\mathbf{x}) = \int p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z}) d\mathbf{z}.$$

对  $\mathbf{x}$  求梯度：

$$\nabla_{\mathbf{x}} p_t(\mathbf{x}) = \int \nabla_{\mathbf{x}} p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z}) d\mathbf{z}.$$

利用

$$\nabla_{\mathbf{x}} p_t(\mathbf{x} | \mathbf{z}) = p_t(\mathbf{x} | \mathbf{z}) \nabla_{\mathbf{x}} \log p_t(\mathbf{x} | \mathbf{z}),$$

得到

$$\begin{aligned} \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) &= \frac{\nabla_{\mathbf{x}} p_t(\mathbf{x})}{p_t(\mathbf{x})} \\ &= \int \nabla_{\mathbf{x}} \log p_t(\mathbf{x} | \mathbf{z}) \frac{p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z})}{p_t(\mathbf{x})} d\mathbf{z}. \end{aligned}$$

由 Bayes 定理,

$$p(\mathbf{z} | \mathbf{x}, t) = \frac{p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z})}{p_t(\mathbf{x})}.$$

所以

$$\mathbf{s}_t(\mathbf{x}) = \int \mathbf{s}_t(\mathbf{x} | \mathbf{z}) p(\mathbf{z} | \mathbf{x}, t) d\mathbf{z}. \quad (2.3)$$

也就是

$$\mathbf{s}_t(\mathbf{x}) = \mathbb{E}[\mathbf{s}_t(\mathbf{x} | \mathbf{Z}) | \mathbf{X}_t = \mathbf{x}, t]. \quad (2.4)$$

数学基础提示: Bayes、posterior 与条件期望, 详见附录 A.2。

式 (2.4) 是后续训练证明的基础。conditional score 可以由  $(\mathbf{z}, \epsilon, t)$  直接计算; marginal score 是给定当前  $\mathbf{x}, t$  后所有 conditional score 的 posterior 平均。

## 2.3 Denoising Score Matching

**时间采样约定。** 下面所有含  $\mathbb{E}_t$  的训练目标都使用同一个时间采样分布  $t \sim \rho(t)$ , 其支持集位于  $[t_{\min}, T]$ , 其中  $t_{\min} > 0$ 。除非另有说明, 本书默认

$$t \sim \text{Unif}(t_{\min}, T).$$

采用其他时间权重时, 可以把权重显式写入 loss, 或等价地改变时间采样测度; 比较 DSM 与 SM 时必须保持两边使用同一时间测度与权重。

**理想 Score Matching 目标。** 若  $\mathbf{s}_t(\mathbf{x})$  可以直接计算, 自然可以训练网络

$$\mathbf{s}_t^\theta(\mathbf{x}) \approx \mathbf{s}_t(\mathbf{x})$$

并定义

$$\mathcal{L}_{\text{SM}}(\theta) = \mathbb{E}_{t, \mathbf{x} \sim p_t} \left[ \|\mathbf{s}_t^\theta(\mathbf{x}) - \mathbf{s}_t(\mathbf{x})\|^2 \right].$$

问题在于  $p_t(\mathbf{x})$  是对整个真实数据分布的混合， $\mathbf{s}_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$  通常不能作为逐样本监督标签直接得到。

而 conditional score

$$\mathbf{s}_t(\mathbf{x}_t | \mathbf{z}) = -\frac{\boldsymbol{\epsilon}}{\beta_t}$$

只需要训练数据  $\mathbf{z}$ 、随机噪声  $\boldsymbol{\epsilon}$  和时间  $t$ 。因此本节改用 conditional score 构造可训练 loss，并证明该目标仍然学习同一个 marginal score。

定义 Denoising Score Matching loss：

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{t, \mathbf{z}, \mathbf{x}} \left[ \|\mathbf{s}_t^\theta(\mathbf{x}) - \mathbf{s}_t(\mathbf{x} | \mathbf{z})\|^2 \right],$$

其中

$$\mathbf{z} \sim p_{\text{data}}, \quad \mathbf{x} \sim p_t(\cdot | \mathbf{z}).$$

使用 Gaussian reparameterization 时，也可以写成

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{t, \mathbf{z}, \boldsymbol{\epsilon}} \left[ \left\| \mathbf{s}_t^\theta(\alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}) + \frac{\boldsymbol{\epsilon}}{\beta_t} \right\|^2 \right].$$

**Denoising 命名的含义。** 网络输入是被噪声污染后的  $\mathbf{x}_t$ ，而 conditional target 由当初加入的噪声  $\boldsymbol{\epsilon}$  决定：

$$\mathbf{s}_t(\mathbf{x}_t | \mathbf{z}) = -\frac{\boldsymbol{\epsilon}}{\beta_t}.$$

因此训练过程要求网络从 noisy input 中恢复与污染噪声相关的信息。这里的 “denoising” 不是说训练时真的执行一条完整的反向轨迹，而是说监督信号来自对噪声污染的反演信息。

**DSM 与 SM 的等价性。** 对向量  $\mathbf{a}, \mathbf{b}$  有

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 - 2\mathbf{a}^\top \mathbf{b} + \|\mathbf{b}\|^2.$$

于是

$$\mathcal{L}_{\text{DSM}} = \mathbb{E}_{t, \mathbf{z}, \mathbf{x}} \left[ \|\mathbf{s}_t^\theta(\mathbf{x})\|^2 - 2\mathbf{s}_t^\theta(\mathbf{x})^\top \mathbf{s}_t(\mathbf{x} | \mathbf{z}) + \|\mathbf{s}_t(\mathbf{x} | \mathbf{z})\|^2 \right].$$

第一项中  $\mathbf{s}_t^\theta(\mathbf{x})$  与  $\mathbf{z}$  无关。对  $\mathbf{z}$  边缘化：

$$\begin{aligned} & \mathbb{E}_{\mathbf{z}, \mathbf{x}} \|\mathbf{s}_t^\theta(\mathbf{x})\|^2 \\ &= \int \int \|\mathbf{s}_t^\theta(\mathbf{x})\|^2 p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z}) d\mathbf{z} d\mathbf{x} \\ &= \int \|\mathbf{s}_t^\theta(\mathbf{x})\|^2 p_t(\mathbf{x}) d\mathbf{x}. \end{aligned}$$

因此

$$\mathbb{E}_{t, \mathbf{z}, \mathbf{x}} \|\mathbf{s}_t^\theta(\mathbf{x})\|^2 = \mathbb{E}_{t, \mathbf{x}} \|\mathbf{s}_t^\theta(\mathbf{x})\|^2.$$

再看交叉项：

$$\begin{aligned} & \mathbb{E}_{\mathbf{z}, \mathbf{x}} [\mathbf{s}_t^\theta(\mathbf{x})^\top \mathbf{s}_t(\mathbf{x} | \mathbf{z})] \\ &= \int \mathbf{s}_t^\theta(\mathbf{x})^\top \left[ \int \mathbf{s}_t(\mathbf{x} | \mathbf{z}) p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z}) d\mathbf{z} \right] d\mathbf{x}. \end{aligned}$$

由式 (2.3),

$$\int \mathbf{s}_t(\mathbf{x} | \mathbf{z}) p_t(\mathbf{x} | \mathbf{z}) p_{\text{data}}(\mathbf{z}) d\mathbf{z} = p_t(\mathbf{x}) \mathbf{s}_t(\mathbf{x}).$$

所以

$$\mathbb{E}_{t, \mathbf{z}, \mathbf{x}} [\mathbf{s}_t^\theta(\mathbf{x})^\top \mathbf{s}_t(\mathbf{x} | \mathbf{z})] = \mathbb{E}_{t, \mathbf{x}} [\mathbf{s}_t^\theta(\mathbf{x})^\top \mathbf{s}_t(\mathbf{x})].$$

第三项

$$C_{\text{cond}} = \mathbb{E}_{t, \mathbf{z}, \mathbf{x}} \|\mathbf{s}_t(\mathbf{x} | \mathbf{z})\|^2$$

不含参数  $\theta$ 。因此

$$\mathcal{L}_{\text{DSM}}(\theta) = A_\theta - 2B_\theta + C_{\text{cond}},$$

其中

$$\begin{aligned} A_\theta &= \mathbb{E}_{t, \mathbf{x}} \|\mathbf{s}_t^\theta(\mathbf{x})\|^2, \\ B_\theta &= \mathbb{E}_{t, \mathbf{x}} [\mathbf{s}_t^\theta(\mathbf{x})^\top \mathbf{s}_t(\mathbf{x})]. \end{aligned}$$

理想 Score Matching loss 展开为

$$\mathcal{L}_{\text{SM}}(\theta) = \mathbb{E}_{t, \mathbf{x}} [\|\mathbf{s}_t^\theta(\mathbf{x})\|^2 - 2\mathbf{s}_t^\theta(\mathbf{x})^\top \mathbf{s}_t(\mathbf{x}) + \|\mathbf{s}_t(\mathbf{x})\|^2]$$

$$= A_\theta - 2B_\theta + C_{\text{marg}},$$

其中

$$C_{\text{marg}} = \mathbb{E}_{t, \mathbf{x}} \|\mathbf{s}_t(\mathbf{x})\|^2$$

同样与  $\theta$  无关。于是

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathcal{L}_{\text{SM}}(\theta) + C,$$

其中

$$C = C_{\text{cond}} - C_{\text{marg}}$$

不依赖网络参数。因此

$$\arg \min_{\theta} \mathcal{L}_{\text{DSM}} = \arg \min_{\theta} \mathcal{L}_{\text{SM}},$$

并且

$$\nabla_{\theta} \mathcal{L}_{\text{DSM}} = \nabla_{\theta} \mathcal{L}_{\text{SM}}.$$

数学基础提示：条件期望、MSE 与积分换序，详见附录 A.3。

**MSE 的条件均值解释。** 同一结论也可以从 MSE 的一般性质理解。固定网络输入  $(\mathbf{x}, t)$  后，把随机 target 记为

$$\mathbf{Y} = \mathbf{s}_t(\mathbf{x} \mid \mathbf{Z}).$$

MSE 的最优预测是

$$\mathbb{E}[\mathbf{Y} \mid \mathbf{X}_t = \mathbf{x}, t].$$

由式 (2.4),

$$\mathbb{E}[\mathbf{s}_t(\mathbf{x} \mid \mathbf{Z}) \mid \mathbf{X}_t = \mathbf{x}, t] = \mathbf{s}_t(\mathbf{x}).$$

所以虽然单个训练标签是 conditional score，网络在给定同一 noisy state 时最终学习的是它们的 posterior average，即 marginal score。

**Score prediction 与 noise prediction。** Gaussian path 下，式 (2.2) 给出

$$\mathbf{s}_t(\mathbf{x}_t \mid \mathbf{z}) = -\frac{\epsilon}{\beta_t}.$$

若定义一个 noise-prediction 网络

$$\epsilon_\theta(\mathbf{x}_t, t) := -\beta_t \mathbf{s}_t^\theta(\mathbf{x}_t), \quad (2.5)$$

则

$$\mathbf{s}_t^\theta(\mathbf{x}_t) + \frac{\epsilon}{\beta_t} = -\frac{1}{\beta_t} (\epsilon_\theta(\mathbf{x}_t, t) - \epsilon).$$

因此 DSM 可以改写为

$$\mathcal{L}_{\text{DSM}} = \mathbb{E}_{t, \mathbf{z}, \epsilon} \left[ \frac{1}{\beta_t^2} \|\epsilon_\theta(\mathbf{x}_t, t) - \epsilon\|^2 \right].$$

这说明 score prediction 与 noise prediction 是同一 Gaussian 条件目标的两种参数化。若实现中直接使用未加  $1/\beta_t^2$  的 noise MSE，则等价于采用了不同的时间权重；网络预测对象仍然由式 (2.5) 联系起来。

当  $\beta_t$  很小时， $-\epsilon/\beta_t$  的幅值可能很大，因此实际实现经常通过预测参数化和时间权重改善数值尺度。这里不改变 score 的定义，只改变网络输出与 loss 的参数化方式。

## 2.4 得分函数与反向扩散动力学

前两节已经解决训练问题：利用可计算的 conditional score，可以训练网络得到

$$\mathbf{s}_t^\theta(\mathbf{x}) \approx \mathbf{s}_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x}).$$

下面把这一得分函数代回随机动力学，建立训练目标与反向生成之间的联系。

**正向扩散动力学。** 再次写出

$$d\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) dt + \sigma_t d\mathbf{W}_t, \quad t : 0 \rightarrow T.$$

在本书时间约定下， $t = 0$  是数据， $t = T$  接近简单 Gaussian 噪声。

正向过程对应的 Fokker-Planck 方程是

$$\partial_t p_t = -\nabla \cdot (\mathbf{u}_t p_t) + \frac{\sigma_t^2}{2} \Delta p_t.$$

反向生成要求从  $T$  往 0 运行一个随机过程，其边缘分布依次恢复为  $p_t$ 。

**Reverse-time SDE。** 在常见的各向同性  $\sigma_t$  只依赖时间的条件下，时间反演后的 SDE 可以写成

$$d\mathbf{X}_t = [\mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{X}_t)] dt + \sigma_t d\bar{\mathbf{W}}_t, \quad t: T \rightarrow 0. \quad (2.6)$$

这里积分方向是从  $T$  到  $0$ ，因此  $dt < 0$ ； $\bar{\mathbf{W}}_t$  表示反向时间中的 Brownian motion。score 项

$$\nabla_{\mathbf{x}} \log p_t(\mathbf{X}_t)$$

正是网络学习的对象。

为了避免“ $dt$  为负”带来的阅读负担，也可以定义新的正向时钟

$$\tau = T - t, \quad \mathbf{Y}_\tau = \mathbf{X}_{T-\tau}.$$

则  $\tau$  从  $0$  增加到  $T$ ，反向过程等价写成

$$d\mathbf{Y}_\tau = [-\mathbf{u}_{T-\tau}(\mathbf{Y}_\tau) + \sigma_{T-\tau}^2 \mathbf{s}_{T-\tau}(\mathbf{Y}_\tau)] d\tau + \sigma_{T-\tau} d\bar{\mathbf{W}}_\tau.$$

这两个公式表达同一个反向扩散过程，只是使用了不同时间坐标。

**严格推导的位置。** 式 (2.6) 不是人为规定的更新规则，而是正向扩散在时间反演下必须满足的结果。其推导需要同时使用 Fokker-Planck 方程、概率流 (probability current) 以及反向时钟  $\tau = T - t$ 。为保持正文主线连续，这些步骤集中放在附录 A.12；附录还说明了为何只比较 Fokker-Planck 方程的散度形式并不足以唯一确定反向漂移，以及空间依赖扩散矩阵下会出现的额外项。

**神经网络得分对真实得分的替代。** 训练结束后并不知道真实  $\mathbf{s}_t(\mathbf{x})$ ，因此使用

$$\mathbf{s}_t(\mathbf{x}) \approx \mathbf{s}_t^\theta(\mathbf{x}).$$

反向 SDE 变为

$$d\mathbf{X}_t = [\mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t^\theta(\mathbf{X}_t)] dt + \sigma_t d\bar{\mathbf{W}}_t, \quad t: T \rightarrow 0.$$

这就是训练目标与生成算法之间的连接：训练阶段学的是每个噪声水平上的 marginal score；生成阶段把它放进 reverse-time drift。

## 2.5 扩散模型的训练与采样

反向采样的初始分布。理论上，若正向过程的终端分布严格满足

$$p_T = \mathcal{N}(0, \mathbf{I}),$$

并且使用真实 score 连续地反演，则可以从  $\mathbf{X}_T \sim p_T$  出发精确恢复  $p_0 = p_{\text{data}}$ 。实际有限  $T$  的 schedule 通常只有

$$p_T \approx \mathcal{N}(0, \mathbf{I}),$$

因此实践中从容易采样的  $\mathcal{N}(0, \mathbf{I})$  启动时还包含 terminal-prior approximation。再考虑 score network 近似与数值离散误差，最终得到的是

$$\mathbf{X}_0 \stackrel{\text{approx}}{\sim} p_{\text{data}}.$$

**Euler–Maruyama 反向采样。** 令反向时间步长为  $\Delta t < 0$ 。一种基本离散化为

$$\mathbf{X}_{t+\Delta t} = \mathbf{X}_t + [\mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t^\theta(\mathbf{X}_t)] \Delta t + \sigma_t \sqrt{|\Delta t|} \boldsymbol{\xi},$$

其中

$$\boldsymbol{\xi} \sim \mathcal{N}(0, \mathbf{I}).$$

随机项的尺度是  $\sqrt{|\Delta t|}$ ，而不是  $|\Delta t|$ ，因为 Brownian increment 在时间长度  $h$  上的方差为  $h$ 。

数学基础提示：Brownian increment 与 Euler–Maruyama 数值方法，详见附录 A.10。

Listing 2.1: 扩散模型训练的核心采样逻辑（示意）

```

1  for z in dataloader:
2      eps = randn_like(z)
3      t = sample_uniform_time(z.shape[0], t_min, T)
4
5      alpha = alpha_t(t)
6      beta = beta_t(t)
7      x_t = alpha * z + beta * eps
8
9      # one common parameterization: predict the added Gaussian noise
10     eps_pred = model(x_t, t)
11     loss = mean((eps_pred - eps) ** 2)
12
13     optimizer.zero_grad()
14     loss.backward()
15     optimizer.step()

```

上面的 noise MSE 是常见参数化。它与 score prediction 通过

$$\epsilon_{\theta}(\mathbf{x}_t, t) = -\beta_t \mathbf{s}_t^{\theta}(\mathbf{x}_t)$$

联系。具体实现采用何种时间权重，需要结合所选 schedule 与训练目标确定。

Listing 2.2: Reverse SDE 的 Euler-Maruyama 采样逻辑（示意）

```

1  x = randn(sample_shape)           # X_T ~ N(0, I)
2
3  for t in reversed(time_grid):
4      score = score_model(x, t)
5      drift = u_t(x, t) - sigma_t(t)**2 * score
6
7      dt = negative_step(t)          # dt < 0
8      noise = randn_like(x)
9      x = x + drift * dt + sigma_t(t) * sqrt(abs(dt)) * noise
10
11 return x                           # approximate sample from p_data

```

训练与采样的完整关系。训练阶段：

$$\begin{aligned}
 t &\sim \text{Unif}(t_{\min}, T), \\
 \mathbf{z} &\sim p_{\text{data}}, \\
 \boldsymbol{\epsilon} &\sim \mathcal{N}(0, \mathbf{I}), \\
 \mathbf{x}_t &= \alpha_t \mathbf{z} + \beta_t \boldsymbol{\epsilon}, \\
 \mathbf{s}_t(\mathbf{x}_t \mid \mathbf{z}) &= -\frac{\boldsymbol{\epsilon}}{\beta_t}, \\
 \mathbf{s}_t^\theta(\mathbf{x}_t) &\approx \mathbf{s}_t(\mathbf{x}_t).
 \end{aligned}$$

生成阶段：

$$\begin{aligned}
 \mathbf{X}_T &\sim \mathcal{N}(0, \mathbf{I}), \\
 d\mathbf{X}_t &= [\mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t^\theta(\mathbf{X}_t)] dt + \sigma_t d\bar{\mathbf{W}}_t, \\
 t : T &\rightarrow 0, \\
 \mathbf{X}_0 &\overset{\text{approx}}{\sim} p_{\text{data}}.
 \end{aligned}$$

全书的主线可以概括为：先规定数据到噪声的正向扩散过程，再利用已知加噪机制构造 denoising 监督，学习 noisy marginal 的 score，最后把 score 代入 reverse-time SDE，从纯噪声逐步恢复数据。

# 扩散模型推导所需的数学基础

---

## A.1 随机变量、概率密度与期望

正文用途：正文 1.2 的 Gaussian 加噪，以及 2.2 的边缘化推导。。

**随机变量与具体取值。** 随机变量  $X$  描述随机实验结果；小写  $x$  通常表示一次具体取值。若

$$X \sim p,$$

则  $p(x)$  描述  $X$  在  $x$  附近的概率密度。

**期望。** 对连续随机变量  $X$ ,

$$\mathbb{E}[f(X)] = \int f(x)p(x) \, dx.$$

若有多个随机变量，例如  $(X, Z)$ ，则

$$\mathbb{E}[f(X, Z)] = \iint f(x, z)p(x, z) \, dx \, dz.$$

## A.2 联合概率、条件概率与 Bayes 公式

**联合、条件与边缘分布。** 联合密度可以分解为

$$p(x, z) = p(x \mid z)p(z).$$

只关心  $x$  时，对  $z$  积分：

$$p(x) = \int p(x, z) \, dz = \int p(x \mid z)p(z) \, dz.$$

这就是 marginalization。

**Bayes 定理。** 由

$$p(x, z) = p(x | z)p(z) = p(z | x)p(x)$$

得到

$$p(z | x) = \frac{p(x | z)p(z)}{p(x)}.$$

在扩散模型中把时间  $t$  作为条件时，常写为

$$p(z | \mathbf{x}, t) = \frac{p_t(\mathbf{x} | \mathbf{z})p_{\text{data}}(\mathbf{z})}{p_t(\mathbf{x})}.$$

这里

$$p_t(\mathbf{x} | \mathbf{z}) = p(\mathbf{x} | \mathbf{z}, t), \quad p_t(\mathbf{x}) = p(\mathbf{x} | t)$$

只是把“时刻  $t$ ”压缩到了下标中。

## A.3 条件期望与 MSE

**条件期望。** 对连续随机变量  $Z$ ,

$$\mathbb{E}[f(Z) | X = x] = \int f(z)p(z | x) dz.$$

所以

$$\mathbb{E}[s_t(\mathbf{x} | Z) | X_t = \mathbf{x}, t] = \int s_t(\mathbf{x} | z)p(z | \mathbf{x}, t) dz.$$

**MSE 与条件均值。** 令

$$\mathbf{m}(X) = \mathbb{E}[Y | X].$$

对任意预测函数  $f(X)$ , 有分解

$$\begin{aligned} \mathbb{E}\|f(X) - Y\|^2 &= \mathbb{E}\|f(X) - \mathbf{m}(X)\|^2 \\ &\quad + \mathbb{E}\|Y - \mathbf{m}(X)\|^2. \end{aligned}$$

第二项与  $f$  无关，因此 MSE 的最优预测为

$$f^*(X) = \mathbb{E}[Y | X].$$

这给出了 DSM 使用 conditional score 监督而学习 marginal score 的一般概率论解释。

## A.4 Gaussian 分布与重参数化

多元 Gaussian。若

$$\epsilon \sim \mathcal{N}(0, \mathbf{I}_d),$$

则

$$\mathbf{X} = \boldsymbol{\mu} + \sigma \epsilon$$

满足

$$\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_d).$$

其密度为

$$p(\mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{\|\mathbf{x} - \boldsymbol{\mu}\|^2}{2\sigma^2}\right).$$

因此 Gaussian noising

$$\mathbf{X}_t = \alpha_t \mathbf{z} + \beta_t \epsilon$$

立即得到

$$\mathbf{X}_t \mid \mathbf{Z} = \mathbf{z} \sim \mathcal{N}(\alpha_t \mathbf{z}, \beta_t^2 \mathbf{I}).$$

## A.5 普通导数、偏导数与链式法则

正文用途：正文 2.1 的基础求导，以及 2.2 的 Gaussian 条件得分推导。。

**普通导数与偏导数。** 如果函数只依赖一个变量  $t$ ，使用

$$\frac{df}{dt}.$$

若  $p = p(t, \mathbf{x})$  同时依赖时间和空间，固定  $\mathbf{x}$  对时间求导写成

$$\frac{\partial p}{\partial t}.$$

链式法则。若  $\mathbf{x} = \mathbf{x}(t)$ , 则

$$\frac{d}{dt}p(t, \mathbf{x}(t)) = \frac{\partial p}{\partial t} + \nabla_{\mathbf{x}}p(t, \mathbf{x}(t))^{\top} \frac{d\mathbf{x}}{dt}.$$

## A.6 Gradient 与对数梯度

log 求导。一维情况下

$$\frac{d}{dx} \log f(x) = \frac{f'(x)}{f(x)}.$$

多维情况下

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \frac{\nabla_{\mathbf{x}} p(\mathbf{x})}{p(\mathbf{x})}.$$

这就是 score 推导里反复使用的恒等式。

**Gradient.** 对标量函数  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ,

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_d} \end{bmatrix}.$$

平方范数的梯度。若  $\mathbf{a}$  与  $\mathbf{x}$  无关,

$$\|\mathbf{x} - \mathbf{a}\|^2 = (\mathbf{x} - \mathbf{a})^{\top}(\mathbf{x} - \mathbf{a}),$$

则

$$\nabla_{\mathbf{x}} \|\mathbf{x} - \mathbf{a}\|^2 = 2(\mathbf{x} - \mathbf{a}).$$

因此

$$\nabla_{\mathbf{x}} \left[ -\frac{1}{2\beta^2} \|\mathbf{x} - \mathbf{a}\|^2 \right] = -\frac{\mathbf{x} - \mathbf{a}}{\beta^2}.$$

## A.7 Divergence 与 Laplacian

**Divergence**。对向量场  $\mathbf{v} = (v_1, \dots, v_d)$ ,

$$\nabla \cdot \mathbf{v} = \sum_{i=1}^d \frac{\partial v_i}{\partial x_i}.$$

它衡量局部“流出”或“流入”的强弱。

**Laplacian**。对标量函数  $p$ ,

$$\Delta p = \nabla \cdot (\nabla p) = \sum_{i=1}^d \frac{\partial^2 p}{\partial x_i^2}.$$

在扩散方程中, Laplacian 描述局部密度差异被平滑的趋势。

**Fubini 定理**。在满足适当可积条件时, 多重积分可以交换顺序:

$$\int \int f(\mathbf{x}, \mathbf{z}) \, d\mathbf{x} \, d\mathbf{z} = \int \int f(\mathbf{x}, \mathbf{z}) \, d\mathbf{z} \, d\mathbf{x}.$$

DSM 与 SM 的 loss 等价证明用它把  $\mathbf{z}$  的边缘化和  $\mathbf{x}$  的积分重新排列。

## A.8 随机过程与 Brownian Motion

正文用途: 正文 1.3、2.4 与 2.5 的随机扩散、反向动力学和数值采样。。

**Brownian motion**。一维 Brownian motion  $W_t$  满足:

- $W_0 = 0$ ;
- 不相交时间区间上的增量独立;
- 对  $h > 0$ ,

$$W_{t+h} - W_t \sim \mathcal{N}(0, h).$$

因此在很短时间  $h$  上, Brownian increment 的典型尺度是

$$\sqrt{h}.$$

这解释了 Euler–Maruyama 随机项中的  $\sqrt{h}$ 。

## A.9 随机微分方程

SDE。一般 Itô SDE 写成

$$d\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) dt + \sigma_t(\mathbf{X}_t) d\mathbf{W}_t.$$

$\mathbf{u}_t$  决定平均漂移趋势， $\sigma_t$  控制随机扰动强度。在正文中主要考虑  $\sigma_t$  只依赖时间、且对各维度各向同性的情形。

## A.10 Euler–Maruyama 方法

**Euler–Maruyama**。对时间步  $h > 0$ ，从  $t$  到  $t + h$  的基本离散化为

$$\mathbf{X}_{t+h} \approx \mathbf{X}_t + \mathbf{u}_t(\mathbf{X}_t)h + \sigma_t\sqrt{h}\boldsymbol{\xi}, \quad \boldsymbol{\xi} \sim \mathcal{N}(0, \mathbf{I}).$$

若沿反向时间积分，可令  $\Delta t < 0$ ，并使用

$$\sqrt{|\Delta t|}$$

作为随机增量尺度。

**随机项的  $\sqrt{h}$  尺度**。如果写成  $h\boldsymbol{\xi}$ ，其协方差为  $h^2\mathbf{I}$ ；Brownian increment 的真实协方差应为  $h\mathbf{I}$ 。因此需要

$$\sqrt{h}\boldsymbol{\xi},$$

因为

$$\text{Cov}(\sqrt{h}\boldsymbol{\xi}) = h\mathbf{I}.$$

## A.11 Fokker–Planck Equation

正文用途：正文 1.4 的密度演化，以及 2.4 中 reverse-time SDE 的 score 修正。。

**Fokker-Planck 方程。** 考虑

$$d\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) dt + \sigma_t d\mathbf{W}_t,$$

其中  $\sigma_t$  与  $\mathbf{x}$  无关。若  $\mathbf{X}_t$  的密度为  $p_t(\mathbf{x})$ , 则

$$\partial_t p_t(\mathbf{x}) = -\nabla \cdot (\mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x})) + \frac{\sigma_t^2}{2} \Delta p_t(\mathbf{x}).$$

第一项是由确定性 drift 引起的概率质量搬运; 第二项是由 Brownian noise 引起的扩散。

**Heat equation 作为特殊情况。** 若  $\mathbf{u}_t = 0$  且  $\sigma_t = \sigma$  为常数,

$$\partial_t p_t = \frac{\sigma^2}{2} \Delta p_t,$$

这就是 heat equation。它把局部高密度向邻近低密度区域摊开, 因此是“扩散”一词的数学原型。

## A.12 时间反演与 Reverse-Time SDE

本节给出正文式 (2.6) 的推导。为了避免符号歧义, 先在一个单调增加的反向时钟  $\tau$  下推导, 再换回扩散模型文献常用的  $t: T \rightarrow 0$  写法。

**假设与记号。** 考虑  $d$  维正向扩散

$$d\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) dt + \sigma_t d\mathbf{W}_t, \quad 0 \leq t \leq T, \quad (\text{A.1})$$

其中  $\mathbf{W}_t$  是  $d$  维 Brownian motion,  $\sigma_t > 0$  是只依赖时间的标量, 因此扩散协方差为  $\sigma_t^2 \mathbf{I}$ 。假设  $\mathbf{u}_t$  与  $\sigma_t$  满足使 SDE 存在唯一非爆解的常见正则条件, 并且对  $0 < t < T$ ,  $\mathbf{X}_t$  具有严格为正且足够光滑的密度

$$p_t \in C^{1,2}((0, T) \times \mathbb{R}^d).$$

这些条件保证下文的 Fokker-Planck 方程、空间梯度与时间反演操作都有意义。

**正向 Fokker–Planck 方程。** 由附录 A.11, 式 (A.1) 的边缘密度满足

$$\partial_t p_t(\mathbf{x}) = -\nabla \cdot (\mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x})) + \frac{\sigma_t^2}{2} \Delta p_t(\mathbf{x}).$$

把右端写成连续性方程的形式。定义正向概率流

$$\mathbf{J}_t(\mathbf{x}) := \mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x}) - \frac{\sigma_t^2}{2} \nabla p_t(\mathbf{x}). \quad (\text{A.2})$$

则

$$\partial_t p_t(\mathbf{x}) = -\nabla \cdot \mathbf{J}_t(\mathbf{x}). \quad (\text{A.3})$$

$\mathbf{J}_t$  不仅描述密度在某点增加或减少, 还保留了概率质量穿过空间的局部方向信息。

**引入单调增加的反向时钟。** 定义

$$\tau = T - t, \quad \mathbf{Y}_\tau := \mathbf{X}_{T-\tau}, \quad 0 \leq \tau \leq T.$$

当  $\tau$  从 0 增加到  $T$  时, 原时间  $t$  从  $T$  减小到 0。  $\mathbf{Y}_\tau$  的边缘密度记为  $q_\tau$ , 由定义立即得到

$$q_\tau(\mathbf{x}) = p_{T-\tau}(\mathbf{x}). \quad (\text{A.4})$$

因此, 令  $t = T - \tau$ , 链式法则给出

$$\partial_\tau q_\tau(\mathbf{x}) = -\partial_t p_t(\mathbf{x}).$$

再利用式 (A.3):

$$\partial_\tau q_\tau(\mathbf{x}) = \nabla \cdot \mathbf{J}_t(\mathbf{x}) = -\nabla \cdot [-\mathbf{J}_t(\mathbf{x})]. \quad (\text{A.5})$$

**时间反演要求概率流反向。** 对真正的时间反演过程  $\mathbf{Y}_\tau = \mathbf{X}_{T-\tau}$ , 一条正向轨迹上在时刻  $t$  穿过某个小面的概率流, 在反向观察时必须以相反方向穿过同一个小面。因此实际的反向概率流满足

$$\mathbf{J}_\tau^R(\mathbf{x}) = -\mathbf{J}_{T-\tau}(\mathbf{x}). \quad (\text{A.6})$$

这里有一个容易忽略的严谨性问题: 仅从式 (A.5) 只能确定概率流的散度。两个概率流若相差一个散度为零的向量场, 仍会给出同一个密度演化。因此, **单独比较两边的 Fokker–Planck 方程并不能在高维中唯一确定反向漂移**。式 (A.6) 使用的是

“实际路径被时间反演”这一更强条件，它固定了概率流本身，而不仅是概率流的散度。

**设反向过程仍为扩散过程。** 时间反演定理在上述正则条件下给出： $\mathbf{Y}_\tau$  仍可表示为具有同一瞬时扩散协方差的 Markov diffusion。写成

$$d\mathbf{Y}_\tau = \mathbf{b}_\tau^R(\mathbf{Y}_\tau) d\tau + \sigma_{T-\tau} d\bar{\mathbf{W}}_\tau,$$

其中  $\bar{\mathbf{W}}_\tau$  是反向过程自身的 Brownian motion,  $\mathbf{b}_\tau^R$  是待求反向漂移。

该 SDE 的概率流为

$$\mathbf{J}_\tau^R(\mathbf{x}) = \mathbf{b}_\tau^R(\mathbf{x})q_\tau(\mathbf{x}) - \frac{\sigma_{T-\tau}^2}{2} \nabla q_\tau(\mathbf{x}).$$

把式 (A.4)、(A.2) 与 (A.6) 代入。令  $t = T - \tau$ , 得到

$$\begin{aligned} \mathbf{b}_\tau^R(\mathbf{x})p_t(\mathbf{x}) - \frac{\sigma_t^2}{2} \nabla p_t(\mathbf{x}) &= - \left[ \mathbf{u}_t(\mathbf{x})p_t(\mathbf{x}) - \frac{\sigma_t^2}{2} \nabla p_t(\mathbf{x}) \right] \\ &= -\mathbf{u}_t(\mathbf{x})p_t(\mathbf{x}) + \frac{\sigma_t^2}{2} \nabla p_t(\mathbf{x}). \end{aligned}$$

把左边的扩散项移到右边：

$$\mathbf{b}_\tau^R(\mathbf{x})p_t(\mathbf{x}) = -\mathbf{u}_t(\mathbf{x})p_t(\mathbf{x}) + \sigma_t^2 \nabla p_t(\mathbf{x}).$$

由于  $p_t(\mathbf{x}) > 0$ , 两边除以  $p_t(\mathbf{x})$ :

$$\mathbf{b}_\tau^R(\mathbf{x}) = -\mathbf{u}_t(\mathbf{x}) + \sigma_t^2 \frac{\nabla p_t(\mathbf{x})}{p_t(\mathbf{x})}.$$

利用恒等式

$$\frac{\nabla p_t(\mathbf{x})}{p_t(\mathbf{x})} = \nabla_x \log p_t(\mathbf{x}) = \mathbf{s}_t(\mathbf{x}),$$

得到

$$\mathbf{b}_\tau^R(\mathbf{x}) = -\mathbf{u}_t(\mathbf{x}) + \sigma_t^2 \mathbf{s}_t(\mathbf{x}), \quad t = T - \tau. \quad (\text{A.7})$$

因此，在单调增加的反向时钟  $\tau$  下，严格的反向 SDE 为

$$d\mathbf{Y}_\tau = \left[ -\mathbf{u}_{T-\tau}(\mathbf{Y}_\tau) + \sigma_{T-\tau}^2 \mathbf{s}_{T-\tau}(\mathbf{Y}_\tau) \right] d\tau + \sigma_{T-\tau} d\bar{\mathbf{W}}_\tau. \quad (\text{A.8})$$

这也是最不容易产生符号歧义的写法。

换回文献常用的  $t: T \rightarrow 0$  记法。由  $\tau = T - t$  有

$$d\tau = -dt.$$

将同一个反向过程重新用原时间标签  $t$  表示，并约定积分方向为  $T \rightarrow 0$ ，便得到正文使用的写法

$$d\mathbf{X}_t = \left[ \mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t(\mathbf{X}_t) \right] dt + \sigma_t d\bar{\mathbf{W}}_t, \quad t: T \rightarrow 0. \quad (\text{A.9})$$

这里的  $\bar{\mathbf{W}}_t$  表示按反向时间参数化的 Brownian noise。随机微分项不能像普通微分那样简单用 “ $d\tau = -dt$ ” 机械变号；更严谨的对象是式 (A.8)，式 (A.9) 是扩散模型文献中方便使用的下降时间记法。

**score 项的实际方向。** 式 (A.9) 中 score 前面写着负号，但生成时  $t$  在减小。取一步长度  $h > 0$ ，令

$$\Delta t = -h.$$

忽略高阶误差，Euler-Maruyama 更新为

$$\begin{aligned} \mathbf{X}_{t-h} &\approx \mathbf{X}_t + [\mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t(\mathbf{X}_t)](-h) + \sigma_t \sqrt{h} \boldsymbol{\xi} \\ &= \mathbf{X}_t - h\mathbf{u}_t(\mathbf{X}_t) + h\sigma_t^2 \mathbf{s}_t(\mathbf{X}_t) + \sigma_t \sqrt{h} \boldsymbol{\xi}, \quad \boldsymbol{\xi} \sim \mathcal{N}(0, \mathbf{I}). \end{aligned}$$

因此 score 对实际反向一步贡献的是

$$+h\sigma_t^2 \mathbf{s}_t(\mathbf{X}_t),$$

也就是沿  $\mathbf{s}_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$  指向的局部高密度方向移动。负号与直觉并不矛盾，它来自“方程写在下降的  $t$  上”这一时间约定。

**神经网络替代真实 score。** 真实  $\mathbf{s}_t(\mathbf{x}) = \nabla \log p_t(\mathbf{x})$  通常未知。Denoising Score Matching 训练得到

$$\mathbf{s}_t^\theta(\mathbf{x}) \approx \mathbf{s}_t(\mathbf{x}),$$

因此生成阶段使用

$$d\mathbf{X}_t = \left[ \mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t^\theta(\mathbf{X}_t) \right] dt + \sigma_t d\bar{\mathbf{W}}_t, \quad t: T \rightarrow 0.$$

这说明 **score network** 的作用不是直接输出最终数据，而是近似反向漂移中唯一依赖未知边缘密度  $p_t$  的那一项。

**一般扩散矩阵下的边界。** 若正向过程更一般地写成

$$d\mathbf{X}_t = \mathbf{b}_t(\mathbf{X}_t) dt + \mathbf{G}_t(\mathbf{X}_t) d\mathbf{W}_t,$$

并记

$$\mathbf{a}_t(\mathbf{x}) = \mathbf{G}_t(\mathbf{x})\mathbf{G}_t(\mathbf{x})^\top,$$

则扩散矩阵依赖空间位置时，反向漂移不能只写成  $-\mathbf{b} + \mathbf{a}\nabla \log p$ 。在反向时钟  $\tau$  下，其第  $i$  个分量为

$$b_{\tau,i}^R(\mathbf{x}) = -b_{t,i}(\mathbf{x}) + \sum_j \partial_{x_j} a_{t,ij}(\mathbf{x}) + \sum_j a_{t,ij}(\mathbf{x}) \partial_{x_j} \log p_t(\mathbf{x}), \quad t = T - \tau. \quad (\text{A.10})$$

本书正文采用

$$\mathbf{a}_t(\mathbf{x}) = \sigma_t^2 \mathbf{I},$$

且  $\sigma_t$  只依赖时间，因此

$$\sum_j \partial_{x_j} a_{t,ij}(\mathbf{x}) = 0,$$

式 (A.10) 正好化为式 (A.7)。这就是正文简化公式成立的边界条件。

# 全书公式索引

| 对象                                  | 公式                                                                                                                                                                       |
|-------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Gaussian 加噪                         | $\mathbf{X}_t = \alpha_t \mathbf{z} + \beta_t \epsilon$                                                                                                                  |
| Conditional density                 | $p_t(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x}; \alpha_t \mathbf{z}, \beta_t^2 \mathbf{I})$                                                                   |
| Gaussian path $\leftrightarrow$ SDE | $\mathbf{u}_t(\mathbf{x}) = f_t \mathbf{x}, f_t = \mathrm{d}(\log \alpha_t) / \mathrm{d}t, \sigma_t^2 = \mathrm{d}(\beta_t^2) / \mathrm{d}t - 2f_t \beta_t^2$            |
| Marginal density                    | $p_t(\mathbf{x}) = \int p_t(\mathbf{x} \mid \mathbf{z}) p_{\text{data}}(\mathbf{z}) \mathrm{d}\mathbf{z}$                                                                |
| Score                               | $\mathbf{s}_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$                                                                                                    |
| Conditional score                   | $\mathbf{s}_t(\mathbf{x} \mid \mathbf{z}) = -(\mathbf{x} - \alpha_t \mathbf{z}) / \beta_t^2$                                                                             |
| Noise form                          | $\mathbf{s}_t(\mathbf{x}_t \mid \mathbf{z}) = -\epsilon / \beta_t$                                                                                                       |
| Marginal score                      | $\mathbf{s}_t(\mathbf{x}) = \mathbb{E}[\mathbf{s}_t(\mathbf{x} \mid \mathbf{Z}) \mid \mathbf{X}_t = \mathbf{x}, t]$                                                      |
| DSM                                 | $\mathcal{L}_{\text{DSM}} = \mathbb{E} \ \mathbf{s}_t^\theta(\mathbf{x}) - \mathbf{s}_t(\mathbf{x} \mid \mathbf{z})\ ^2$                                                 |
| Noise parameterization              | $\epsilon_\theta(\mathbf{x}_t, t) = -\beta_t \mathbf{s}_t^\theta(\mathbf{x}_t)$                                                                                          |
| Forward SDE                         | $\mathrm{d}\mathbf{X}_t = \mathbf{u}_t(\mathbf{X}_t) \mathrm{d}t + \sigma_t \mathrm{d}\mathbf{W}_t$                                                                      |
| Fokker–Planck                       | $\partial_t p_t(\mathbf{x}) = -\nabla \cdot (\mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x})) + \frac{\sigma_t^2}{2} \Delta p_t(\mathbf{x})$                                    |
| Reverse-time SDE                    | $\mathrm{d}\mathbf{X}_t = [\mathbf{u}_t(\mathbf{X}_t) - \sigma_t^2 \mathbf{s}_t(\mathbf{X}_t)] \mathrm{d}t + \sigma_t \mathrm{d}\bar{\mathbf{W}}_t, t : T \rightarrow 0$ |

# Flow Matching 与 Score Matching 对照

本表只作为全书最后的概念对照。正文仍以 Diffusion Model 的 score 学习与反向扩散为主线。两类方法都可以从带噪中间状态  $\mathbf{X}_t$  出发，但神经网络学习的对象以及生成阶段对该对象的使用方式不同。

| 对比项                             | Flow Matching                                                                                                                         | Score Matching / Diffusion                                                                                  |
|---------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| 核心学习对象                          | 速度场 / 向量场 $\mathbf{u}_t^{\text{FM}}(\mathbf{x})$                                                                                      | 得分函数 $s_t(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$                                           |
| 直观含义                            | 当前位于 $\mathbf{x}_t$ 时，样本应以什么方向和速度移动                                                                                                   | 当前位于 $\mathbf{x}_t$ 时，概率密度在哪个方向增长最快                                                                         |
| 网络输入                            | $(\mathbf{x}_t, t)$                                                                                                                   | $(\mathbf{x}_t, t)$                                                                                         |
| Gaussian 条件目标                   | $\mathbf{u}_t^{\text{FM}}(\mathbf{x}_t   \mathbf{z}) = \dot{\alpha}_t \mathbf{z} + \dot{\beta}_t \boldsymbol{\epsilon}$               | $s_t(\mathbf{x}_t   \mathbf{z}) = -\boldsymbol{\epsilon} / \beta_t$                                         |
| 真正需要的边缘量                        | $\mathbf{u}_t^{\text{FM}}(\mathbf{x}) = \mathbb{E}[\mathbf{u}_t^{\text{FM}}(\mathbf{x}   \mathbf{Z})   \mathbf{X}_t = \mathbf{x}, t]$ | $s_t(\mathbf{x}) = \mathbb{E}[s_t(\mathbf{x}   \mathbf{Z})   \mathbf{X}_t = \mathbf{x}, t]$                 |
| 典型训练方法                          | Conditional Flow Matching                                                                                                             | Denoising Score Matching                                                                                    |
| MSE 的作用                         | 用可计算的 conditional velocity 监督网络，最优回归函数为 marginal velocity                                                                             | 用可计算的 conditional score 监督网络，最优回归函数为 marginal score                                                         |
| 生成阶段                            | 将学到的速度场直接放入 ODE 并积分                                                                                                                   | 将学到的 score 放入 reverse-time SDE，构造反向漂移并采样                                                                    |
| 与噪声 $\boldsymbol{\epsilon}$ 的关系 | 目标通常同时含 $\mathbf{z}$ 与 $\boldsymbol{\epsilon}$ ；直线路径下可化为数据与噪声之差                                                                       | Gaussian DSM 下 $s_t(\mathbf{x}_t   \mathbf{z}) = -\boldsymbol{\epsilon} / \beta_t$ ，因此常改写为 noise prediction |
| 一句话概括                           | 学习“样本怎样移动”                                                                                                                            | 学习“概率分布在当前位置的局部形状”                                                                                          |

**符号区分。**本表用  $\mathbf{u}_t^{\text{FM}}$  表示 Flow Matching 中神经网络学习的速度场；正文沿用  $\mathbf{u}_t$  表示正向扩散 SDE 中预先规定的 drift。二者角色不同，不应混淆。